



Отчет о проверке


Автор: ApiCorp

Название документа: ПЗ-основная часть.pdf

Проверяющий: ApiCorp

Организация: Федеральное государственное автономное образовательное учреждение высшего образования "Национальный исследовательский университет "Высшая школа экономики"

РЕЗУЛЬТАТЫ ПРОВЕРКИ



Совпадения:
24,04%



Оригинальность:
69,68%



ИИ-контент:
0%



Цитирования:
6,28%



Самоцитирования:
0%



«Совпадения», «Цитирования», «Самоцитирования», «Оригинальность» являются отдельными показателями, отображаются в процентах и в сумме дают 100%, что соответствует проверенному тексту документа.

Проверено: 96,71% текста документа, исключено из проверки: 3,29% текста документа. Разделы и элементы, отключенные пользователем: Таблицы

- Совпадения** — фрагменты проверяемого текста, полностью или частично сходные с найденными источниками, за исключением фрагментов, которые система отнесла к цитированию или самоцитированию. Показатель «Совпадения» — это доля фрагментов проверяемого текста, отнесенных к совпадениям, в общем объеме текста.
- Самоцитирование** — фрагменты проверяемого текста, совпадающие или почти совпадающие с фрагментом текста источника, автором или соавтором которого является автор проверяемого документа. Показатель «Самоцитирования» — это доля фрагментов текста, отнесенных к самоцитированию, в общем объеме текста.
- Цитирования** — фрагменты проверяемого текста, которые не являются авторскими, но которые система отнесла к корректно оформленным. К цитированиям относятся также шаблонные фразы; библиография; фрагменты текста, найденные модулем поиска «СПС Гарант: нормативно-правовая документация». Показатель «Цитирования» — это доля фрагментов проверяемого текста, отнесенных к цитированию, в общем объеме текста.
- Текстовое пересечение** — фрагмент текста проверяемого документа, совпадающий или почти совпадающий с фрагментом текста источника.
- Источник** — документ, проиндексированный в системе и содержащийся в модуле поиска, по которому проводится проверка.
- Оригинальный текст** — фрагменты проверяемого текста, не обнаруженные ни в одном источнике и не отмеченные ни одним из модулей поиска. Показатель «Оригинальность» — это доля фрагментов проверяемого текста, отнесенных к оригинальному тексту, в общем объеме текста.

Обращаем Ваше внимание, что система находит текстовые совпадения проверяемого документа с проиндексированными в системе источниками. При этом система является вспомогательным инструментом, определение корректности и правомерности совпадений или цитирований, а также авторства текстовых фрагментов проверяемого документа остается в компетенции проверяющего.

ИНФОРМАЦИЯ О ДОКУМЕНТЕ

Номер документа: 1392736

Тип документа: Не указано

Дата проверки: 12.05.2026 00:37:13

Дата корректировки: Нет

Количество страниц: 16

Символов в тексте: 29294

Слов в тексте: 3339

Число предложений: 1853

Комментарий: не указано

ПАРАМЕТРЫ ПРОВЕРКИ

Выполнена проверка с учетом редактирования: Да

Выполнено распознавание текста (OCR): Нет

Выполнена проверка с учетом структуры: Нет

Разделы и элементы, отключенные пользователем: Таблицы

Модули поиска: Коллекция НБУ, Шаблонные фразы, Профессиональная лексика. Медицина, Цитирование, Перефразирования по коллекции IEEE, Профессиональная лексика. АПК и биотех, PubMed, Коллекция открытых публикаций международных издательств, Перефразирования по базе публикаций открытого доступа PubMed, Патенты СССР, РФ, СНГ, СМИ России и СНГ, Перефразированные заимствования по коллекции Интернет в английском сегменте, Перефразирования по Коллекции открытых публикаций международных издательств, Переводные заимствования, Переводные заимствования по коллекции Гарант: аналитика, СПС ГАРАНТ: нормативно-правовая документация, IEEE, ИПС Адилет, Публикации eLIBRARY, Публикации РГБ (переводы и перефразирования), Кольцо вузов, Переводные заимствования по базе публикаций открытого доступа PubMed, Публикации РГБ, Переводные заимствования IEEE, СПС ГАРАНТ: аналитика, Переводные заимствования по Коллекции открытых публикаций международных издательств, Переводные заимствования по коллекции Интернет в русском сегменте, Сводная коллекция научных работ Беларуси, Медицина, Сводная коллекция ЭБС, Перефразирования по СПС ГАРАНТ: аналитика, Публикации eLIBRARY (переводы и перефразирования), Перефразированные заимствования по коллекции Интернет в русском сегменте, Переводные заимствования по коллекции Интернет в английском сегменте, Интернет Плюс, Собственная коллекция компании

ИСТОЧНИКИ

№	Доля в тексте	Доля в отчете	Источник	Актуален на	Модуль поиска	Комментарий
[01]	28,94%	7,18%	ПЗ_Макеев.pdf	11 Мая 2026	Собственная коллекция компании	
[02]	28,83%	2,67%	Пояснительная записка Тахунов....	11 Мая 2026	Собственная коллекция компании	
[03]	28,62%	0,82%	ПЗ_Тихонов_Илья.pdf	11 Мая 2026	Собственная коллекция компании	
[04]	27,31%	0,04%	Пояснительная записка_Жданок_...	11 Мая 2026	Собственная коллекция компании	
[05]	24,51%	0%	ФедоровНА_231_ПЗ.pdf	30 Апр 2026	Собственная коллекция компании	
[06]	24,42%	0%	Пояснительная записка.docx	11 Мая 2026	Собственная коллекция компании	
[07]	22,85%	4,04%	Кан Сергей КР https://hse.ru	23 Ноя 2017	Интернет Плюс	
[08]	22,34%	0%	ПЗ_Щагин (1).docx	10 Апр 2025	Собственная коллекция компании	
[09]	22,01%	1,07%	zagitov_a_luchshie-raboty https://hse.ru	17 Мая 2020	Интернет Плюс	
[10]	21,24%	2,01%	Бадретдинов Тимур КР https://hse.ru	23 Ноя 2017	Интернет Плюс	
[11]	21%	1,39%	Пояснительная записка.docx	11 Апр 2023	Собственная коллекция компании	
[12]	20,82%	0%	kazanceva_a_luchshie-raboty https://hse.ru	30 Дек 2017	Интернет Плюс	
[13]	17,14%	0%	993745833.pdf https://cs.hse.ru	23 Июн 2025	Интернет Плюс	
[14]	16,7%	0%	kupriyanov_k_luchshie-raboty https://hse.ru	17 Мая 2020	Интернет Плюс	
[15]	15,56%	0%	993745560.pdf https://cs.hse.ru	05 Июн 2025	Интернет Плюс	
[16]	15,5%	0%	Муратов Владимир КР https://hse.ru	30 Дек 2017	Интернет Плюс	
[17]	15,39%	0%	Пояснительная_Записка_Понома...	11 Мая 2023	Собственная коллекция компании	
[18]	14,85%	0%	marinosyan_n_luchshie-raboty https://hse.ru	12 Фев 2018	Интернет Плюс	
[19]	12,8%	0%	Бадретдинов Тимур КР https://hse.ru	23 Ноя 2017	Интернет Плюс	
[20]	10,32%	4,61%	993745833.pdf https://cs.hse.ru	23 Июн 2025	Перефразированные заимствования по коллекции Интернет в русском сегменте	
[21]	10,32%	0%	993745839.pdf	22 Мая 2025	Перефразированные заимствования по	

			https://cs.hse.ru		коллекции Интернет в русском сегменте
[22]	8,02%	0%	https://cs.hse.ru/mirror/pubs/shar... https://cs.hse.ru	02 Сен 2024	Перефразированные заимствования по коллекции Интернет в русском сегменте
[23]	7,11%	0%	Клепиков, Алексей Константинов... http://dlib.rsl.ru	01 Янв 2015	Публикации РГБ
[24]	6,82%	0,02%	993745560.pdf https://cs.hse.ru	05 Июн 2025	Перефразированные заимствования по коллекции Интернет в русском сегменте
[25]	5,71%	0%	Стандартизация и сертификация ... http://biblioclub.ru	21 Янв 2020	Сводная коллекция ЭБС
[26]	5,4%	0%	УТВЕРЖДЕН RU.17701729.501390-... https://pastebin.com	14 Фев 2024	Перефразированные заимствования по коллекции Интернет в русском сегменте
[27]	5,25%	0%	А. С. Тимонин ; Федеральное аге... http://dlib.rsl.ru	01 Янв 2008	Публикации РГБ
[28]	5,25%	0%	231576 http://biblioclub.ru	19 Апр 2016	Сводная коллекция ЭБС
[29]	5,04%	0,03%	Подготовка и оформление магис... http://elibrary.ru	01 Янв 2022	Публикации eLIBRARY (переводы и перефразирования)
[30]	4,97%	0%	Отчет_СП5_Климат_2023_Книга 4	22 Мар 2024	Кольцо вузов
[31]	4,77%	0%	Н-7385	31 Авг 2017	Кольцо вузов
[32]	4,68%	0%	Курсовая v1.3..docx	29 Ноя 2023	Кольцо вузов
[33]	4,66%	4,38%	Межгосударственный стандарт Г... http://ivo.garant.ru	30 Ноя 2014	СПС ГАРАНТ: нормативно-правовая документация
[34]	4,59%	0%	809765777.pdf https://cs.hse.ru	26 Сен 2024	Перефразированные заимствования по коллекции Интернет в русском сегменте
[35]	4,41%	0%	Стандартизация и сертификация ... https://geotar.ru	23 Ноя 2018	Сводная коллекция ЭБС
[36]	4,39%	0%	УТВЕРЖДЕН RU.17701729.501390-... https://pastebin.com	19 Мая 2025	Перефразированные заимствования по коллекции Интернет в русском сегменте
[37]	4,38%	0%	Проект Приказа Министерства св... http://ivo.garant.ru	22 Янв 2017	СПС ГАРАНТ: нормативно-правовая документация
[38]	4,38%	0%	Проект Приказа Министерства св... http://ivo.garant.ru	11 Янв 2017	СПС ГАРАНТ: нормативно-правовая документация
[39]	4,38%	0%	Сертификация программного и п...	12 Окт 2022	Публикации eLIBRARY
[40]	4,38%	0%	Валеев_Информационные_систе...	13 Ноя 2016	Кольцо вузов
[41]	4,02%	0%	НОРМАТИВНО-ПРАВОВАЯ ОСНО... http://elibrary.ru	01 Янв 2013	Публикации eLIBRARY
[42]	4,02%	0%	Выпускная работа бакалавра. http://elibrary.ru	01 Янв 2020	Публикации eLIBRARY
[43]	4,02%	0%	Стандартизация и управление ка...	07 Апр 2024	Кольцо вузов
[44]	4,02%	0%	Единая система программной до...	11 Янв 2024	Кольцо вузов
[45]	3,79%	0%	ВЕСТНИК МОЛОДЫХ УЧЕНЫХ ПГ... http://elibrary.ru	17 Окт 2015	Публикации eLIBRARY (переводы и перефразирования)
[46]	3,74%	0%	Дипломное проектирование по с...	19 Дек 2016	Медицина
[47]	3,68%	0%	ЦИФРОВЫЕ СИГНАЛЬНЫЕ ПРОЦЕ... http://elibrary.ru	01 Янв 2003	Публикации eLIBRARY
[48]	3,02%	0%	rsl01006525868.txt http://dlib.rsl.ru	01 Янв 2012	Публикации РГБ
[49]	3,02%	0%	Информационные таможенные т... https://e.lanbook.com	22 Янв 2020	Сводная коллекция ЭБС
[50]	2,84%	0%	Electric Drives Power-Hardware-in-... https://ieeexplore.ieee.org	01 Ноя 2018	IEEE

[51]	2,84%	0%	Простановка размеров на черте... http://elibrary.ru	01 Янв 2014	Публикации eLIBRARY	
[52]	2,49%	0%	https://cs.hse.ru/mirror/pubs/shar... https://cs.hse.ru	02 Сен 2024	Перефразированные заимствования по коллекции Интернет в русском сегменте	
[53]	2,45%	0%	Основы программирования https://book.ru	01 Янв 2024	Сводная коллекция ЭБС	
[54]	2,31%	0%	Метрологическая экспертиза тех... https://e.lanbook.com	22 Янв 2020	Сводная коллекция ЭБС	
[55]	2,16%	0%	Жмылёв, Сергей Александрович ... http://dlib.rsl.ru	01 Янв 2019	Публикации РГБ	
[56]	2,11%	0%	813271814.pdf https://cs.hse.ru	09 Окт 2024	Перефразированные заимствования по коллекции Интернет в русском сегменте	
[57]	2%	0%	253601 http://biblioclub.ru	19 Апр 2016	Сводная коллекция ЭБС	
[58]	1,9%	1,9%	Перечень технической и техноло... http://ivo.garant.ru	24 Сен 2020	СПС ГАРАНТ: нормативно-правовая документация	
[59]	1,9%	0%	Ю. П. Ехлаков ; Федеральное аге... http://dlib.rsl.ru	01 Янв 2007	Публикации РГБ	
[60]	1,87%	0%	Клепиков, Алексей Константинов... http://dlib.rsl.ru	01 Янв 2015	Публикации РГБ (переводы и перефразирования)	
[61]	1,7%	0%	p_2619_911	07 Апр 2017	Кольцо вузов	
[62]	1,64%	0%	Основные правила работы с нау... http://ivo.garant.ru	02 Дек 2014	СПС ГАРАНТ: нормативно-правовая документация	
[63]	1,57%	0,18%	А. С. Тимонин ; Федеральное аге... http://dlib.rsl.ru	01 Янв 2008	Публикации РГБ (переводы и перефразирования)	
[64]	1,57%	0%	Сертификация программного и п...	12 Окт 2022	Публикации eLIBRARY (переводы и перефразирования)	
[65]	1,42%	0%	Особенности технических испыт... http://ivo.garant.ru	20 Окт 2018	Перефразирования по СПС ГАРАНТ: аналитика	
[66]	1,34%	0%	Особенности технических испыт... http://ivo.garant.ru	20 Окт 2018	СПС ГАРАНТ: аналитика	
[67]	1,29%	0%	Технология разработки програм... https://geotar.ru	04 Авг 2018	Сводная коллекция ЭБС	
[68]	1,28%	0%	Оформление дипломных проект...	19 Дек 2016	Медицина	
[69]	1,28%	0%	Оформление дипломных проект...	19 Дек 2016	Медицина	
[70]	1,27%	0%	Основы цифровой схмотехники	19 Дек 2016	Медицина	
[71]	1,22%	0%	Подготовка и оформление выпус...	24 Окт 2024	Публикации eLIBRARY (переводы и перефразирования)	
[72]	1,02%	0%	Нормативное обеспечение в сфе...	30 Апр 2025	Публикации eLIBRARY	
[73]	1,01%	0%	Технология проектирования авт...	20 Дек 2016	Медицина	
[74]	0,95%	0%	Крюкова МД. 181-324. Учебная п...	25 Мар 2022	Кольцо вузов	
[75]	0,86%	0%	Нормативное обеспечение в сфе...	30 Апр 2025	Публикации eLIBRARY (переводы и перефразирования)	
[76]	0,79%	0%	Постановление администрации ... http://municipal.garant.ru	18 Сен 2021	СПС ГАРАНТ: нормативно-правовая документация	Источник исключен. Причина: Маленький процент пересечения.
[77]	0,7%	0%	Приказ Министерства здравоохранения ... http://ivo.garant.ru	25 Сен 2017	СПС ГАРАНТ: нормативно-правовая документация	Источник исключен. Причина: Маленький процент пересечения.
[78]	0,65%	0%	Экдистериоды растений семейств... http://diss.natlib.uz	12 Фев 2019	Коллекция НБУ	Источник исключен. Причина: Маленький процент пересечения.
[79]	0,62%	0%	_ВКР_ПятаеваАА_17СМ(ба)ОП_180...	18 Июн 2021	Кольцо вузов	Источник исключен. Причина: Маленький процент пересечения.
[80]	0,61%	0%	Модели и программные средства... https://elib.nlb.by	01 Янв 2005	Сводная коллекция научных работ Беларуси	Источник исключен. Причина: Маленький процент пересечения.

[81]	0,48%	0%	Разработка технологии эластичн... https://elib.nlb.by	01 Янв 2002	Сводная коллекция научных работ Беларуси	Источник исключен. Причина: Маленький процент пересечения.
[82]	0,46%	0%	Об утверждении технического за... https://adilet.zan.kz	14 Дек 2025	ИПС Адилет	Источник исключен. Причина: Маленький процент пересечения.
[83]	0,43%	0%	Межгосударственный стандарт Г... http://ivo.garant.ru	25 Ноя 2014	СПС ГАРАНТ: нормативно-правовая документация	Источник исключен. Причина: Маленький процент пересечения.
[84]	0,43%	0%	Стандартизация и разработка пр...	19 Дек 2016	Медицина	Источник исключен. Причина: Маленький процент пересечения.
[85]	0,33%	0%	Разработка мобильного приложе... http://elibrary.ru	01 Янв 2018	Публикации eLIBRARY	Источник исключен. Причина: Маленький процент пересечения.
[86]	0,33%	0%	Разработка мобильной игры "Пр...	12 Мая 2025	Кольцо вузов	Источник исключен. Причина: Маленький процент пересечения.
[87]	0,33%	0%	Коротких, Виталий Федорович Ра... http://dlib.rsl.ru	01 Янв 2008	Публикации РГБ	Источник исключен. Причина: Маленький процент пересечения.
[88]	0,32%	0%	Управление и инноватика в тепл...	19 Дек 2016	Медицина	Источник исключен. Причина: Маленький процент пересечения.
[89]	0,32%	0%	Управление и инноватика в тепл... https://geotar.ru	09 Апр 2019	Сводная коллекция ЭБС	Источник исключен. Причина: Маленький процент пересечения.
[90]	0,28%	0%	Несын, Георгий Викторович Пол... http://dlib.rsl.ru	01 Янв 2007	Публикации РГБ	Источник исключен. Причина: Маленький процент пересечения.
[91]	0,25%	0%	Особенности разработки програ...	09 Июл 2025	Публикации eLIBRARY (переводы и перефразирования)	Источник исключен. Причина: Маленький процент пересечения.
[92]	0,22%	0%	Техническое обслуживание и ре... https://book.ru	03 Июл 2017	Сводная коллекция ЭБС	Источник исключен. Причина: Маленький процент пересечения.
[93]	0,13%	0%	не указано	13 Янв 2022	Шаблонные фразы	Источник исключен. Причина: Маленький процент пересечения.

АННОТАЦИЯ

Данный программный документ представляет собой пояснительную записку к программному проекту «Быстрая реализация вещественных и квантованных сверточных нейронных сетей на мобильных устройствах Apple» содержит следующие разделы: «Введение», «Назначение и область применения», «Технические характеристики», «Ожидаемые технико-экономические показатели», приложения.

Раздел «Введение» включает в себя наименование программы и документ, на основании которого ведётся разработка, с указанием организации, утвердившей данный документ.

В разделе «Назначение и область применения» содержатся функциональное и эксплуатационное назначение программы и краткая характеристика области её применения.

В разделе «Назначение разработки» указано функциональное и эксплуатационное назначение создаваемого программного продукта.

В разделе «Технические характеристики» присутствуют следующие подразделы: постановка задачи на разработку программы, описание функционирования программы, описание и обоснование алгоритма работы программы, описание и обоснование выбора метода организации входных и выходных данных, описание работы с базой данных, описание и обоснование выбора состава технических и программных средств.

Раздел «Требования к программным документам» содержит указание на предварительный состав программной документации и специальные требования к ней.

В разделе «Ожидаемые технико-экономические показатели» указана предполагаемая потребность и экономические преимущества разработки по сравнению с отечественными и зарубежными образцами или аналогами.

Настоящий документ разработан в соответствии с требованиями:

1. СТ 19.101-77 [1]: Виды программ и программных документов.
2. ГОСТ 19.102-77 [2]: Стадии разработки.
3. ГОСТ 19.103-77 [3]: Обозначения программ и программных документов.
4. ГОСТ 19.104-78 [4]: Основные надписи.
5. ГОСТ 19.105-78 [5]: Общие требования к программным документам.
6. ГОСТ 19.106-78 [6]: Требования к программным документам, выполненным печатным способом.
7. ГОСТ 19.404-79 [10]: Пояснительная записка. Требования к содержанию и оформлению.

Изменения к данной Пояснительной записке оформляются согласно ГОСТ 19.603-78 [12], ГОСТ 19.604-78 [13].

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 81 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

СОДЕРЖАНИЕ

1. ВВЕДЕНИЕ	4
1.1. Наименование программы	4
1.2. Документ(ы), на основании которого(ых) ведется разработка	4
1.3. Краткая характеристика области применения программы	4
2. НАЗНАЧЕНИЕ РАЗРАБОТКИ	5
2.1. Функциональное назначение	5
2.2. Эксплуатационное назначение	5
2.3. Краткая характеристика области применения программы	6
3. ТЕХНИЧЕСКИЕ ХАРАКТЕРИСТИКИ	7
3.1. Постановка задачи на разработку программы	7
3.2. Описание обоснование выбора состава технических и программных средств	7
3.2.1. Состав технических и программных средств	7
3.2.2. Обоснование выбора технических и программных средств	7
3.3. Описание и обоснование архитектуры программы	8
3.4. Особенности функционала	8
3.4.1. Тензорное ядро и матричные операции	8
3.4.2. im2col и сверточные слои	9
3.4.3. Квантованные представления	9
3.4.4. Модуль тестирования и бенчмаркинга	9
3.5. Обоснование выбора метода организации входных и выходных данных	9
4. ОЖИДАЕМЫЕ ТЕХНИКО-ЭКОНОМИЧЕСКИЕ ПОКАЗАТЕЛИ	11
4.1. Ориентировочная экономическая эффективность	11
4.2. Предполагаемая потребность	11
ПРИЛОЖЕНИЕ 1. СПИСОК ИСПОЛЬЗУЕМОЙ ЛИТЕРАТУРЫ	12
ПРИЛОЖЕНИЕ 2. ТЕРМИНОЛОГИЯ	13
ПРИЛОЖЕНИЕ 3. ГРАФИК СРАВНЕНИЯ ПРОИЗВОДИТЕЛЬНОСТИ	15

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 81 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

1. ВВЕДЕНИЕ

1.1. Наименование программы

Наименование программы 7 «Быстрая реализация вещественных и квантованных сверточных нейронных сетей на мобильных устройствах Apple».

Наименование программы на английском языке – «Fast Implementation of Floating-Point and Quantized Convolutional Neural Networks on Apple Mobile Devices».

1.2. 24 документ(ы), на основании которого(ых) ведется разработка

Разработка ведется на основании учебного плана подготовки бакалавров по направлению 09.03.04 «Программная инженерия» и утвержденной академическим руководителем программы темы курсового проекта.

1.3. Краткая характеристика области применения 2 программы 29

В современных мобильных вычислительных системах всё чаще требуется выполнять алгоритмы компьютерного зрения непосредственно на пользовательском устройстве. Такой подход позволяет уменьшить задержку обработки, снизить зависимость приложения от сетевого соединения и ограничить передачу пользовательских данных на внешние серверы. Для задач распознавания изображений и анализа видеопотока существенную часть вычислительной нагрузки составляют операции свертки и матричного умножения, поэтому эффективность их реализации напрямую влияет на практическую применимость нейронной модели.

Проект ориентирован на устройства Apple Silicon, в которых доступны как универсальные вычислительные ресурсы CPU, так и специализированные механизмы ускорения матричных операций. В рамках работы рассматривается выполнение сверточных нейронных сетей в вещественном и квантованном представлении, а также сравнение эталонного CPU/NEON-исполнения с ускоренным AMX/Accelerate-исполнением. Разрабатываемая библиотека предназначена для использования в составе приложений, где требуется локальный и воспроизводимый инференс модели без обучения. 4

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 81 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата 2

2. НАЗНАЧЕНИЕ РАЗРАБОТКИ

2.1. Функциональное назначение

Разрабатываемая программа предназначена для **2** выполнения основных операций сверточных нейронных моделей на устройствах Apple Silicon. Программный продукт должен предоставлять модульный C++ API для выполнения прямого прохода нейронной сети, выбора режима вычислений, проверки корректности результатов и измерения производительности.

Программа должна обеспечивать выполнение следующих основных функций:

- создание и управление тензорами, включая описание формы, типа данных и режима вычислений;
- выполнение базовых операций линейной алгебры, включая матричное умножение (GEMM);
- преобразование свертки в матричное умножение с помощью алгоритма im2col;
- поддержку путей исполнения CPU/NEON и AMX/Accelerate с возможностью резервного переключения;
- поддержку вещественных и квантованных представлений данных различной разрядности;
- реализацию базовых слоев нейронных сетей: Conv2D, Linear, ReLU, Softmax, AvgPool2D, Flatten;
- загрузку весов модели из JSON-файлов и запуск инференса тестовой сети LeNet;
- измерение производительности и проверку корректности вычислений.

Функциональность программы распределяется между двумя группами компонентов. Первая группа относится к базовому тензорному ядру и включает описание формы тензора, выделение и хранение данных, доступ к элементам, создание представлений без копирования, итерацию по данным и выполнение элементарных операций. Вторая группа относится к уровню нейронных сетей и включает слои свертки, пулинга, активации, выравнивания и полносвязные слои, объединяемые в тестовую архитектуру LeNet.

Разработка должна обеспечивать проверяемость вычислений. Для этого CPU/NEON-исполнение рассматривается как эталонный и резервный путь, а AMX/Accelerate-исполнение используется для ускорения матричных операций на совместимых устройствах. Результаты ускоренного пути должны сравниваться с эталонными результатами с учетом допустимой численной погрешности.

2.2. Эксплуатационное назначение

Основными конечными пользователями разрабатываемого программного продукта являются разработчики приложений и специалисты по машинному обучению, работающие с моделями компьютерного зрения на базе Apple Silicon.

Программа предоставляет возможность реализации оптимизированных и энергоэффективных сверточных нейронных сетей на устройствах Apple Silicon с сопоставлением эффективности CPU/NEON- и AMX-исполнения при вещественном и квантованном представлении данных.

В эксплуатационном сценарии пользователь подготавливает веса модели в формате JSON, передает входное изображение или заранее сформированный тензор в библиотеку, выбирает требуемый путь исполнения и получает выходной тензор с результатами работы сети. Для проверки работы библиотеки предусмотрены тестовые изображения из набора MNIST и файл весов mnist_lenet.json,

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 81 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата 7

что позволяет воспроизводимо проверять классификацию цифр и корректность загрузки параметров модели.

2.3. Краткая характеристика области применения программы

Программа «Быстрая реализация вещественных и квантованных сверточных нейронных сетей на мобильных устройствах Apple» относится к области системного программирования и оптимизации нейросетевых вычислений. Предметной областью является выполнение тензорных операций, необходимых для сверточных нейронных сетей, с использованием аппаратных возможностей Apple Silicon.

Область применения программы включает обработку изображений в реальном времени, исследование эффективности AMX/Accelerate по сравнению с CPU/NEON, а также оценку влияния квантования на скорость и точность инференса.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 81 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата 1

3. ТЕХНИЧЕСКИЕ ХАРАКТЕРИСТИКИ

3.1. Постановка задачи на разработку программы

Целью разработки является создание **1** высокопроизводительной программной библиотеки для выполнения прямого прохода сверточных нейронных сетей на устройствах Apple Silicon.

Основная задача заключается в реализации набора вычислительных компонентов, обеспечивающих выполнение операций нейронной сети в нескольких режимах: эталонном CPU/NEON-режиме, ускоренном AMX/Accelerate-режиме и режиме с квантованным представлением данных. Для достижения указанной цели необходимо реализовать общее тензорное представление данных, преобразование `im2col` для сверточных слоев, механизм выбора пути исполнения и воспроизводимые средства проверки производительности.

Ожидаемым результатом является библиотека, способная загружать веса предобученной модели, выполнять прямой проход сети LeNet и предоставлять данные для сравнения корректности и скорости разных путей исполнения.

3.2. Описание и обоснование выбора состава технических и программных средств

3.2.1. Состав технических и программных средств

Для разработки и тестирования программы используются следующие технические и программные средства: **10**

- оборудование: устройства на базе Apple Silicon (процессоры серий M или A);
- операционная система: macOS или iOS;
- язык программирования: C++17 или выше;
- системные библиотеки: Apple Accelerate Framework, BLAS/LAPACK, доступные механизмы AMX;
- векторные инструкции: ARM NEON для эталонного CPU-пути;
- инструменты разработки: Xcode, Clang, CMake;
- вспомогательные инструменты: Python 3 для конвертации весов через `pt2json.py`;
- форматы данных: JSON для весов модели, JPEG/PNG для входных изображений.

В коде проекта поддерживаются вещественные и целочисленные типы данных `int8`, `int16`, `int32`, `int64`, `float32` и `float64`. Для описания вычислительного устройства используется перечисление режимов `cpu`, `neon` и `amx`. Такое разделение позволяет на уровне типа тензора фиксировать как формат данных, так и предполагаемый путь исполнения, что упрощает статическую организацию кода и уменьшает риск случайного смешивания несовместимых представлений.

3.2.2. Обоснование выбора технических и программных средств

Выбор языка C++ обусловлен необходимостью низкоуровневого управления памятью и минимизации накладных расходов при выполнении тензорных операций. Архитектура Apple Silicon выбрана в качестве целевой, поскольку она позволяет исследовать взаимодействие CPU, NEON, AMX и объединенной памяти в рамках одного программного продукта. Формат JSON используется для прозрачной передачи весов из среды обучения в среду исполнения и упрощения отладки загрузки модели.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 81 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата 1

3.3. Описание и обоснование архитектуры программы

Архитектура программы построена по модульному принципу с разделением уровней представления данных, базовых операций, бэкендов исполнения и высокоуровневых слоев нейронной сети.

Основные компоненты архитектуры:

1. Слой представления данных: Tensor, TensorDesc, TensorView и описание типов данных.
2. Слой операций: элементарные операции, матричное умножение, im2col, функции активации.
3. Слой бэкендов: CPU/NEON-реализация, AMX/Accelerate-реализация и механизм fallback.
4. Слой нейронных сетей: Layer, Conv2D, Linear, LeNet и вспомогательные слои.
5. Слой сериализации: загрузка весов модели из JSON-файлов.

Такое разделение позволяет независимо развивать тензорное ядро, оптимизированные бэкенды и высокоуровневые нейросетевые слои.

На уровне исходного кода публичный интерфейс разделен на агрегирующие заголовочные файлы core.hpp и nn.hpp. Первый объединяет базовые структуры данных и операции, второй предоставляет слои нейронной сети. Реализации шаблонных компонентов вынесены в файлы с расширением.hpp.inl, что позволяет сохранять раздельную структуру проекта и одновременно использовать шаблонные классы без отдельной компоновки специализаций.

Слой сериализации представлен загрузчиком JSON-модели. Он формирует набор состояний слоев, где для каждого слоя хранятся именованные тензоры весов и смещений. Такой формат соответствует потребностям архитектуры LeNet: сверточные и полносвязные слои получают свои параметры по идентификаторам conv1, conv2, fc1, fc2 и fc3, после чего могут использовать их в прямом проходе.

3.4. Особенности функционала

3.4.1. Тензорное ядро и матричные операции

Назначение модуля состоит в обеспечении единого интерфейса для работы с многомерными массивами данных. Модуль выполняет создание тензоров, проверку совместимости размерностей, доступ к данным и передачу буферов в операции матричного умножения. Для проверки корректности ускоренных вычислений используется CPU/NEON-эталон.

Описание тензора включает форму, шаги обхода и смещение относительно начала буфера. Благодаря этому библиотека может создавать представления тензоров, выполнять транспонирование и срезы без обязательного копирования данных. При необходимости пользователь может получить непрерывное представление данных, что важно для передачи буфера в низкоуровневые операции матричного умножения и в ускоренные бэкенды.

Операция матричного умножения проверяет размерности входных аргументов и поддерживает случаи перемножения векторов, матрицы на вектор, вектора на матрицу и двух матриц. При несовместимых формах операция должна завершаться диагностической ошибкой. Такой подход соответствует требованиям ТЗ к устойчивости программы при некорректных входных данных и позволяет использовать CPU/NEON-реализацию как проверяемую базу для ускоренных вариантов.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 81 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата 1

3.4.2. im2col и сверточные слои

Назначение модуля im2col состоит в преобразовании локальных областей входного изображения в матричное представление. Такое преобразование позволяет выполнять свертку через GEMM и использовать общие оптимизированные пути исполнения для сверточных и полносвязных слоев.

Сверточный слой принимает число входных и выходных каналов, размер ядра, шаг, отступы, дилатацию, число групп и признак использования смещения. На основании этих параметров вычисляется размер выходной карты признаков. Преобразование im2col делает вычисление свертки совместимым с общим механизмом матричного умножения, поэтому оптимизация GEMM одновременно улучшает работу полносвязных и сверточных слоев.

3.4.3. Квантованные представления

Механизм квантования предназначен для уменьшения потребления памяти и повышения скорости вычислений при контролируемой потере точности относительно вещественной реализации.

Поддержка целочисленных типов данных важна для экспериментального сравнения вещественного и квантованного исполнения. Квантованные представления позволяют уменьшить размер весов и промежуточных активаций, но требуют контроля масштабирующих коэффициентов и проверки итоговой точности.

3.4.4. Модуль тестирования и бенчмаркинга

Модуль тестирования и бенчмаркинга предназначен для верификации корректности вычислений и количественной оценки производительности. Бенчмарки фиксируют параметры эксперимента, время выполнения операций и режим исполнения: CPU Conv2d, NEON im2col или AMX Conv2d. График сравнения производительности приведен в приложении 3.

Интеграционные тесты LeNet загружают изображения, приводят их к размеру 28 на 28 пикселей, нормализуют значения яркости и формируют входной тензор с одной компонентой канала. После загрузки весов модель выполняет последовательность Conv2D, ReLU, AvgPool2D, Flatten и Linear-слоев. Полученный выходной вектор обрабатывается Softmax, после чего выбирается класс с максимальной вероятностью. Тестовый набор содержит изображения цифр от 0 до 9 и позволяет проверить не только отдельные операции, но и весь путь данных от файла изображения до итогового класса.

Бенчмарк LeNet формирует входные тензоры размера 28 на 28 для нескольких размеров пакета и выполняет полный прямой проход сети. В режиме NEON im2col свертка сводится к матричному умножению в NEON-бэкенде. В режиме CPU Conv2d используется базовая реализация сверточного слоя. В режиме AMX Conv2d используется тот же интерфейс сверточного слоя, но для AMX-бэкенда. Такой набор измерений позволяет сравнивать не отдельную операцию, а полный путь инференса.

3.5. Обоснование выбора метода организации входных и выходных данных

Веса моделей хранятся в JSON-файлах, что упрощает перенос параметров из PyTorch и отладку структуры сети. Входные изображения преобразуются в тензоры, совместимые с выбранным форматом данных и режимом исполнения. Выходные данные представляют собой тензор вероятно-

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 81 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата 2

стей классов после Softmax, который используется для ²терпретации результата классификации и сравнения корректности вычислений.

Внутреннее представление данных основано на плоском массиве и метаданных тензора. Форма задает логическую размерность данных, шаги определяют способ перехода между элементами по каждой оси, а смещение позволяет создавать представления на часть исходного буфера. Такая организация уменьшает количество лишних копирований при передаче данных между слоями и облегчает реализацию операций slice, transpose и contiguous.

Выходные данные бенчмарков и тестов используются в двух целях. Во-первых, они подтверждают функциональную корректность: тесты LeNet должны выдавать ожидаемые классы для подготовленных изображений. Во-вторых, они формируют основу для оценки производительности: результаты замеров используются для построения графика времени выполнения CPU Conv2d, NEON im2col и AMX Conv2d, приведенного в ¹приложении 3.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 81 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата ¹

4. ОЖИДАЕМЫЕ ТЕХНИКО-ЭКОНОМИЧЕСКИЕ ПОКАЗАТЕЛИ

4.1. Ориентировочная экономическая эффективность

Экономическая эффективность разработки **1** заключается в снижении вычислительных затрат при локальном выполнении CNN-моделей на устройствах Apple Silicon. Использование AMX/Accelerate, CPU/NEON-резервирования, im2col и квантованных представлений позволяет уменьшить задержку инференса, сократить энергопотребление и снизить требования к объему памяти.

Ожидаемый эффект включает:

- повышение пропускной способности при обработке изображений;
- снижение времени активной работы процессора при выполнении тяжелых операций;
- возможность запуска более компактных квантованных моделей;
- сокращение времени интеграции за счет единого C++ API.

Дополнительный эффект связан с переносом вычислений с удаленной инфраструктуры на пользовательское устройство. При локальном инференсе снижаются расходы на серверные вычисления и сетевую передачу данных, уменьшается задержка ответа приложения и повышается устойчивость работы в условиях нестабильного соединения. Для приложений компьютерного зрения это особенно важно, поскольку обработка изображений часто выполняется в интерактивном режиме и требует воспроизводимого времени отклика.

Наличие CPU/NEON-эталона снижает стоимость сопровождения программы. Разработчик получает возможность проверять корректность ускоренного режима без привлечения внешних фреймворков и без отдельной эталонной реализации. Модульная структура также уменьшает стоимость расширения: новые слои или дополнительные бэкэнды могут добавляться без переписывания всей цепочки инференса.

4.2. Предполагаемая потребность

Разработка востребована разработчиками iOS/macOS-приложений, инженерами по машинному обучению и исследователями edge-вычислений, которым необходим локальный инференс без сетевой задержки и без передачи данных на сервер. Типовые области применения: компьютерное зрение, AR, мобильная аналитика и автономная обработка изображений.

Практическая потребность в такой библиотеке возникает при создании приложений, где высокоуровневые фреймворки оказываются избыточными или не позволяют явно контролировать путь исполнения отдельных операций. Разрабатываемая программа предоставляет более узкую, но проверяемую основу для экспериментов с AMX/Accelerate, CPU/NEON и квантованными представлениями **данных. 1**

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 81 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата 20

ПРИЛОЖЕНИЕ 1. СПИСОК ИСПОЛЬЗУЕМОЙ ЛИТЕРАТУРЫ

1. ГОСТ 19.101-77: Виды программ и программных документов. // Единая система программной документации. – М.: ИПК Издательство стандартов, 2001.
2. ГОСТ 19.102-77: Стадии разработки. // Единая система программной документации. – М.: ИПК Издательство стандартов, 2001.
3. ГОСТ 19.103-77: Обозначения программ и программных документов. // Единая система программной документации. – М.: ИПК Издательство стандартов, 2001.
4. ГОСТ 19.104-78: Основные надписи. // Единая система программной документации. – М.: ИПК Издательство стандартов, 2001.
5. ГОСТ 19.105-78: Общие требования к программным документам. // Единая система программной документации. – М.: ИПК Издательство стандартов, 2001.
6. 20 СТ 19.106-78: Требования к программным документам, выполненным печатным способом. 58 Единая система программной документации. – М.: ИПК Издательство стандартов, 2001.
7. ГОСТ 19.404-79: Пояснительная записка. Требования к содержанию и оформлению. // Единая система программной документации. – М.: ИПК Издательство стандартов, 2001.
8. Официальная документация Apple Accelerate. Электронный ресурс. URL: <https://developer.apple.com/documentation/accelerate> (дата обращения 11.1.25).
9. Документация C++. Электронный ресурс. URL: <https://cppreference.com/> (дата обращения 22.11.25).

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 81 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата 3

ПРИЛОЖЕНИЕ 2. ТЕРМИНОЛОГИЯ

Термин	Определение 3
Инференс	Прямой проход нейронной сети по входным данным с получением результата без дообучения модели.
Сверточная нейронная сеть	Архитектура нейронной сети, применяющая операции свертки для выделения признаков из данных с пространственной структурой.
Тензор	Многомерный массив числовых данных, используемый для хранения входов, весов, активаций и результатов.
Backend	Низкоуровневый путь исполнения вычислительной операции, например CPU/NEON или AMX/Accelerate.
CPU/NEON-эталон	Базовая реализация на центральном процессоре с использованием векторных инструкций NEON для проверки корректности ускоренных режимов.
Apple Silicon	Семейство систем на кристалле Apple на базе ARM64 с CPU, GPU, ускорителями и объединенной памятью.
AMX	Аппаратный механизм Apple Silicon для ускорения матричных вычислений.
Accelerate	Системный фреймворк Apple с оптимизированными функциями линейной алгебры и обработки сигналов.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 81 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата 1

Термин	Определение 1
GEMM	Обобщенное матричное умножение, используемое в полносвязных слоях и сверточных слоях после im2col.
Conv2D	Двумерная свертка для вычисления карт признаков по входному изображению и набору фильтров.
im2col	Преобразование областей входного изображения в матричное представление для выполнения свертки через GEMM.
Квантование	Представление весов и активаций с меньшей разрядностью для снижения потребления памяти и ускорения вычислений.
LeNet	Тестовая архитектура сверточной нейронной сети, используемая для проверки инференса.
Softmax	Функция активации, преобразующая выходной вектор модели в распределение вероятностей по классам.
Fallback	Резервное переключение вычислений на CPU/NEON при недоступности или ошибке ускоренного пути.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 81 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата 9

ПРИЛОЖЕНИЕ 3. ГРАФИК СРАВНЕНИЯ ПРОИЗВОДИТЕЛЬНОСТИ




Рис. 1. Сравнение времени выполнения CPU Conv2d, NEON im2col и AMX Conv2d

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 81 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата9




Рис. 2. Сравнение времени выполнения матричного умножения CPU/NEON и AMX

Источник данных: результаты выполнения lenet_benchmark.cpp и tensor_mul_benchmark.cpp.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 81 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

ЛИСТ РЕГИСТРАЦИИ ИЗМЕНЕНИЙ

[illegible]