

**ПРАВИТЕЛЬСТВО РОССИЙСКОЙ ФЕДЕРАЦИИ
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ
ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ
"ВЫСШАЯ ШКОЛА ЭКОНОМИКИ"**

Факультет компьютерных наук
Образовательная программа "Программная инженерия"

СОГЛАСОВАНО

Научный руководитель, научный
сотрудник ФИЦ ИУ РАН

_____ Е. Е. Лимонова
«__» _____ 2026 г.

УТВЕРЖДЕНО

Академический руководитель
образовательной программы
"Программная инженерия", старший
преподаватель Департамента
программной инженерии

_____ Н. А. Павлов
«__» _____ 2026 г.

**БЫСТРАЯ РЕАЛИЗАЦИЯ ВЕЩЕСТВЕННЫХ И КВАНТОВАННЫХ
СВЕРТОЧНЫХ НЕЙРОННЫХ СЕТЕЙ НА МОБИЛЬНЫХ УСТРОЙСТВАХ
APPLE**

Программа и методика испытаний

ЛИСТ УТВЕРЖДЕНИЯ

RU.17701729.04.06 51 01-1-ЛУ

Исполнители:

Студент группы БПИ241

_____ / А. Д. Ергучев /

«__» _____ 2026 г.

Подп. и дата	
Инв.№ дубл.	
Взам. инв.№	
Подп. и дата	
Инв.№ подл.	

УТВЕРЖДЕН

RU.17701729.04.06 51 01-1-ЛЮ

**БЫСТРАЯ РЕАЛИЗАЦИЯ ВЕЩЕСТВЕННЫХ И КВАНТОВАННЫХ
СВЕРТОЧНЫХ НЕЙРОННЫХ СЕТЕЙ НА МОБИЛЬНЫХ УСТРОЙСТВАХ
APPLE**

Программа и методика испытаний

RU.17701729.04.06 51 01-1

Листов 14

Инов.№ подп	Подп. и дата	Взам. инв.№	Инов.№ дубл.	Подп. и дата

АННОТАЦИЯ

Программа и методика испытаний — это документ, в котором содержится информация о программном продукте, а также полное описание приемочных испытаний для данного программного продукта.

Настоящая Программа и методика испытаний для «Быстрая реализация вещественных и квантованных сверточных нейронных сетей на мобильных устройствах Apple» содержит следующие разделы: «Объект испытаний», «Цель испытаний», «Требования к программе», «Требования к программной документации», «Средства и порядок испытаний», «Методы испытаний», «Приложения».

В разделе «Объект испытаний» указано наименование, краткая характеристика и назначение программы.

В разделе «Цель испытаний» указана цель проведения испытаний. Раздел «Требования к программе» содержит основные требования к программе, которые подлежат проверке во время испытаний (требования к функционалу и интерфейсу).

Раздел «Требования к программным документам» содержит состав программной документации, которая представляется на испытания.

Раздел «Средства и порядок испытаний» содержит информацию о технических и программных средствах, которые следует использовать во время испытаний, а также порядок этих испытаний.

Раздел «Методы испытаний» содержит информацию об используемых методах испытаний.

Настоящий документ разработан в соответствии с требованиями:

1. ГОСТ 19.101-77 [1]: Виды программ и программных документов.
2. ГОСТ 19.102-77 [2]: Стадии разработки.
3. ГОСТ 19.103-77 [3]: Обозначения программ и программных документов.
4. ГОСТ 19.104-78 [4]: Основные надписи.
5. ГОСТ 19.105-78 [5]: Общие требования к программным документам.
6. ГОСТ 19.106-78 [6]: Требования к программным документам, выполненным печатным способом.
7. ГОСТ 19.301-79 [7]: Программа и методика испытаний. Требования к содержанию и оформлению.

Изменения к данной Программе и методике испытаний оформляются согласно ГОСТ 19.603-78 [8], ГОСТ 19.604-78 [9].

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 51 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

СОДЕРЖАНИЕ

1. ОБЪЕКТ ИСПЫТАНИЙ	4
1.1. Наименование программы	4
1.2. Краткая характеристика области применения программы	4
2. ЦЕЛЬ ИСПЫТАНИЙ	5
3. ТРЕБОВАНИЯ К ПРОГРАММЕ	6
3.1. Требования к функциональным характеристикам	6
3.1.1. Состав выполняемых функций	6
3.2. Требования к входным и выходным данным	6
3.2.1. Организация входных данных	6
3.2.2. Организация выходных данных	7
3.3. Требования к интерфейсу	7
4. ТРЕБОВАНИЯ К ПРОГРАММНОЙ ДОКУМЕНТАЦИИ	8
5. СРЕДСТВА И ПОРЯДОК ИСПЫТАНИЙ	9
5.1. Технические средства	9
5.2. Программные средства	9
5.3. Порядок проведения испытаний	9
5.4. Требования к персоналу	10
6. МЕТОДЫ ИСПЫТАНИЙ	11
6.1. Проверка требований к технической документации	11
6.2. Проверка требований к интерфейсу	11
6.3. Проверка требований к функциональным характеристикам	11
6.3.1. Проверка корректности матричного умножения (CPU vs AMX)	11
6.3.2. Проверка обработки ошибок размерностей	12
6.3.3. Проверка работы сквозного вывода (Inference) на модели LeNet	12
6.3.4. Сравнение производительности путей исполнения	12
СПИСОК ИСПОЛЪЗУЕМОЙ ЛИТЕРАТУРЫ	13

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 51 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

1. ОБЪЕКТ ИСПЫТАНИЙ

1.1. Наименование программы

Наименование программы: «Быстрая реализация вещественных и квантованных сверточных нейронных сетей на мобильных устройствах Apple».

Наименование программы на английском языке: «Fast Implementation of Floating-Point and Quantized Convolutional Neural Networks on Apple Mobile Devices».

1.2. Краткая характеристика области применения программы

Программный проект по созданию высокопроизводительной реализации сверточных нейронных сетей на устройствах Apple Silicon. В рамках работы сравниваются CPU- и АМХ-исполнения, поддерживаются вещественные и квантованные представления различной разрядности, а целевой архитектурой выступает VGG-уровень для задач компьютерного зрения.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 51 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

2. ЦЕЛЬ ИСПЫТАНИЙ

Целью испытаний является проверка корректности выполнения программой функций, изложенных в п. 4 «Требования к программе» документа «Техническое задание» из комплекта документации в соответствии с ЕСПД (Единой системой программной документации).

В рамках проведения испытаний особое внимание уделяется проверке следующих критических свойств программного обеспечения:

- **Корректность численных вычислений:** проверка того, что результаты матричного умножения, реализованного через AMX/Accelerate-путь, совпадают с результатами эталонного CPU-исполнения в пределах допустимой численной погрешности.
- **Стабильность работы API:** подтверждение корректности создания тензоров, управления их формами (shape) и доступа к данным через единый C++ интерфейс.
- **Отказоустойчивость и диагностика:** проверка способности системы выявлять несовместимость размерностей операндов при выполнении матричных операций и выдавать соответствующие диагностические ошибки.
- **Целостность путей исполнения:** проверка корректного переключения между ускоренным (AMX/Accelerate) и резервным (CPU) режимами вычислений без изменения интерфейса вызывающего слоя.
- **Производительность:** оценка эффективности реализации сверточных слоев и матричных операций на целевой архитектуре Apple Silicon.

Результаты испытаний служат основанием для подтверждения соответствия реализованного API требованиям к функциональности тензорного ядра и определяют готовность библиотеки к интеграции в общую структуру сверточных нейронных сетей.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 51 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

3. ТРЕБОВАНИЯ К ПРОГРАММЕ

3.1. Требования к функциональным характеристикам

3.1.1. Состав выполняемых функций

Программа должна соответствовать следующим функциональным требованиям, указанным в документе «Быстрая реализация вещественных и квантованных сверточных нейронных сетей на мобильных устройствах Apple. Техническое задание»

В ходе испытаний подлежат проверке следующие группы функций:

1. Управление тензорными структурами
 - Создание тензоров с заданным описанием формы (shape) и типа данных.
 - Обеспечение корректного доступа к данным тензора.
 - Проверка совместимости размерностей при выполнении операций и генерация диагностических ошибок при их несоответствии.
2. Выполнение матричных операций
 - Реализация эталонного пути вычислений на CPU (матричное умножение).
 - Реализация ускоренного пути вычислений с использованием AMX/Accelerate.
 - Обеспечение прозрачного переключения между путями исполнения без изменения пользовательского интерфейса слоя.
 - Автоматическое резервирование (fallback) на CPU-исполнение при невозможности использования AMX.
3. Реализация слоев нейронной сети
 - Выполнение сверточных операций (Conv2D) с использованием различных бэкендов (AMX, Greedy).
 - Реализация линейных слоев (Linear) и функций активации (ReLU, Softmax).
 - Реализация операций пулинга (AvgPool2D) и преобразования размерностей (Flatten).
 - Сборка компонентов в архитектуру уровня VGG (на примере LeNet).
4. Верификация и тестирование
 - Сравнение результатов вычислений AMX/Accelerate с эталонными данными CPU в пределах допустимой численной погрешности.
 - Проверка корректности инференса на тестовых наборах данных (например, MNIST).

3.2. Требования к входным и выходным данным

3.2.1. Организация входных данных

Входные данные программы представляют собой структуры данных и конфигурационные файлы, необходимые для инициализации и работы нейронной сети:

1. Параметры тензоров:
 - Описание формы (размерности) тензора.
 - Тип данных (вещественные представления, поддерживаемые в проекте).
 - Режим вычислений (выбор бэкенда).
2. Веса нейронной сети:

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 51 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

- Конфигурационные файлы в формате JSON (например, `mnist_lenet.json`), содержащие веса и смещения слоев.
3. Входные данные для инференса:
- Изображения в поддерживаемых форматах (например, `.jpg`), которые преобразуются в тензоры для подачи на вход сети.

3.2.2. Организация выходных данных

Выходные данные программы включают результаты вычислений и диагностическую информацию:

1. Результаты инференса:
 - Выходной тензор после прохождения всех слоев сети, представляющий собой распределение вероятностей по классам.
2. Результаты верификации:
 - Значения численной погрешности при сравнении CPU- и AMX-реализаций.
 - Отчеты модульных тестов о корректности выполнения операций матричного умножения.
3. Диагностические сообщения:
 - Ошибки совместимости размерностей матриц.
 - Уведомления о переключении режима исполнения (например, при переходе с AMX на CPU).

3.3. Требования к интерфейсу

Программный продукт представляет собой API-библиотеку (CNN inference API library), в связи с чем требования к интерфейсу касаются программного взаимодействия:

1. Программный интерфейс (C++ API):
 - Единый интерфейс для создания тензоров и доступа к их данным.
 - Унифицированный интерфейс выполнения матричного умножения, скрывающий детали реализации конкретного бэкенда (AMX/Accelerate/CPU).
 - Интерфейс описания слоев нейронной сети, позволяющий конструировать модель из базовых блоков.
2. Взаимодействие с внешними данными:
 - Механизм десериализации весов из JSON-файлов в структуры тензоров.
 - Инструменты визуализации (тензорный принтер) для отладочного вывода содержимого тензоров.
3. Инструментарий тестирования:
 - Наличие бенчмарков (например, `lenet_benchmark.cpp`) для измерения производительности различных путей исполнения.

TODO: вставить скриншот или таблицу с примером структуры C++ API для создания тензора и вызова операции `matmul`

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 51 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

4. ТРЕБОВАНИЯ К ПРОГРАММНОЙ ДОКУМЕНТАЦИИ

На испытание должна быть представлена документация в следующем составе:

1. «Быстрая реализация вещественных и квантованных сверточных нейронных сетей на мобильных устройствах Apple». Техническое задание (ГОСТ 19.201-78 [7]).
2. «Быстрая реализация вещественных и квантованных сверточных нейронных сетей на мобильных устройствах Apple». Пояснительная записка (ГОСТ 19.404-79 [10]).
3. «Быстрая реализация вещественных и квантованных сверточных нейронных сетей на мобильных устройствах Apple». Программа и методика испытаний (ГОСТ 19.301-79 [8]).
4. «Быстрая реализация вещественных и квантованных сверточных нейронных сетей на мобильных устройствах Apple». Текст программы (ГОСТ 19.401-78 [9]).
5. «Быстрая реализация вещественных и квантованных сверточных нейронных сетей на мобильных устройствах Apple». Руководство оператора (ГОСТ 19.505-79 [11]).

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 51 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

5. СРЕДСТВА И ПОРЯДОК ИСПЫТАНИЙ

5.1. Технические средства

Для проведения испытаний и обеспечения корректной работы библиотеки высокопроизводительного вывода нейронных сетей требуются следующие технические средства:

1. Мобильное устройство или эмулятор на базе архитектуры Apple Silicon (процессоры серии М или А), поддерживающее инструкции AMX (Apple Matrix Extensions).
2. Объем оперативной памяти, достаточный для размещения весов модели (например, LeNet) и промежуточных тензоров активации.
3. Среда разработки Apple Mac с установленным инструментарием для сборки C++ проектов.

5.2. Программные средства

В процессе проведения испытаний используются следующие программные средства:

1. Операционная система macOS (актуальная версия, поддерживающая Xcode).
2. Среда разработки Xcode (последняя стабильная версия) с компилятором Clang.
3. Фреймворк Accelerate для доступа к низкоуровневым оптимизациям матричных вычислений.
4. Интерпретатор Python (для использования скрипта `pt2json.py` при подготовке весов моделей из формата PyTorch в JSON).
5. Набор тестовых данных:
 - Файл с весами модели в формате JSON (`mnist_lenet.json`).
 - Набор тестовых изображений в формате JPG для проверки корректности инференса.

5.3. Порядок проведения испытаний

Испытания программного обеспечения проводятся в следующей последовательности:

1. Подготовка среды и данных:
 - Конвертация весов предобученной модели из формата PyTorch в формат JSON с помощью скрипта `pt2json.py`.
 - Размещение тестовых изображений в директории `inputs_test/`.
 - Компиляция проекта с использованием Xcode с включением оптимизаций для целевой архитектуры.
2. Проверка корректности вычислений (функциональное тестирование):
 - Запуск модульных тестов (`lenet_test.cpp`) для проверки базовых операций линейной алгебры.
 - Сравнение результатов выполнения матричного умножения на эталонном CPU-пути и на ускоренном AMX/Accelerate-пути.
 - Верификация соблюдения заданной численной погрешности при сравнении результатов разных путей исполнения.
 - Проверка обработки ошибок при несовместимости размерностей тензоров.
3. Тестирование производительности (бенчмаркинг):
 - Запуск специализированных тестов производительности (`lenet_benchmark.cpp`).
 - Измерение времени выполнения прямого прохода (inference) нейронной сети.
 - Сравнение скорости работы CPU-исполнения и AMX-исполнения.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 51 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

- TODO: вставить скрин графиков сравнения производительности.

4. Валидация итогового вывода:

- Прогон тестового набора изображений через реализованную архитектуру LeNet.
- Сопоставление полученных классов с эталонными метками.

5.4. Требования к персоналу

Испытания должны проводиться специалистом, обладающим следующей квалификацией:

1. Знание языка программирования C++ и принципов работы с тензорными структурами данных.
2. Навыки работы со средой разработки Xcode и инструментами отладки в экосистеме Apple.
3. Понимание основ работы сверточных нейронных сетей (CNN) и операций матричного умножения.
4. Умение работать с командной строкой macOS и запускать Python-скрипты для подготовки данных.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 51 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

6. МЕТОДЫ ИСПЫТАНИЙ

6.1. Проверка требований к технической документации

Проверка осуществляется путем визуального анализа состава и содержания представленного комплекта документов на соответствие стандартам ЕСПД и требованиям технического задания. В ходе проверки подтверждается наличие следующих документов:

- Техническое задание: проверка полноты описания целей, задач и функциональных требований к реализации тензорного ядра и АМХ-исполнения.
- Пояснительная записка: проверка наличия описания архитектуры тензоров, алгоритмов матричного умножения и обоснования выбора путей исполнения (CPU/АМХ).
- Программа и методика испытаний: проверка наличия описанных сценариев тестирования корректности вычислений и замера производительности.
- Текст программы: проверка наличия исходного кода всех модулей (core, nn, backend) и заголовочных файлов.
- Руководство оператора: проверка инструкций по сборке библиотеки, интеграции API и запуску эталонных тестов.

6.2. Проверка требований к интерфейсу

Поскольку разрабатываемый продукт представляет собой библиотеку (CNN inference API library), проверка интерфейса заключается в анализе C++ API на соответствие требованиям к доступности и удобству использования. Проверяются следующие аспекты:

- Интерфейс создания тензоров: проверка корректности работы функций создания тензоров с заданной формой (shape), типом данных (dtype) и режимом вычислений.
- Интерфейс доступа к данным: проверка методов чтения и записи данных в тензор, а также работы итераторов.
- Интерфейс выполнения операций: проверка единообразия вызовов для матричного умножения и сверточных слоев независимо от выбранного бэкенда (CPU или АМХ).
- Диагностический интерфейс: проверка вывода информативных сообщений об ошибках при несовместимости размерностей матриц или недоступности аппаратного ускорения.

6.3. Проверка требований к функциональным характеристикам

Функциональные характеристики проверяются путем выполнения серии тестов, включающих как модульное тестирование отдельных операций, так и сквозное тестирование на архитектуре LeNet.

6.3.1. Проверка корректности матричного умножения (CPU vs АМХ)

Исходные данные: Два тензора (матрицы) случайных размерностей, совместимых для умножения, с вещественными значениями. **Действия:**

1. Выполнить умножение матриц с использованием эталонного CPU-пути.
2. Выполнить умножение тех же матриц с использованием АМХ/Accelerate-пути.
3. Вычислить разность между результатами двух вычислений.

Ожидаемый результат: Результаты вычислений на CPU и АМХ должны совпадать с точностью до заданной численной погрешности. **Критерий успешности:** Максимальная абсолютная разность

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 51 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

между соответствующими элементами результирующих тензоров не превышает допустимый порог (epsilon).

6.3.2. Проверка обработки ошибок размерностей

Исходные данные: Два тензора, размерности которых делают операцию матричного умножения математически невозможной (например, количество столбцов первой матрицы не равно количеству строк второй). **Действия:** Вызвать функцию матричного умножения для данных тензоров. **Ожидаемый результат:** Программа не должна аварийно завершаться (crash); API должен вернуть диагностическую ошибку или выбросить исключение, указывающее на несовместимость форм. **Критерий успешности:** Фиксация корректного сообщения об ошибке размерности.

6.3.3. Проверка работы сквозного вывода (Inference) на модели LeNet

Исходные данные: Веса предобученной сети LeNet (файл mnist_lenet.json) и тестовые изображения из набора inputs_test. **Действия:**

1. Загрузить веса модели в структуры тензоров.
2. Прогнать тестовые изображения через всю цепочку слоев (Conv2D to ReLU to AvgPool2D to Flatten to Linear to Softmax).
3. Сравнить полученный класс с истинной меткой изображения.

Ожидаемый результат: Модель корректно классифицирует изображения, возвращая индекс наиболее вероятного класса. **Критерий успешности:** Совпадение предсказанного класса с эталонным для большинства тестовых примеров.

6.3.4. Сравнение производительности путей исполнения

Исходные данные: Набор матриц больших размерностей, типичных для сверточных слоев VGG-уровня. **Действия:**

1. Замерить время выполнения операции умножения на CPU-эталоне.
2. Замерить время выполнения той же операции на AMX/Accelerate-бэкенде.
3. Построить сравнительный график.

Ожидаемый результат: Время выполнения на AMX/Accelerate-пути должно быть существенно ниже, чем на CPU-пути. **Критерий успешности:** Подтвержденный прирост производительности при использовании аппаратного ускорения Apple Silicon.

TODO: вставить скрин или график сравнения производительности CPU и AMX.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 51 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

СПИСОК ИСПОЛЬЗУЕМОЙ ЛИТЕРАТУРЫ

1. ГОСТ 19.101-77: Виды программ и программных документов. // Единая система программной документации. – М.: ИПК Издательство стандартов, 2001.
2. ГОСТ 19.102-77: Стадии разработки. // Единая система программной документации. – М.: ИПК Издательство стандартов, 2001.
3. ГОСТ 19.103-77: Обозначения программ и программных документов. // Единая система программной документации. – М.: ИПК Издательство стандартов, 2001.
4. ГОСТ 19.104-78: Основные надписи. // Единая система программной документации. – М.: ИПК Издательство стандартов, 2001.
5. ГОСТ 19.105-78: Общие требования к программным документам. // Единая система программной документации. – М.: ИПК Издательство стандартов, 2001.
6. ГОСТ 19.106-78: Требования к программным документам, выполненным печатным способом. // Единая система программной документации. – М.: ИПК Издательство стандартов, 2001.
7. ГОСТ 19.201-78: Техническое задание. Требования к содержанию и оформлению. // Единая система программной документации. – М.: ИПК Издательство стандартов, 2001.
8. ГОСТ 19.301-79: Программа и методика испытаний. Требования к содержанию и оформлению. // Единая система программной документации. – М.: ИПК Издательство стандартов, 2001.
9. ГОСТ 19.401-78: Текст программы. Требования к содержанию и оформлению. // Единая система программной документации. – М.: ИПК Издательство стандартов, 2001.
10. ГОСТ 19.404-79: Пояснительная записка. Требования к содержанию и оформлению. // Единая система программной документации. – М.: ИПК Издательство стандартов, 2001.
11. ГОСТ 19.505-79: Руководство оператора. Требования к содержанию и оформлению. // Единая система программной документации. – М.: ИПК Издательство стандартов, 2001.
12. ГОСТ 19.603-78: Общие правила внесения изменений. // Единая система программной документации. – М.: ИПК Издательство стандартов, 2001.
13. ГОСТ 19.604-78: Правила внесения изменений в программные документы, выполненные печатным способом. // Единая система программной документации. – М.: ИПК Издательство стандартов, 2001.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 51 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

ЛИСТ РЕГИСТРАЦИИ ИЗМЕНЕНИЙ

[illegible]