

**ПРАВИТЕЛЬСТВО РОССИЙСКОЙ ФЕДЕРАЦИИ
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ
ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ
"ВЫСШАЯ ШКОЛА ЭКОНОМИКИ"**

Факультет компьютерных наук
Образовательная программа "Программная инженерия"

СОГЛАСОВАНО

Научный руководитель, научный
сотрудник ФИЦ ИУ РАН

_____ Е. Е. Лимонова
«__» _____ 2026 г.

УТВЕРЖДЕНО

Академический руководитель
образовательной программы
"Программная инженерия", старший
преподаватель Департамента
программной инженерии

_____ Н. А. Павлочев
«__» _____ 2026 г.

**БЫСТРАЯ РЕАЛИЗАЦИЯ ВЕЩЕСТВЕННЫХ И КВАНТОВАННЫХ
СВЕРТОЧНЫХ НЕЙРОННЫХ СЕТЕЙ НА МОБИЛЬНЫХ УСТРОЙСТВАХ
APPLE**

Руководство оператора

ЛИСТ УТВЕРЖДЕНИЯ

RU.17701729.04.06 34 01-1-ЛУ

Исполнители:

Студент группы БПИ241

_____ / А. Д. Ергучев /
«__» _____ 2026 г.

Подп. и дата	
Инв.№ дубл.	
Взам. инв.№	
Подп. и дата	
Инв.№ подл	

УТВЕРЖДЕН

RU.17701729.04.06 34 01-1-ЛЮ

**БЫСТРАЯ РЕАЛИЗАЦИЯ ВЕЩЕСТВЕННЫХ И КВАНТОВАННЫХ
СВЕРТОЧНЫХ НЕЙРОННЫХ СЕТЕЙ НА МОБИЛЬНЫХ УСТРОЙСТВАХ
APPLE**

Руководство оператора

RU.17701729.04.06 34 01-1

Листов 10

Инов.№ подп	Подп. и дата	Взам. инв.№	Инов.№ дубл.	Подп. и дата

АННОТАЦИЯ

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 34 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

СОДЕРЖАНИЕ

1. НАЗНАЧЕНИЕ ПРОГРАММЫ	4
1.1. Функциональное назначение	4
1.2. Эксплуатационное назначение	4
2. УСЛОВИЯ ВЫПОЛНЕНИЯ ПРОГРАММЫ	5
2.1. Минимальный состав аппаратных средств	5
2.2. Минимальный состав программных средств	5
2.3. Требования к персоналу (пользователю)	5
3. Выполнение программы	6
3.1. Установка программы	6
3.2. Запуск программы и работа с приложением	6
3.2.1. Выполнение эталонного и ускоренного матричного умножения	6
3.2.2. Запуск инференса сети LeNet	7
3.2.3. Проведение сравнительного анализа производительности (Benchmark)	7
СООБЩЕНИЯ ОПЕРАТОРУ	8
Тексты сообщений оператору	8
Ошибки инициализации и конфигурации	8
Системные уведомления о режиме исполнения	8
Диагностика корректности (Тестовый режим)	8
Действия оператора в исключительных ситуациях	8
Несовместимость размерностей тензоров	8
Некорректные результаты вычислений	9
Сбои при работе с аппаратным ускорением	9

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 34 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

1. НАЗНАЧЕНИЕ ПРОГРАММЫ

1.1. Функциональное назначение

Программа «Быстрая реализация вещественных и квантованных сверточных нейронных сетей на мобильных устройствах Apple» предназначена для выполнения пользовательских сценариев, описанных в техническом задании.

Основным функциональным назначением программы является предоставление низкоуровневого C++ API для высокопроизводительного выполнения прямого прохода (inference) сверточных нейронных сетей на устройствах с архитектурой Apple Silicon. Программа обеспечивает возможность реализации архитектур уровня VGG для задач компьютерного зрения.

В рамках функционального назначения программа реализует следующие возможности:

- создание и управление тензорами (определение формы, типа данных и режима вычислений);
- выполнение базовых операций линейной алгебры, включая матричное умножение (GEMM), которое является ядром сверточных слоев;
- поддержка различных путей исполнения: использование аппаратного ускорителя AMX (Apple Matrix Coprocessor) через фреймворк Accelerate для максимальной производительности и CPU-исполнения в качестве эталона или резервного варианта;
- реализация стандартных слоев нейронной сети: сверточных слоев (Conv2D), полносвязных слоев (Linear), функций активации (ReLU, Softmax), а также операций пулинга (AvgPool2D) и выравнивания данных (Flatten);
- поддержка вещественных и квантованных представлений данных различной разрядности для оптимизации памяти и скорости вычислений;
- верификация корректности вычислений путем сравнения результатов ускоренного AMX-пути с эталонным CPU-исполнением в пределах заданной численной погрешности.

1.2. Эксплуатационное назначение

Программный проект по созданию высокопроизводительной реализации сверточных нейронных сетей на устройствах Apple Silicon. В рамках работы сравниваются CPU- и AMX-исполнения, поддерживаются вещественные и квантованные представления различной разрядности, а целевой архитектурой выступает VGG-уровень для задач компьютерного зрения.

Программный продукт представляет собой библиотеку (API library), предназначенную для интеграции в мобильные приложения на базе iOS или macOS, где требуется локальный запуск нейронных сетей с минимальными задержками и эффективным использованием энергопотребления.

Эксплуатация программы предполагает использование её в качестве бэкенда для задач компьютерного зрения, где критически важна скорость обработки кадров. Программа позволяет разработчику переключаться между различными режимами исполнения (AMX/CPU) без изменения пользовательского интерфейса слоев нейронной сети, что обеспечивает гибкость при развертывании на устройствах с разной конфигурацией Apple Silicon.

Для проверки производительности и корректности работы в процессе эксплуатации предусмотрены инструменты бенчмаркинга и модульные тесты, позволяющие анализировать скорость выполнения операций на конкретном устройстве.

TODO: вставить скрин графиков сравнения производительности CPU и AMX исполнений

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 34 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

2. УСЛОВИЯ ВЫПОЛНЕНИЯ ПРОГРАММЫ

2.1. Минимальный состав аппаратных средств

Для обеспечения корректного функционирования библиотеки и достижения заявленной производительности при инференсе нейронных сетей требуются следующие аппаратные средства:

1. Мобильное устройство на базе архитектуры Apple Silicon (чипы серии A или M);
2. Наличие аппаратного модуля AMX (Apple Matrix Coprocessor) для использования ускоренного пути вычислений матричного умножения;
3. Объем оперативной памяти, достаточный для размещения весов модели и промежуточных тензоров (зависит от размера конкретной сети, например, для архитектуры LeNet достаточно минимального объема ОЗУ современных устройств Apple);
4. Свободное место на внутреннем накопителе для хранения файлов с весами нейронной сети в формате JSON или ином поддерживаемом формате сериализации.

2.2. Минимальный состав программных средств

Для сборки, запуска и эксплуатации программы необходимо наличие следующих программных средств:

1. Операционная система: iOS или macOS (актуальные версии, поддерживающие доступ к Accelerate framework);
2. Среда разработки и компиляции: Xcode (включая компилятор Clang с поддержкой стандартов C++17 или выше);
3. Системные библиотеки: Apple Accelerate Framework для реализации высокопроизводительных матричных операций;
4. Инструментарий для подготовки данных: интерпретатор Python (для работы скрипта `pt2json.py` при конвертации весов из PyTorch в формат, совместимый с библиотекой).

2.3. Требования к персоналу (пользователю)

Пользователем данной программы является разработчик программного обеспечения или инженер по машинному обучению, интегрирующий функционал инференса CNN в конечное приложение. К пользователю предъявляются следующие требования:

1. Знание языка программирования C++ на уровне, достаточном для работы с API библиотеки (создание тензоров, управление памятью, вызов функций слоев);
2. Понимание базовых принципов работы сверточных нейронных сетей (понятия тензора, размерности слоев, свертки, пулинга и функций активации);
3. Навыки работы с инструментами сборки проектов в среде Xcode;
4. Умение работать с консолью для запуска бенчмарков и анализа результатов производительности.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 34 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

3. Выполнение программы

3.1. Установка программы

Для установки и развертывания библиотеки `project-name` необходимо подготовить среду разработки на устройстве с архитектурой Apple Silicon (М-серия). Проект представляет собой C++ API библиотеку, поэтому установка осуществляется путем сборки исходного кода.

Требования к окружению:

- Операционная система: macOS с установленным Xcode.
- Компилятор: Clang (поставляется с Xcode), поддерживающий стандарт C++17 или выше.
- Зависимости: Apple Accelerate Framework для использования функций матричных вычислений и AMX-оптимизаций.
- Дополнительные инструменты: Python 3 (для работы скрипта `pt2json.py`, осуществляющего конвертацию весов нейронной сети из формата PyTorch в JSON).

Порядок установки:

1. Клонирование репозитория проекта на локальный диск устройства.
2. Настройка путей к заголовочным файлам в директории `include`.
3. Сборка проекта с помощью системы сборки (например, CMake или через Xcode Project), обеспечив линковку с фреймворком Accelerate.
4. Подготовка весов модели: использование скрипта `scripts/pt2json.py` для перевода предобученных весов в формат `.json`, совместимый с модулем `fastinf/core/serialization.hpp`.

3.2. Запуск программы и работа с приложением

Поскольку проект реализован в виде библиотеки API, взаимодействие с ним осуществляется через написание C++ кода, использующего предоставленные интерфейсы, либо через запуск готовых тестовых и бенчмарк-приложений. Основной функционал доступен через заголовочные файлы `fastinf/core.hpp` и `fastinf/nn.hpp`.

3.2.1. Выполнение эталонного и ускоренного матричного умножения

Данный сценарий используется для проверки корректности работы тензорного ядра и сравнения CPU-реализации (эталон) с AMX/Accelerate-исполнением.

Действия оператора:

1. Создание двух тензоров через `fastinf::Tensor` с указанием размерностей, совместимых для матричного умножения.
2. Вызов функции умножения матриц через общий интерфейс `fastinf::ops::matmul`.
3. Переключение режима исполнения между CPU-путем (эталонным) и AMX/Accelerate-путем.
4. Сравнение полученных результатов.

Реакция программы:

- Программа проверяет совместимость размерностей матриц. При несовместимости выдается диагностическая ошибка.
- В зависимости от выбранного бэкенда, вычисления производятся либо стандартным циклом на CPU, либо через оптимизированные инструкции Apple Silicon.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 34 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

Ожидаемый результат: Результаты AMX/Accelerate-исполнения должны совпадать с результатами CPU-эталона в пределах заданной численной погрешности.

3.2.2. Запуск инференса сети LeNet

Сценарий запуска полноценного прохода нейронной сети для задачи распознавания образов.

Действия оператора:

1. Загрузка весов сети из файла `weights/mnist_lenet.json` с помощью модуля сериализации.
2. Инициализация структуры сети `fastinf::nn::LeNet`.
3. Подача входного изображения (тензора) в сеть.
4. Запуск метода `forward`-прохода.

Реакция программы:

- Программа последовательно выполняет операции свертки (`conv2d`), пулинга (`avg_pool2d`), активации (`relu`) и полносвязных слоев (`linear`).
- Для каждого слоя выбирается оптимальный путь исполнения (AMX или `greedy`-реализация).

Ожидаемый результат: На выходе получается тензор с вероятностями классов (после `softmax`), соответствующий предсказанию сети для данного изображения.

TODO: вставить скрин консольного вывода с результатами распознавания из `lenet_test.cpp`

3.2.3. Проведение сравнительного анализа производительности (Benchmark)

Сценарий измерения скорости работы различных реализаций сверточных слоев.

Действия оператора:

1. Запуск исполняемого файла `lenet_benchmark`.
2. Определение параметров тестирования (размер входных данных, количество итераций).

Реакция программы:

- Программа многократно выполняет один и тот же набор операций, замеряя время исполнения для CPU-ветки и AMX-ветки.
- Рассчитывается среднее время выполнения и пропускная способность.

Ожидаемый результат: Вывод в консоль таблицы со временем выполнения операций, демонстрирующий прирост производительности при использовании AMX по сравнению с CPU.

TODO: вставить скрин или график сравнения производительности CPU vs AMX

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 34 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

СООБЩЕНИЯ ОПЕРАТОРУ

3.2.3 Тексты сообщений оператору

Поскольку программный продукт представляет собой библиотеку API (CNN inference API library), взаимодействие с оператором осуществляется через возвращаемые коды ошибок, исключения C++ и диагностические сообщения в стандартном потоке ошибок (stderr). Ключевые сообщения и типы уведомлений разделены по категориям:

3.2.3 Ошибки инициализации и конфигурации

Данные сообщения выводятся при попытке создания тензоров или инициализации слоев нейронной сети с некорректными параметрами:

- **Несовместимость размерностей (Dimension Mismatch):** Выводится при попытке выполнения матричного умножения или свертки, если формы входных тензоров не соответствуют требованиям операции (например, количество столбцов матрицы A не совпадает с количеством строк матрицы B).
- **Ошибка выделения памяти:** Уведомление о невозможности выделить непрерывный блок памяти под данные тензора в ОЗУ устройства.
- **Некорректный формат весов:** Сообщение об ошибке при десериализации весов из JSON-файла, если структура файла не соответствует ожидаемому описанию формы (shape) или типу данных.

3.2.3 Системные уведомления о режиме исполнения

Библиотека автоматически управляет путями исполнения (backend), уведомляя оператора о переключении режимов:

- **Переход на CPU-резервирование (CPU Fallback):** Сообщение о том, что AMX/Accelerate-исполнение недоступно на данном устройстве или для данной конфигурации данных, и вычисления будут выполнены эталонным CPU-путем.
- **Активация AMX-ускорения:** Уведомление о том, что операция успешно перенаправлена на аппаратный ускоритель Apple Silicon.

3.2.3 Диагностика корректности (Тестовый режим)

При запуске модульных тестов или бенчмарков оператору выводятся следующие данные:

- **Превышение численного порога (Precision Error):** Сообщение о том, что разница между результатом AMX/Accelerate и CPU-эталоном превышает заданную допустимую погрешность.
- **Результаты замера производительности:** Вывод времени выполнения операции для каждого из путей исполнения (CPU vs AMX).

3.2.3 Действия оператора в исключительных ситуациях

В случае возникновения исключительных ситуаций оператору (разработчику, интегрирующему библиотеку) рекомендуется следовать данным инструкциям:

3.2.3 Несовместимость размерностей тензоров

При получении ошибки совместимости размерностей необходимо:

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 34 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

1. Проверить описание формы (tensor description) входных данных и весов слоя.
2. Убедиться, что операция преобразования данных (например, flatten или im2col) была выполнена корректно перед подачей данных в линейный слой или свертку.
3. Сверить параметры архитектуры сети (VGG-уровень) с фактическими размерностями входных изображений.

3.2.3 Некорректные результаты вычислений

Если тесты корректности фиксируют расхождение результатов между CPU и AMX beyond tolerance:

1. Проверить соответствие типов данных (dtype) для всех операндов операции.
2. Убедиться, что используемая разрядность квантования поддерживается текущим бекендом исполнения.
3. Проверить целостность весов, загруженных из внешнего файла.

3.2.3 Сбои при работе с аппаратным ускорением

При возникновении критических ошибок при обращении к AMX/Accelerate:

1. Проверить версию ОС и совместимость целевого устройства Apple Silicon с используемыми фреймворками.
2. Использовать CPU-путь исполнения для локализации проблемы (определение, является ли ошибка алгоритмической или аппаратной).
3. В случае систематического отказа аппаратного ускорения, задокументировать параметры тензоров, вызвавших сбой, и обратиться к разработчику библиотеки.

TODO: вставить скрин/таблицу с кодами ошибок API (если применимо)

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 34 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

ЛИСТ РЕГИСТРАЦИИ ИЗМЕНЕНИЙ

[illegible]