

**ПРАВИТЕЛЬСТВО РОССИЙСКОЙ ФЕДЕРАЦИИ
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ
ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ
"ВЫСШАЯ ШКОЛА ЭКОНОМИКИ"**

Факультет компьютерных наук
Образовательная программа "Программная инженерия"

СОГЛАСОВАНО

Научный руководитель, научный
сотрудник ФИЦ ИУ РАН

_____ Е. Е. Лимонова

«__» _____ 2026 г.

УТВЕРЖДЕНО

Академический руководитель
образовательной программы
"Программная инженерия", старший
преподаватель Департамента
программной инженерии

_____ Н. А. Павлов

«__» _____ 2026 г.

**БЫСТРАЯ РЕАЛИЗАЦИЯ ВЕЩЕСТВЕННЫХ И КВАНТОВАННЫХ
СВЕРТОЧНЫХ НЕЙРОННЫХ СЕТЕЙ НА МОБИЛЬНЫХ УСТРОЙСТВАХ
APPLE**

Пояснительная записка

ЛИСТ УТВЕРЖДЕНИЯ

RU.17701729.04.06 81 01-1-ЛУ

Исполнители:

Студент группы БПИ241

_____ / А. Д. Ергучев /

«__» _____ 2026 г.

Студент группы БПИ241

_____ / Г. А. Суханов /

«__» _____ 2026 г.

Инд.№ подп	Подп. и дата	Взам. инв.№	Инд.№ дубл.	Подп. и дата

УТВЕРЖДЕН

RU.17701729.04.06 81 01-1-ЛУ

**БЫСТРАЯ РЕАЛИЗАЦИЯ ВЕЩЕСТВЕННЫХ И КВАНТОВАННЫХ
СВЕРТОЧНЫХ НЕЙРОННЫХ СЕТЕЙ НА МОБИЛЬНЫХ УСТРОЙСТВАХ
APPLE**

Пояснительная записка

RU.17701729.04.06 81 01-1

Листов 16

Инов.№ подп	Подп. и дата	Взам. инв.№	Инов.№ дубл.	Подп. и дата

АННОТАЦИЯ

Данный программный документ представляет собой пояснительную записку к программному проекту «Быстрая реализация вещественных и квантованных сверточных нейронных сетей на мобильных устройствах Apple» содержит следующие разделы: «Введение», «Назначение и область применения», «Технические характеристики», «Ожидаемые технико-экономические показатели», приложения.

Раздел «Введение» включает в себя наименование программы и документ, на основании которого ведётся разработка, с указанием организации, утвердившей данный документ.

В разделе «Назначение и область применения» содержатся функциональное и эксплуатационное назначение программы и краткая характеристика области её применения.

В разделе «Назначение разработки» указано функциональное и эксплуатационное назначение создаваемого программного продукта.

В разделе «Технические характеристики» присутствуют следующие подразделы: постановка задачи на разработку программы, описание функционирования программы, описание и обоснование алгоритма работы программы, описание и обоснование выбора метода организации входных и выходных данных, описание работы с базой данных, описание и обоснование выбора состава технических и программных средств.

Раздел «Требования к программным документам» содержит указание на предварительный состав программной документации и специальные требования к ней.

В разделе «Ожидаемые технико-экономические показатели» указана предполагаемая потребность и экономические преимущества разработки по сравнению с отечественными и зарубежными образцами или аналогами.

Настоящий документ разработан в соответствии с требованиями:

1. ГОСТ 19.101-77 [1]: Виды программ и программных документов.
2. ГОСТ 19.102-77 [2]: Стадии разработки.
3. ГОСТ 19.103-77 [3]: Обозначения программ и программных документов.
4. ГОСТ 19.104-78 [4]: Основные надписи.
5. ГОСТ 19.105-78 [5]: Общие требования к программным документам.
6. ГОСТ 19.106-78 [6]: Требования к программным документам, выполненным печатным способом.
7. ГОСТ 19.404-79 [10]: Пояснительная записка. Требования к содержанию и оформлению.

Изменения к данной Пояснительной записке оформляются согласно ГОСТ 19.603-78 [12], ГОСТ 19.604-78 [13].

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 81 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

СОДЕРЖАНИЕ

1. ВВЕДЕНИЕ	4
1.1. Наименование программы	4
1.2. Документ(ы), на основании которого(ых) ведется разработка	4
1.3. Краткая характеристика области применения программы	4
2. НАЗНАЧЕНИЕ РАЗРАБОТКИ	5
2.1. Функциональное назначение	5
2.2. Эксплуатационное назначение	5
2.3. Краткая характеристика области применения программы	6
3. ТЕХНИЧЕСКИЕ ХАРАКТЕРИСТИКИ	7
3.1. Постановка задачи на разработку программы	7
3.2. Описание и обоснование выбора состава технических и программных средств	7
3.2.1. Состав технических и программных средств	7
3.2.2. Обоснование выбора технических и программных средств	7
3.3. Описание и обоснование архитектуры программы	8
3.4. Особенности функционала	8
3.4.1. Тензорное ядро и матричные операции	8
3.4.2. im2col и сверточные слои	9
3.4.3. Квантованные представления	9
3.4.4. Модуль тестирования и бенчмаркинга	9
3.5. Обоснование выбора метода организации входных и выходных данных	9
4. ОЖИДАЕМЫЕ ТЕХНИКО-ЭКОНОМИЧЕСКИЕ ПОКАЗАТЕЛИ	11
4.1. Ориентировочная экономическая эффективность	11
4.2. Предполагаемая потребность	11
ПРИЛОЖЕНИЕ 1. СПИСОК ИСПОЛЬЗУЕМОЙ ЛИТЕРАТУРЫ	12
ПРИЛОЖЕНИЕ 2. ТЕРМИНОЛОГИЯ	13
ПРИЛОЖЕНИЕ 3. ГРАФИК СРАВНЕНИЯ ПРОИЗВОДИТЕЛЬНОСТИ	15

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 81 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

1. ВВЕДЕНИЕ

1.1. Наименование программы

Наименование программы – «Быстрая реализация вещественных и квантованных сверточных нейронных сетей на мобильных устройствах Apple».

Наименование программы на английском языке – «Fast Implementation of Floating-Point and Quantized Convolutional Neural Networks on Apple Mobile Devices».

1.2. Документ(ы), на основании которого(ых) ведется разработка

Разработка ведется на основании учебного плана подготовки бакалавров по направлению 09.03.04 «Программная инженерия» и утвержденной академическим руководителем программы темы курсового проекта.

1.3. Краткая характеристика области применения программы

В современных мобильных вычислительных системах всё чаще требуется выполнять алгоритмы компьютерного зрения непосредственно на пользовательском устройстве. Такой подход позволяет уменьшить задержку обработки, снизить зависимость приложения от сетевого соединения и ограничить передачу пользовательских данных на внешние серверы. Для задач распознавания изображений и анализа видеопотока существенную часть вычислительной нагрузки составляют операции свертки и матричного умножения, поэтому эффективность их реализации напрямую влияет на практическую применимость нейронной модели.

Проект ориентирован на устройства Apple Silicon, в которых доступны как универсальные вычислительные ресурсы CPU, так и специализированные механизмы ускорения матричных операций. В рамках работы рассматривается выполнение сверточных нейронных сетей в вещественном и квантованном представлении, а также сравнение эталонного CPU/NEON-исполнения с ускоренным AMX/Accelerate-исполнением. Разрабатываемая библиотека предназначена для использования в составе приложений, где требуется локальный и воспроизводимый инференс модели без обучения.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 81 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

2. НАЗНАЧЕНИЕ РАЗРАБОТКИ

2.1. Функциональное назначение

Разрабатываемая программа предназначена для выполнения основных операций сверточных нейронных моделей на устройствах Apple Silicon. Программный продукт должен предоставлять модульный C++ API для выполнения прямого прохода нейронной сети, выбора режима вычислений, проверки корректности результатов и измерения производительности.

Программа должна обеспечивать выполнение следующих основных функций:

- создание и управление тензорами, включая описание формы, типа данных и режима вычислений;
- выполнение базовых операций линейной алгебры, включая матричное умножение (GEMM);
- преобразование свертки в матричное умножение с помощью алгоритма im2col;
- поддержку путей исполнения CPU/NEON и AMX/Accelerate с возможностью резервного переключения;
- поддержку вещественных и квантованных представлений данных различной разрядности;
- реализацию базовых слоев нейронных сетей: Conv2D, Linear, ReLU, Softmax, AvgPool2D, Flatten;
- загрузку весов модели из JSON-файлов и запуск инференса тестовой сети LeNet;
- измерение производительности и проверку корректности вычислений.

Функциональность программы распределяется между двумя группами компонентов. Первая группа относится к базовому тензорному ядру и включает описание формы тензора, выделение и хранение данных, доступ к элементам, создание представлений без копирования, итерацию по данным и выполнение элементарных операций. Вторая группа относится к уровню нейронных сетей и включает слои свертки, пулинга, активации, выравнивания и полносвязные слои, объединяемые в тестовую архитектуру LeNet.

Разработка должна обеспечивать проверяемость вычислений. Для этого CPU/NEON-исполнение рассматривается как эталонный и резервный путь, а AMX/Accelerate-исполнение используется для ускорения матричных операций на совместимых устройствах. Результаты ускоренного пути должны сравниваться с эталонными результатами с учетом допустимой численной погрешности.

2.2. Эксплуатационное назначение

Основными конечными пользователями разрабатываемого программного продукта являются разработчики приложений и специалисты по машинному обучению, работающие с моделями компьютерного зрения на базе Apple Silicon.

Программа предоставляет возможность реализации оптимизированных и энергоэффективных сверточных нейронных сетей на устройствах Apple Silicon с сопоставлением эффективности CPU/NEON- и AMX-исполнения при вещественном и квантованном представлении данных.

В эксплуатационном сценарии пользователь подготавливает веса модели в формате JSON, передает входное изображение или заранее сформированный тензор в библиотеку, выбирает требуемый путь исполнения и получает выходной тензор с результатами работы сети. Для проверки работы библиотеки предусмотрены тестовые изображения из набора MNIST и файл весов mnist_lenet.json,

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 81 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

что позволяет воспроизводимо проверять классификацию цифр и корректность загрузки параметров модели.

2.3. Краткая характеристика области применения программы

Программа «Быстрая реализация вещественных и квантованных сверточных нейронных сетей на мобильных устройствах Apple» относится к области системного программирования и оптимизации нейросетевых вычислений. Предметной областью является выполнение тензорных операций, необходимых для сверточных нейронных сетей, с использованием аппаратных возможностей Apple Silicon.

Область применения программы включает обработку изображений в реальном времени, исследование эффективности AMX/Accelerate по сравнению с CPU/NEON, а также оценку влияния квантования на скорость и точность инференса.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 81 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

3. ТЕХНИЧЕСКИЕ ХАРАКТЕРИСТИКИ

3.1. Постановка задачи на разработку программы

Целью разработки является создание высокопроизводительной программной библиотеки для выполнения прямого прохода сверточных нейронных сетей на устройствах Apple Silicon.

Основная задача заключается в реализации набора вычислительных компонентов, обеспечивающих выполнение операций нейронной сети в нескольких режимах: эталонном CPU/NEON-режиме, ускоренном AMX/Accelerate-режиме и режиме с квантованным представлением данных. Для достижения указанной цели необходимо реализовать общее тензорное представление данных, преобразование `im2col` для сверточных слоев, механизм выбора пути исполнения и воспроизводимые средства проверки производительности.

Ожидаемым результатом является библиотека, способная загружать веса предобученной модели, выполнять прямой проход сети LeNet и предоставлять данные для сравнения корректности и скорости разных путей исполнения.

3.2. Описание и обоснование выбора состава технических и программных средств

3.2.1. Состав технических и программных средств

Для разработки и тестирования программы используются следующие технические и программные средства:

- оборудование: устройства на базе Apple Silicon (процессоры серий M или A);
- операционная система: macOS или iOS;
- язык программирования: C++17 или выше;
- системные библиотеки: Apple Accelerate Framework, BLAS/LAPACK, доступные механизмы AMX;
- векторные инструкции: ARM NEON для эталонного CPU-пути;
- инструменты разработки: Xcode, Clang, CMake;
- вспомогательные инструменты: Python 3 для конвертации весов через `pt2json.py`;
- форматы данных: JSON для весов модели, JPEG/PNG для входных изображений.

В коде проекта поддерживаются вещественные и целочисленные типы данных `int8`, `int16`, `int32`, `int64`, `float32` и `float64`. Для описания вычислительного устройства используется перечисление режимов `cpu`, `neon` и `amx`. Такое разделение позволяет на уровне типа тензора фиксировать как формат данных, так и предполагаемый путь исполнения, что упрощает статическую организацию кода и уменьшает риск случайного смешивания несовместимых представлений.

3.2.2. Обоснование выбора технических и программных средств

Выбор языка C++ обусловлен необходимостью низкоуровневого управления памятью и минимизации накладных расходов при выполнении тензорных операций. Архитектура Apple Silicon выбрана в качестве целевой, поскольку она позволяет исследовать взаимодействие CPU, NEON, AMX и объединенной памяти в рамках одного программного продукта. Формат JSON используется для прозрачной передачи весов из среды обучения в среду исполнения и упрощения отладки загрузки модели.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 81 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

3.3. Описание и обоснование архитектуры программы

Архитектура программы построена по модульному принципу с разделением уровней представления данных, базовых операций, бэкендов исполнения и высокоуровневых слоев нейронной сети.

Основные компоненты архитектуры:

1. Слой представления данных: Tensor, TensorDesc, TensorView и описание типов данных.
2. Слой операций: элементарные операции, матричное умножение, im2col, функции активации.
3. Слой бэкендов: CPU/NEON-реализация, AMX/Accelerate-реализация и механизм fallback.
4. Слой нейронных сетей: Layer, Conv2D, Linear, LeNet и вспомогательные слои.
5. Слой сериализации: загрузка весов модели из JSON-файлов.

Такое разделение позволяет независимо развивать тензорное ядро, оптимизированные бэкенды и высокоуровневые нейросетевые слои.

На уровне исходного кода публичный интерфейс разделен на агрегирующие заголовочные файлы core.hpp и nn.hpp. Первый объединяет базовые структуры данных и операции, второй предоставляет слои нейронной сети. Реализации шаблонных компонентов вынесены в файлы с расширением.hpp.inl, что позволяет сохранять раздельную структуру проекта и одновременно использовать шаблонные классы без отдельной компоновки специализаций.

Слой сериализации представлен загрузчиком JSON-модели. Он формирует набор состояний слоев, где для каждого слоя хранятся именованные тензоры весов и смещений. Такой формат соответствует потребностям архитектуры LeNet: сверточные и полносвязные слои получают свои параметры по идентификаторам conv1, conv2, fc1, fc2 и fc3, после чего могут использовать их в прямом проходе.

3.4. Особенности функционала

3.4.1. Тензорное ядро и матричные операции

Назначение модуля состоит в обеспечении единого интерфейса для работы с многомерными массивами данных. Модуль выполняет создание тензоров, проверку совместимости размерностей, доступ к данным и передачу буферов в операции матричного умножения. Для проверки корректности ускоренных вычислений используется CPU/NEON-эталон.

Описание тензора включает форму, шаги обхода и смещение относительно начала буфера. Благодаря этому библиотека может создавать представления тензоров, выполнять транспонирование и срезы без обязательного копирования данных. При необходимости пользователь может получить непрерывное представление данных, что важно для передачи буфера в низкоуровневые операции матричного умножения и в ускоренные бэкенды.

Операция матричного умножения проверяет размерности входных аргументов и поддерживает случаи перемножения векторов, матрицы на вектор, вектора на матрицу и двух матриц. При несовместимых формах операция должна завершаться диагностической ошибкой. Такой подход соответствует требованиям ТЗ к устойчивости программы при некорректных входных данных и позволяет использовать CPU-реализацию как проверяемую базу для ускоренных вариантов.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 81 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

3.4.2. im2col и сверточные слои

Назначение модуля im2col состоит в преобразовании локальных областей входного изображения в матричное представление. Такое преобразование позволяет выполнять свертку через GEMM и использовать общие оптимизированные пути исполнения для сверточных и полносвязных слоев.

Сверточный слой принимает число входных и выходных каналов, размер ядра, шаг, отступы, дилатацию, число групп и признак использования смещения. На основании этих параметров вычисляется размер выходной карты признаков. Преобразование im2col делает вычисление свертки совместимым с общим механизмом матричного умножения, поэтому оптимизация GEMM одновременно улучшает работу полносвязных и сверточных слоев.

3.4.3. Квантованные представления

Механизм квантования предназначен для уменьшения потребления памяти и повышения скорости вычислений при контролируемой потере точности относительно вещественной реализации.

Поддержка целочисленных типов данных важна для экспериментального сравнения вещественного и квантованного исполнения. Квантованные представления позволяют уменьшить размер весов и промежуточных активаций, но требуют контроля масштабирующих коэффициентов и проверки итоговой точности.

3.4.4. Модуль тестирования и бенчмаркинга

Модуль тестирования и бенчмаркинга предназначен для верификации корректности вычислений и количественной оценки производительности. Бенчмарки фиксируют параметры эксперимента, время выполнения операций и расчетное ускорение AMX-исполнения относительно CPU/NEON. График сравнения производительности приведен в приложении 3.

Интеграционные тесты LeNet загружают изображения, приводят их к размеру 28 на 28 пикселей, нормализуют значения яркости и формируют входной тензор с одной компонентой канала. После загрузки весов модель выполняет последовательность Conv2D, ReLU, AvgPool2D, Flatten и Linear-слоев. Полученный выходной вектор обрабатывается Softmax, после чего выбирается класс с максимальной вероятностью. Тестовый набор содержит изображения цифр от 0 до 9 и позволяет проверить не только отдельные операции, но и весь путь данных от файла изображения до итогового класса.

Бенчмарк матричного умножения формирует входные матрицы фиксированных размеров и выполняет серию измерений для float32 и float64 в CPU- и AMX-режимах. В качестве параметров используются размеры 128 на 128, 256 на 256, а также прямоугольный случай 128 на 256, умножаемый на 256 на 64. Для каждого запуска фиксируется число обработанных элементов, что позволяет рассчитывать задержку и пропускную способность вычислений.

3.5. Обоснование выбора метода организации входных и выходных данных

Веса моделей хранятся в JSON-файлах, что упрощает перенос параметров из PyTorch и отладку структуры сети. Входные изображения преобразуются в тензоры, совместимые с выбранным форматом данных и режимом исполнения. Выходные данные представляют собой тензор вероятно-

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 81 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

стей классов после Softmax, который используется для интерпретации результата классификации и сравнения корректности вычислений.

Внутреннее представление данных основано на плоском массиве и метаданных тензора. Форма задает логическую размерность данных, шаги определяют способ перехода между элементами по каждой оси, а смещение позволяет создавать представления на часть исходного буфера. Такая организация уменьшает количество лишних копирований при передаче данных между слоями и облегчает реализацию операций slice, transpose и contiguous.

Выходные данные бенчмарков и тестов используются в двух целях. Во-первых, они подтверждают функциональную корректность: тесты LeNet должны выдавать ожидаемые классы для подготовленных изображений. Во-вторых, они формируют основу для оценки производительности: результаты замеров используются для построения графика ускорения AMX-исполнения относительно CPU/NEON, приведенного в приложении 3.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 81 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

4. ОЖИДАЕМЫЕ ТЕХНИКО-ЭКОНОМИЧЕСКИЕ ПОКАЗАТЕЛИ

4.1. Ориентировочная экономическая эффективность

Экономическая эффективность разработки заключается в снижении вычислительных затрат при локальном выполнении CNN-моделей на устройствах Apple Silicon. Использование AMX/Accelerate, CPU/NEON-резервирования, im2col и квантованных представлений позволяет уменьшить задержку инференса, сократить энергопотребление и снизить требования к объему памяти.

Ожидаемый эффект включает:

- повышение пропускной способности при обработке изображений;
- снижение времени активной работы процессора при выполнении тяжелых операций;
- возможность запуска более компактных квантованных моделей;
- сокращение времени интеграции за счет единого C++ API.

Дополнительный эффект связан с переносом вычислений с удаленной инфраструктуры на пользовательское устройство. При локальном инференсе снижаются расходы на серверные вычисления и сетевую передачу данных, уменьшается задержка ответа приложения и повышается устойчивость работы в условиях нестабильного соединения. Для приложений компьютерного зрения это особенно важно, поскольку обработка изображений часто выполняется в интерактивном режиме и требует воспроизводимого времени отклика.

Наличие CPU/NEON-эталона снижает стоимость сопровождения программы. Разработчик получает возможность проверять корректность ускоренного режима без привлечения внешних фреймворков и без отдельной эталонной реализации. Модульная структура также уменьшает стоимость расширения: новые слои или дополнительные бэкэнды могут добавляться без переписывания всей цепочки инференса.

4.2. Предполагаемая потребность

Разработка востребована разработчиками iOS/macOS-приложений, инженерами по машинному обучению и исследователями edge-вычислений, которым необходим локальный инференс без сетевой задержки и без передачи данных на сервер. Типовые области применения: компьютерное зрение, AR, мобильная аналитика и автономная обработка изображений.

Практическая потребность в такой библиотеке возникает при создании приложений, где высокоуровневые фреймворки оказываются избыточными или не позволяют явно контролировать путь исполнения отдельных операций. Разрабатываемая программа предоставляет более узкую, но проверяемую основу для экспериментов с AMX/Accelerate, CPU/NEON и квантованными представлениями данных.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 81 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

ПРИЛОЖЕНИЕ 1. СПИСОК ИСПОЛЬЗУЕМОЙ ЛИТЕРАТУРЫ

1. ГОСТ 19.101-77: Виды программ и программных документов. // Единая система программной документации. – М.: ИПК Издательство стандартов, 2001.
2. ГОСТ 19.102-77: Стадии разработки. // Единая система программной документации. – М.: ИПК Издательство стандартов, 2001.
3. ГОСТ 19.103-77: Обозначения программ и программных документов. // Единая система программной документации. – М.: ИПК Издательство стандартов, 2001.
4. ГОСТ 19.104-78: Основные надписи. // Единая система программной документации. – М.: ИПК Издательство стандартов, 2001.
5. ГОСТ 19.105-78: Общие требования к программным документам. // Единая система программной документации. – М.: ИПК Издательство стандартов, 2001.
6. ГОСТ 19.106-78: Требования к программным документам, выполненным печатным способом. // Единая система программной документации. – М.: ИПК Издательство стандартов, 2001.
7. ГОСТ 19.404-79: Пояснительная записка. Требования к содержанию и оформлению. // Единая система программной документации. – М.: ИПК Издательство стандартов, 2001.
8. Официальная документация Apple Accelerate. Электронный ресурс. URL: <https://developer.apple.com/documentation/accelerate> (дата обращения 22.11.25).
9. Документация C++. Электронный ресурс. URL: <https://cppreference.com/> (дата обращения 22.11.25).

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 81 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

ПРИЛОЖЕНИЕ 2. ТЕРМИНОЛОГИЯ

Термин	Определение
Инференс	Прямой проход нейронной сети по входным данным с получением результата без дообучения модели.
Сверточная нейронная сеть	Архитектура нейронной сети, применяющая операции свертки для выделения признаков из данных с пространственной структурой.
Тензор	Многомерный массив числовых данных, используемый для хранения входов, весов, активаций и результатов.
Backend	Низкоуровневый путь исполнения вычислительной операции, например CPU/NEON или AMX/Accelerate.
CPU/NEON-эталон	Базовая реализация на центральном процессоре с использованием векторных инструкций NEON для проверки корректности ускоренных режимов.
Apple Silicon	Семейство систем на кристалле Apple на базе ARM64 с CPU, GPU, ускорителями и объединенной памятью.
AMX	Аппаратный механизм Apple Silicon для ускорения матричных вычислений.
Accelerate	Системный фреймворк Apple с оптимизированными функциями линейной алгебры и обработки сигналов.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 81 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

Термин	Определение
GEMM	Обобщенное матричное умножение, используемое в полносвязных слоях и сверточных слоях после im2col.
Conv2D	Двумерная свертка для вычисления карт признаков по входному изображению и набору фильтров.
im2col	Преобразование областей входного изображения в матричное представление для выполнения свертки через GEMM.
Квантование	Представление весов и активаций с меньшей разрядностью для снижения потребления памяти и ускорения вычислений.
LeNet	Тестовая архитектура сверточной нейронной сети, используемая для проверки инференса.
Softmax	Функция активации, преобразующая выходной вектор модели в распределение вероятностей по классам.
Fallback	Резервное переключение вычислений на CPU/NEON при недоступности или ошибке ускоренного пути.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 81 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

ПРИЛОЖЕНИЕ 3. ГРАФИК СРАВНЕНИЯ ПРОИЗВОДИТЕЛЬНОСТИ




Рис. 1. Сравнение ускорения AMX-исполнения относительно CPU/NEON-исполнения
Источник данных: результаты выполнения бенчмарков матричного умножения.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 81 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

ЛИСТ РЕГИСТРАЦИИ ИЗМЕНЕНИЙ

[illegible]