

**ПРАВИТЕЛЬСТВО РОССИЙСКОЙ ФЕДЕРАЦИИ
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ
ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ
"ВЫСШАЯ ШКОЛА ЭКОНОМИКИ"**

Факультет компьютерных наук
Образовательная программа "Программная инженерия"

СОГЛАСОВАНО

Научный руководитель, научный
сотрудник ФИЦ ИУ РАН

_____ Е. Е. Лимонова

«__» _____ 2026 г.

УТВЕРЖДЕНО

Академический руководитель
образовательной программы
"Программная инженерия", старший
преподаватель Департамента
программной инженерии

_____ Н. А. Павлов

«__» _____ 2026 г.

**БЫСТРАЯ РЕАЛИЗАЦИЯ ВЕЩЕСТВЕННЫХ И КВАНТОВАННЫХ
СВЕРТОЧНЫХ НЕЙРОННЫХ СЕТЕЙ НА МОБИЛЬНЫХ УСТРОЙСТВАХ
APPLE**

Программа и методика испытаний

ЛИСТ УТВЕРЖДЕНИЯ

RU.17701729.04.06 51 01-1-ЛУ

Исполнители:

Студент группы БПИ241

_____ / А. Д. Ергучев /

«__» _____ 2026 г.

Студент группы БПИ241

_____ / Г. А. Суханов /

«__» _____ 2026 г.

Инов.№ подп	Подп. и дата	Взам. инв.№	Инов.№ дубл.	Подп. и дата

УТВЕРЖДЕН

RU.17701729.04.06 51 01-1-ЛЮ

**БЫСТРАЯ РЕАЛИЗАЦИЯ ВЕЩЕСТВЕННЫХ И КВАНТОВАННЫХ
СВЕРТОЧНЫХ НЕЙРОННЫХ СЕТЕЙ НА МОБИЛЬНЫХ УСТРОЙСТВАХ
APPLE**

Программа и методика испытаний

RU.17701729.04.06 51 01-1

Листов 18

Инов.№ подп	Подп. и дата	Взам. инв.№	Инов.№ дубл.	Подп. и дата

АННОТАЦИЯ

Программа и методика испытаний — это документ, в котором содержится информация о программном продукте, а также полное описание приемочных испытаний для данного программного продукта.

Настоящая Программа и методика испытаний для «Система комплексного анализа самостоятельности выполнения программных проектов» содержит следующие разделы: «Объект испытаний», «Цель испытаний», «Требования к программе», «Требования к программной документации», «Средства и порядок испытаний», «Методы испытаний», «Приложения».

В разделе «Объект испытаний» указано наименование, краткая характеристика и назначение программы.

В разделе «Цель испытаний» указана цель проведения испытаний. Раздел «Требования к программе» содержит основные требования к программе, которые подлежат проверке во время испытаний (требования к функционалу и интерфейсу).

Раздел «Требования к программным документам» содержит состав программной документации, которая представляется на испытания.

Раздел «Средства и порядок испытаний» содержит информацию о технических и программных средствах, которые следует использовать во время испытаний, а также порядок этих испытаний.

Раздел «Методы испытаний» содержит информацию об используемых методах испытаний.

Настоящий документ разработан в соответствии с требованиями:

1. ГОСТ 19.101-77 [1]: Виды программ и программных документов.
2. ГОСТ 19.102-77 [2]: Стадии разработки.
3. ГОСТ 19.103-77 [3]: Обозначения программ и программных документов.
4. ГОСТ 19.104-78 [4]: Основные надписи.
5. ГОСТ 19.105-78 [5]: Общие требования к программным документам.
6. ГОСТ 19.106-78 [6]: Требования к программным документам, выполненным печатным способом.
7. ГОСТ 19.301-79 [7]: Программа и методика испытаний. Требования к содержанию и оформлению.

Изменения к данной Программе и методике испытаний оформляются согласно ГОСТ 19.603-78 [8], ГОСТ 19.604-78 [9].

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 51 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

СОДЕРЖАНИЕ

1. ОБЪЕКТ ИСПЫТАНИЙ	4
1.1. Наименование программы	4
1.2. Краткая характеристика области применения программы	4
2. ЦЕЛЬ ИСПЫТАНИЙ	5
2.1. Верификация функциональной корректности вычислений	5
2.2. Оценка производительности и эффективности путей исполнения	5
2.3. Проверка надежности и отказоустойчивости	5
2.4. Границы приемки системы	6
3. ТРЕБОВАНИЯ К ПРОГРАММЕ	7
3.1. Требования к функциональным характеристикам	7
3.1.1. Состав выполняемых функций	7
3.2. Требования к входным и выходным данным	8
3.2.1. Организация входных данных	8
3.2.2. Организация выходных данных	8
3.3. Требования к интерфейсу	9
4. ТРЕБОВАНИЯ К ПРОГРАММНОЙ ДОКУМЕНТАЦИИ	10
5. СРЕДСТВА И ПОРЯДОК ИСПЫТАНИЙ	11
5.1. Технические средства	11
5.2. Программные средства	11
5.3. Порядок проведения испытаний	11
5.4. Требования к персоналу	12
6. МЕТОДЫ ИСПЫТАНИЙ	13
6.1. Проверка требований к технической документации	13
6.2. Проверка требований к интерфейсу	13
6.3. Проверка требований к функциональным характеристикам	13
6.3.1. Инференс сверточной сети в режиме аппаратного ускорения (AMX)	13
6.3.2. Сравнение точности CPU/NEON- и AMX-реализаций	14
6.3.3. Обработка некорректных входных данных и резервирование	14
6.3.4. Анализ производительности при разной разрядности квантования	14
СПИСОК ИСПОЛЬЗУЕМОЙ ЛИТЕРАТУРЫ	17

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 51 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

1. ОБЪЕКТ ИСПЫТАНИЙ

1.1. Наименование программы

Наименование программы: «Быстрая реализация вещественных и квантованных сверточных нейронных сетей на мобильных устройствах Apple».

Наименование программы на английском языке: «Fast Implementation of Floating-Point and Quantized Convolutional Neural Networks on Apple Mobile Devices».

1.2. Краткая характеристика области применения программы

Программный проект по созданию высокопроизводительной реализации сверточных нейронных сетей на устройствах Apple Silicon. В рамках работы сравниваются CPU/NEON- и AMX-исполнения, поддерживаются вещественные и квантованные представления различной разрядности, а целевой архитектурой выступает VGG-уровень для задач компьютерного зрения.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 51 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

2. ЦЕЛЬ ИСПЫТАНИЙ

Цель испытаний состоит в проверке совместной работы клиентских, серверных и интеграционных компонентов проекта.

В рамках данного программного продукта целью испытаний является проверка корректности реализации высокопроизводительного API для исполнения сверточных нейронных сетей на устройствах Apple Silicon, а также верификация соответствия полученных результатов вычислительным требованиям, изложенным в техническом задании.

Испытания направлены на подтверждение следующих ключевых аспектов системы:

2.1. Верификация функциональной корректности вычислений

Основной целью является подтверждение того, что результаты матричных операций и сверточных слоев, выполненных с использованием аппаратного ускорения Apple Matrix (через фреймворк Accelerate), совпадают с результатами эталонного CPU-исполнения в пределах допустимой численной погрешности. Это включает в себя:

- Проверку корректности работы тензорных структур, описания их формы (shape), типов данных и механизмов доступа к данным.
- Валидацию совместимости размерностей матриц при выполнении операции матричного умножения и корректность обработки диагностических ошибок при их несовпадении.
- Проверку точности вычислений для вещественных и квантованных представлений различной разрядности.
- Верификацию работы основных слоев сверточной сети: свертки (Conv2D), пулинга (AvgPool2D), функций активации (ReLU) и полносвязных слоев (Linear), в том числе в составе архитектуры LeNet/VGG.

2.2. Оценка производительности и эффективности путей исполнения

Испытания должны подтвердить достижение целевых показателей быстродействия, а именно:

- Сокращение времени исполнения операций свертки и полносвязных слоев при переключении с CPU/NEON-реализации на AMX-реализацию через фреймворк Accelerate.
- Определение времени выполнения для каждого проверяемого режима исполнения.
- Оценка стабильности времени обработки одного изображения в рамках архитектуры сверточной сети.
- Сравнение пропускной способности при различных размерах пакета (batch size) и размерностях входных изображений.

2.3. Проверка надежности и отказоустойчивости

Целью является подтверждение стабильной работы библиотеки в различных сценариях:

- Проверка механизма резервного переключения (fallback) на CPU-исполнение в случаях, когда использование AMX недоступно или вызывает сбой.
- Проверка устойчивости системы к некорректным входным данным: обработка поврежденных файлов изображений (.png, .jpg, .jpeg), наличие значений NaN в тензорах, несоответствие форматов тензоров или пустые файлы.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 51 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

- Проверка корректности работы при переключении режимов исполнения (CPU/NEON и AMX) и типов представлений (вещественное/квантованное) без аварийного завершения программы.

2.4. Границы приемки системы

Система считается прошедшей испытания, если:

1. Реализован единый C++ API для создания тензоров, управления доступом к данным и выполнения матричного умножения.
2. Функциональные тесты подтверждают идентичность результатов AMX- и CPU-путей исполнения в пределах заданной численной погрешности.
3. Зафиксировано измеримое сокращение времени выполнения операций при использовании Accelerate по сравнению с базовой CPU/NEON-реализацией.
4. Программный комплекс стабильно работает на целевой платформе (macOS 12.0+ на Apple Silicon) с использованием фреймворка Accelerate.
5. Реализована поддержка вещественных типов данных и механизмы квантования, предусмотренные архитектурой проекта.

Итоговое сравнение производительности CPU Conv2d, NEON im2col и AMX Conv2d формируется по результатам бенчмарков LeNet и используется как подтверждение измеримости характеристик исполнения.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 51 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

3. ТРЕБОВАНИЯ К ПРОГРАММЕ

3.1. Требования к функциональным характеристикам

Программа должна соответствовать следующим функциональным требованиям, указанным в документе «Быстрая реализация вещественных и квантованных сверточных нейронных сетей на мобильных устройствах Apple. Техническое задание»:

3.1.1. Состав выполняемых функций

Программный продукт представляет собой библиотеку (API) для высокопроизводительного инференса сверточных нейронных сетей и должен обеспечивать выполнение следующих функций:

- **Реализация вычислительных слоев:**
 - Выполнение операции двумерной свертки (Conv2D) с поддержкой различных конфигураций ядра и шага.
 - Реализация функций активации, в частности ReLU.
 - Выполнение операций пулинга (Average Pooling) для уменьшения размерности признаков.
 - Реализация полносвязных (Linear) слоев для финальной классификации.
 - Реализация операции Flatten для преобразования многомерных тензоров в одномерные векторы.
 - Реализация функции Softmax для получения вероятностного распределения классов.
- **Управление вычислительными бэкендами:**
 - Обеспечение работы через аппаратный ускоритель Apple Matrix (AMX) с использованием фреймворка Accelerate для максимизации пропускной способности матричных операций.
 - Реализация эталонного пути вычислений на CPU (с использованием ARM NEON) для обеспечения совместимости и верификации результатов.
 - Обеспечение резервирования: при невозможности использования AMX-ускорения вычисления должны быть автоматически перенаправлены на CPU без аварийного завершения работы.
 - Поддержка единого интерфейса вызова операций, скрывающего детали реализации конкретного бэкенда.
- **Поддержка типов данных и квантования:**
 - Работа с вещественными представлениями данных (Floating-Point).
 - Поддержка квантованных представлений различной разрядности для снижения нагрузки на память и увеличения скорости обработки.
 - Возможность переключения между вещественным и квантованным режимами исполнения через конфигурацию.
- **Интеграция и анализ:**
 - Сборка реализованных слоев в единую архитектуру сверточной нейронной сети (целевой уровень — VGG/LeNet).

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 51 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

- Измерение временных затрат на выполнение каждой отдельной операции и всей сети в целом.
- Сравнение точности результатов AMX-исполнения с CPU-эталонном с контролем числовой погрешности.
- Поддержка режима исполнения без обучения (Inference only).

3.2. Требования к входным и выходным данным

3.2.1. Организация входных данных

Входные данные программы разделяются на данные конфигурации, веса модели и входные тензоры (данные для обработки):

- **Данные конфигурации:**
 - Передаются через аргументы командной строки или конфигурационный файл.
 - Включают: режим работы (AMX/CPU), разрядность квантования, размер пакета (batch size), пути к файлам весов и входным изображениям, а также целевой размер изображения.
- **Веса модели:**
 - Загружаются из внешних файлов в формате JSON (подготавливаемых с помощью скрипта pt2json.py).
 - Содержат значения фильтров свертки, веса полносвязных слоев и параметры смещения (bias).
- **Входные тензоры (изображения):**
 - Поддерживаемые форматы: .png, .jpg, .jpeg.
 - Процесс подготовки: изменение размера до заданного, нормализация значений пикселей в диапазон [0; 1] и преобразование в тензор формата NHWC (Batch, Height, Width, Channels).
 - Тип данных тензора должен соответствовать выбранному режиму (вещественный или квантованный).
- **Валидация:**
 - Проверка файлов весов и изображений на целостность и отсутствие повреждений.
 - Контроль совместимости размерностей входного тензора с требованиями первого слоя сети.
 - Проверка данных на наличие некорректных значений (NaN, бесконечности).

3.2.2. Организация выходных данных

Результатом работы программы являются выходные тензоры нейронной сети и диагностические метрики:

- **Результаты инференса:**
 - Выходные данные представляются в виде векторных или тензорных структур (например, вектор вероятностей классов после слоя Softmax).
 - Формат данных должен быть совместим с Accelerate BLAS/AMX API для обеспечения возможности дальнейшей обработки.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 51 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

- **Метрики производительности:**

- Время выполнения отдельных слоев и итоговое время прохода всей сети (в мс/мкс).
- Сравнение времени выполнения для CPU Conv2d, NEON im2col и AMX Conv2d.
- Оценка точности: вычисление разности между результатами CPU-эталона и AMX-выполнения.

- **Диагностические сообщения:**

- Вывод в стандартный поток ошибок (stderr) или консоль сообщений о некорректных входных данных или несоответствии размерностей.
- Уведомления о переключении бэкенда при возникновении ошибок в AMX-пути.

3.3. Требования к интерфейсу

Программа предоставляет два уровня взаимодействия: программный интерфейс (API) для интеграции в другие приложения и консольный интерфейс для проведения тестов и бенчмарков.

- **Программный интерфейс (API):**

- Реализован как модульная библиотека на языке C++.
- Предоставляет базовые абстракции для работы с тензорами (Tensor, TensorDesc) и иерархию классов для слоев (Layer, Conv2d, Linear, ReLU и др.).
- Обеспечивает единый метод выполнения прямого прохода (forward pass), инкапсулирующий логику выбора бэкенда.
- Интерфейс API должен оставаться идентичным при смене режима вычислений с CPU на AMX.

- **Консольный интерфейс:**

- Предназначен для запуска модульных тестов (lenet_test.cpp) и бенчмарков (lenet_benchmark.cpp).
- Позволяет через командную строку задавать параметры запуска: пути к данным, выбор бэкенда, разрядность.
- Выводит в стандартный поток вывода (stdout) результаты замеров производительности и подтверждение корректности вычислений.

- **Критерии согласованной работы:**

- Совместимость с macOS версии 12.0 и выше.
- Корректное взаимодействие с системным фреймворком Accelerate и использование инструкций ARM NEON.
- Формирование итогового протокола производительности, включающего режим исполнения, тип данных, размер входных данных и время выполнения.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 51 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

4. ТРЕБОВАНИЯ К ПРОГРАММНОЙ ДОКУМЕНТАЦИИ

На испытание должна быть представлена документация в следующем составе:

1. «Быстрая реализация вещественных и квантованных сверточных нейронных сетей на мобильных устройствах Apple». Техническое задание (ГОСТ 19.201-78 [7]).
2. «Быстрая реализация вещественных и квантованных сверточных нейронных сетей на мобильных устройствах Apple». Пояснительная записка (ГОСТ 19.404-79 [10]).
3. «Быстрая реализация вещественных и квантованных сверточных нейронных сетей на мобильных устройствах Apple». Программа и методика испытаний (ГОСТ 19.301-79 [8]).
4. «Быстрая реализация вещественных и квантованных сверточных нейронных сетей на мобильных устройствах Apple». Текст программы (ГОСТ 19.401-78 [9]).
5. «Быстрая реализация вещественных и квантованных сверточных нейронных сетей на мобильных устройствах Apple». Руководство оператора (ГОСТ 19.505-79 [11]).

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 51 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

5. СРЕДСТВА И ПОРЯДОК ИСПЫТАНИЙ

5.1. Технические средства

Для проведения испытаний программного обеспечения используется специализированный аппаратный комплекс, обеспечивающий поддержку инструкций Apple Matrix (AMX) и векторных расширений ARM NEON:

- Рабочая станция или мобильное устройство на базе чипа Apple Silicon (серии M1, M2 или M3), что является обязательным требованием для функционирования AMX-исполнения.
- Объем системной оперативной памяти, достаточный для загрузки весов нейронной сети и промежуточных тензоров (рекомендуется не менее 8 Гб).
- Накопитель с достаточным свободным пространством для хранения тестовых наборов изображений и JSON-файлов с весами моделей.

5.2. Программные средства

Программный стенд для испытаний включает в себя следующие компоненты:

- Операционная система: macOS версии 12.0 или выше.
- Системный фреймворк: Apple Accelerate (для доступа к операциям BLAS и AMX).
- Среда разработки и компиляции: Xcode (актуальная версия), поддерживающая стандарт C++17 и выше.
- Инструменты тестирования: консольный интерфейс (Terminal) для запуска исполняемых файлов и замера времени выполнения.
- Вспомогательное ПО: интерпретатор Python (для предварительной конвертации весов моделей из PyTorch в формат JSON с помощью скрипта pt2json.py).

5.3. Порядок проведения испытаний

Испытания проводятся в следующей последовательности:

1. Подготовка данных:

- Конвертация весов предобученной модели (например, LeNet) в JSON-формат.
- Подготовка тестового набора изображений (форматы .png/.jpg/.jpeg), нормализация которых и приведение к размеру NHWC выполняется программно при загрузке.
- Размещение файлов весов (mnist_lenet.json) и входных изображений в директориях, доступных приложению.

2. Запуск компонентов:

- Компиляция исходного кода проекта с подключением библиотек Accelerate.
- Запуск консольного приложения с указанием параметров конфигурации: режима вычислений (CPU или AMX), разрядности квантования и пути к входным данным.

3. Проведение интеграционных сценариев:

- **Проверка корректности:** запуск вычислений в режиме CPU (эталон) и сравнение полученных выходных тензоров с результатами AMX-исполнения. Контроль численной погрешности.
- **Тестирование разрядностей:** последовательное переключение между вещественным представлением и квантованными режимами различной разрядности.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 51 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

- **Замер производительности:** выполнение серии прогонов одной и той же модели в режимах CPU Conv2d, NEON im2col и AMX Conv2d для формирования метрик времени выполнения.
- **Проверка отказоустойчивости:** подача поврежденных файлов или тензоров с несовместимыми размерностями для проверки работы механизмов диагностики и резервной маршрутизации на CPU.

4. Анализ результатов:

- Сбор данных о времени обработки одного изображения.
- Сравнение точности распознавания/выхода модели при квантовании.
- Построение графика времени выполнения CPU Conv2d, NEON im2col и AMX Conv2d по результатам бенчмарков LeNet.

5.4. Требования к персоналу

Испытания должны проводиться специалистом, обладающим следующей квалификацией:

- Владение языком программирования C++ и навыками работы в среде Xcode под macOS.
- Понимание принципов работы сверточных нейронных сетей (CNN), в частности архитектур уровня VGG/LeNet.
- Знание основ линейной алгебры (операции матричного умножения, свертки) и понимание принципов квантования весов.
- Навыки работы с консольным интерфейсом UNIX и инструментами профилирования производительности.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 51 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

6. МЕТОДЫ ИСПЫТАНИЙ

6.1. Проверка требований к технической документации

Проверка технической документации осуществляется путем анализа состава и содержания представленных документов на соответствие требованиям ГОСТ 19.106-78 и специфике проекта. В ходе проверки контролируется наличие следующих документов:

- Техническое задание: проверяется полнота описания функциональных требований к слоям сверточной сети и режимам вычислений (CPU/NEON и AMX).
- Пояснительная записка: оценивается описание архитектуры тензорного ядра, реализации матричных операций и обоснование выбора фреймворка Accelerate.
- Программа и методика испытаний: проверяется наличие всех необходимых сценариев тестирования корректности и производительности.
- Текст программы: проверяется наличие полного исходного кода на языке C++, включая заголовочные файлы (например, core.hpp, tensor.hpp) и реализации (.inl файлы).
- Руководство оператора: проверяется описание процесса сборки проекта, настройки конфигурационных параметров и запуска бенчмарков.

6.2. Проверка требований к интерфейсу

Проверка интерфейса включает в себя тестирование программного API и консольного интерфейса управления.

1. Проверка API: анализ соответствия заголовочных файлов (nn/layer.hpp, core/tensor.hpp) заявленному модульному интерфейсу. Проверяется возможность создания тензоров, задания их формы и типа данных без прямого доступа к внутренним структурам бэкенда.
2. Проверка консольного интерфейса: тестирование параметров командной строки, через которые осуществляется выбор режима работы (AMX/CPU), выбор разрядности квантования и указание путей к весам модели (в формате JSON) и входным изображениям.
3. Проверка интеграционных точек: контроль взаимодействия между высокоуровневыми слоями (например, conv2d.hpp) и низкоуровневыми реализациями матричного умножения в core/backend/amx/matmul.hpp.

6.3. Проверка требований к функциональным характеристикам

Функциональные характеристики проверяются путем выполнения сквозных сценариев, охватывающих полный цикл обработки данных: от загрузки изображения до получения итогового вектора активации с замером времени исполнения.

6.3.1. Инференс сверточной сети в режиме аппаратного ускорения (AMX)

Сценарий проверяет корректность работы всей цепочки слоев при использовании сопроцессора Apple Matrix через фреймворк Accelerate.

- **Исходные данные:** RGB-изображение в формате .jpg (из inputs_test/), файл весов модели в формате JSON (weights/mnist_lenet.json), конфигурация: режим AMX, вещественное представление.
- **Действия:**
 1. Загрузка изображения и приведение его к тензору формата NHWC.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 51 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

2. Инициализация слоев нейронной сети (Convolution, ReLU, AvgPool, Linear) с загрузкой соответствующих весов.
 3. Запуск прямого прохода (forward pass) сети в режиме AMX.
 4. Замер времени выполнения с помощью встроенных инструментов профилирования.
- **Ожидаемый результат:** Получение выходного тензора с размерностью, соответствующей количеству классов модели.
 - **Критерий успешности:** Отсутствие аварийного завершения программы; время исполнения AMX-версии должно быть ниже времени исполнения CPU-версии для аналогичных данных.

6.3.2. Сравнение точности CPU/NEON- и AMX-реализаций

Сценарий направлен на подтверждение численной стабильности аппаратного ускорения.

- **Исходные данные:** Тестовый набор тензоров с фиксированными значениями, веса слоев.
- **Действия:**
 1. Выполнение операции матричного умножения (GEMM) с использованием эталонного CPU-пути.
 2. Выполнение той же операции с использованием AMX/Accelerate-пути.
 3. Вычисление разности результатов (L2-норма или максимальное абсолютное отклонение).
- **Ожидаемый результат:** Разница между результатами CPU/NEON и AMX не должна превышать установленный порог численной погрешности для выбранного типа данных.
- **Критерий успешности:** Все модульные тесты корректности (lenet_test.cpp) проходят успешно.

6.3.3. Обработка некорректных входных данных и резервирование

Сценарий проверяет устойчивость системы к ошибкам и механизм fallback на CPU.

- **Исходные данные:** Поврежденный файл изображения или файл весов с несоответствием размерностей тензоров.
- **Действия:**
 1. Попытка загрузки поврежденного файла.
 2. Попытка инициализации слоя с несовместимыми размерностями матриц.
 3. Имитация сбоя при вызове AMX-функции (в случае поддержки соответствующим API).
- **Ожидаемый результат:** Программа выдает диагностическое сообщение об ошибке, не завершается аварийно (crash) и, при невозможности использовать AMX, переключает вычисления на CPU/NEON-реализацию.
- **Критерий успешности:** Корректный вывод сообщения об ошибке в консоль; успешное завершение работы программы в режиме CPU-резервирования.

6.3.4. Анализ производительности при разной разрядности квантования

Сценарий проверяет влияние квантования на быстродействие и точность.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 51 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

- **Исходные данные:** Модель в вещественном представлении и квантованная модель различной разрядности.
- **Действия:**
 1. Запуск инференса для каждой разрядности в режимах CPU/NEON и AMX.
 2. Сбор метрик времени выполнения для каждого слоя.
 3. Сравнение времени выполнения для каждого режима.
- **Ожидаемый результат:** Формирование отчета с данными по времени исполнения.
- **Критерий успешности:** Программный замер производительности работает корректно; данные протоколируемы и воспроизводимы.




Рис. 1. Сравнение времени выполнения CPU Conv2d, NEON im2col и AMX Conv2d

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 51 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата




Рис. 2. Сравнение времени выполнения матричного умножения CPU/NEON и AMX

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 51 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

СПИСОК ИСПОЛЬЗУЕМОЙ ЛИТЕРАТУРЫ

1. ГОСТ 19.101-77: Виды программ и программных документов. // Единая система программной документации. – М.: ИПК Издательство стандартов, 2001.
2. ГОСТ 19.102-77: Стадии разработки. // Единая система программной документации. – М.: ИПК Издательство стандартов, 2001.
3. ГОСТ 19.103-77: Обозначения программ и программных документов. // Единая система программной документации. – М.: ИПК Издательство стандартов, 2001.
4. ГОСТ 19.104-78: Основные надписи. // Единая система программной документации. – М.: ИПК Издательство стандартов, 2001.
5. ГОСТ 19.105-78: Общие требования к программным документам. // Единая система программной документации. – М.: ИПК Издательство стандартов, 2001.
6. ГОСТ 19.106-78: Требования к программным документам, выполненным печатным способом. // Единая система программной документации. – М.: ИПК Издательство стандартов, 2001.
7. ГОСТ 19.201-78: Техническое задание. Требования к содержанию и оформлению. // Единая система программной документации. – М.: ИПК Издательство стандартов, 2001.
8. ГОСТ 19.301-79: Программа и методика испытаний. Требования к содержанию и оформлению. // Единая система программной документации. – М.: ИПК Издательство стандартов, 2001.
9. ГОСТ 19.401-78: Текст программы. Требования к содержанию и оформлению. // Единая система программной документации. – М.: ИПК Издательство стандартов, 2001.
10. ГОСТ 19.404-79: Пояснительная записка. Требования к содержанию и оформлению. // Единая система программной документации. – М.: ИПК Издательство стандартов, 2001.
11. ГОСТ 19.505-79: Руководство оператора. Требования к содержанию и оформлению. // Единая система программной документации. – М.: ИПК Издательство стандартов, 2001.
12. ГОСТ 19.603-78: Общие правила внесения изменений. // Единая система программной документации. – М.: ИПК Издательство стандартов, 2001.
13. ГОСТ 19.604-78: Правила внесения изменений в программные документы, выполненные печатным способом. // Единая система программной документации. – М.: ИПК Издательство стандартов, 2001.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 51 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

ЛИСТ РЕГИСТРАЦИИ ИЗМЕНЕНИЙ

[illegible]