

Промежуточный отчет по программному проекту

1. Основные планы и этапы проекта

1.1 Краткое описание проекта:

«Быстрая реализация вещественных и квантованных сверточных нейронных сетей на мобильных устройствах Apple» – программный проект по созданию высокопроизводительной реализации сверточных нейронных сетей на устройствах Apple Silicon. В рамках работы сравниваются CPU- и AMX-исполнения, поддерживаются вещественные и квантованные представления различной разрядности, а целевой архитектурой выступает VGG-уровень для задач компьютерного зрения.

Название проекта:

«Быстрая реализация вещественных и квантованных сверточных нейронных сетей на мобильных устройствах Apple»

Цель проекта:

Разработать реализацию основных операций слоёв сверточных нейронных моделей на мобильных устройствах Apple.

Краткое описание задач:

1. Разработка технического задания и определение требований к программе.
2. Реализация основных операций слоёв сверточной нейронной сети.
3. Реализация вычислений в двух режимах: AMX/Accelerate и CPU (ARM NEON), с поддержкой вещественного и квантованного исполнения различной разрядности.
4. Проведение измерений производительности и сравнение результатов по метрикам времени и точности.
5. Подготовка программной документации, проведение испытаний и защита проекта.

1.2 Планы и этапы выполнения проекта

Этап проекта	Описание работ	Ожидаемые результаты	Сроки выполнения
Обоснование необходимости разработки	Постановка задачи и сбор исходных теоретических материалов	Поставлены задачи и собрана литература и источники для теоретического решения задач	22.11.25
Научно-исследовательский этап разработки	Определение структуры входных и выходных данных; Предварительный выбор методов решения задач; Определение требований к техническим и программным средствам; Обоснование возможности решения поставленной задачи	Определение требований для решения задачи	22.11.25 – 15.12.25

Этап проекта	Описание работ	Ожидаемые результаты	Сроки выполнения
Разработка и утверждение технического задания	Определение требований к программному продукту; Выбор языков программирования; Разработка и согласование технического задания с научным руководителем; Загрузка согласованного технического задания в SmartLMS	Готовое техническое задание для начала разработки программы	22.11.25 – 15.12.25
Разработка программы	Предварительная разработка структуры программы; Программирование и отладка программы	Готовая программа, реализующая все функции, определенные в техническом задании	16.12.25 – 03.04.25
Разработка программной документации	Разработка документов в соответствии с требованиями ГОСТ 19 ЕСПД (Единой системы программной документации)	Готовая программная документация	04.04.25 – 07.04.25
Испытания программы	Разработка, согласование и утверждение порядка в методики испытаний; Проведение испытаний программы в соответствии с утвержденными порядком и методикой; Корректировка программы и программной документации по результатам испытаний;	Тестирование программы и исправление недочетов	08.04.25 – 21.04.25
Подготовка и передача программы	Подготовка программы и программной документации для презентации и защиты; Представление разработанного программного продукта научному руководителю и получение отзыва; Загрузка Пояснительной записки в систему Антиплагиат через ЛМС НИУ ВШЭ; Загрузка материалов курсового проекта в ЛМС, дисциплина «Курсовой проект, 2 курс, ПИ»; Защита программного продукта комиссии	Получение готового продукта, реализующего все функции, и защита работы	22.04.25 – 03.05.25

2. Используемый технологический стек и его обоснование

2.1 Перечень используемых технологий

Технология/Инструмент	Описание	Причины выбора
C++	Язык программирования для реализации высокопроизводительных вычислений и низкоуровневой оптимизации	Позволяет реализовать вычислительные ядра сверточных нейронных сетей с контролем памяти и производительности
Accelerate	Фреймворк для высокопроизводительных вычислений на платформах Apple	Используется для реализации ускоренных операций и сравнения с CPU-вычислениями
ARM NEON	SIMD-векторизация для CPU-реализации на архитектуре ARM	Нужна для оптимизированной базовой реализации и резервного режима при недоступности ускорения
macOS + Apple Silicon	Целевая платформа исполнения	Обеспечивает доступ к Accelerate и сопроцессору Apple Matrix на совместимом оборудовании
Git	Управление версиями	Удобство разработки в команде, сохранение версий разработки

2.2 Обоснование выбранного технологического стека

Выбор языка **C++** и фреймворка **Accelerate** для реализации вычислительных компонентов сверточных нейронных сетей обусловлен требованиями к производительности и возможностью задействовать аппаратное ускорение на платформах Apple.

1. Производительность и контроль: C++ подходит для реализации вычислительных ядер с эффективным управлением памятью и минимальными накладными расходами.
2. Аппаратное ускорение: Accelerate предоставляет оптимизированные реализации матричных операций и свёрток, позволяя использовать вычислительные блоки Apple Matrix там, где это возможно.
3. Сравнимость реализаций: наличие CPU-варианта с оптимизацией через ARM NEON позволяет корректно сравнивать ускоренный путь с базовым исполнением и обеспечивать резервный режим вычислений.
4. Целевая платформа: использование macOS на Apple Silicon гарантирует совместимость с Accelerate и воспроизводимость измерений.

Git используется, так как:

1. Контроль версий: Git позволяет отслеживать изменения в проекте, что помогает разработчикам работать с различными версиями программы.

2. Удобство командной работы: Git упрощает взаимодействие между членами команды, особенно при параллельной разработке функций.
3. Безопасность данных: Все изменения сохраняются, что позволяет откатиться к предыдущим версиям при необходимости.

3. Критерии оценивания проекта

Критерий	Описание
Функциональность – Процент выполнения функциональных требований	Выполненные требования в процентах от общего количества
Функциональность – Количество реализованных функций	Абсолютное количество функций, которые работают правильно
Документация и оформление – Полнота документации (%)	Процент от требуемого объема документации
Соблюдение сроков и плана – Процент выполнения работы в срок (%)	Процент задач, выполненных в срок
Соблюдение сроков и плана – Количество дней отклонения от плана	Общее число дней отклонения от плана
Использование технологического стека - Процент использования функциональности стека (%)	Процент использования функциональности выбранного стека технологий
Оценка командной работы – Среднее время коммуникации (в часах)	Среднее время, потраченное на обсуждение задач и решение вопросов
Оценка командной работы – Количество завершенных задач на каждого участника	Общее число задач, выполненных каждым членом команды