

**ПРАВИТЕЛЬСТВО РОССИЙСКОЙ ФЕДЕРАЦИИ  
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ  
ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ  
НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ  
"ВЫСШАЯ ШКОЛА ЭКОНОМИКИ"**

Факультет компьютерных наук  
Образовательная программа "Программная инженерия"

**СОГЛАСОВАНО**

Научный руководитель, научный  
сотрудник ФИЦ ИУ РАН

\_\_\_\_\_ Е. Е. Лимонова  
«\_\_» \_\_\_\_\_ 2026 г.

**УТВЕРЖДЕНО**

Академический руководитель  
образовательной программы  
"Программная инженерия", старший  
преподаватель Департамента  
программной инженерии

\_\_\_\_\_ Н. А. Павлов  
«\_\_» \_\_\_\_\_ 2026 г.

**Руководство оператора**

**ЛИСТ УТВЕРЖДЕНИЯ**

**RU.17701729.04.06 34 01-1-ЛУ**

Исполнители:

Студент группы БПИ241

\_\_\_\_\_ / А. Д. Ергучев /  
«\_\_» \_\_\_\_\_ 2026 г.

Студент группы БПИ241

\_\_\_\_\_ / Г. А. Суханов /  
«\_\_» \_\_\_\_\_ 2026 г.

|            |              |             |             |              |
|------------|--------------|-------------|-------------|--------------|
| Инд.№ подп | Подп. и дата | Взам. инв.№ | Инд.№ дубл. | Подп. и дата |
|            |              |             |             |              |

УТВЕРЖДЕН

RU.17701729.04.06 34 01-1-ЛЮ

|            |              |             |             |              |
|------------|--------------|-------------|-------------|--------------|
| Инв.№ подп | Подп. и дата | Взам. инв.№ | Инв.№ дубл. | Подп. и дата |
|            |              |             |             |              |

**Руководство оператора**  
**RU.17701729.04.06 34 01-1**

**Листов 9**

## АННОТАЦИЯ

|                           |              |              |              |              |
|---------------------------|--------------|--------------|--------------|--------------|
|                           |              |              |              |              |
| Изм.                      | Лист         | № докум.     | Подп.        | Дата         |
| RU.17701729.04.06 34 01-1 |              |              |              |              |
| Инв. № подл.              | Подп. и дата | Взам. Инв. № | Инв. № дубл. | Подп. и дата |

## СОДЕРЖАНИЕ

|                                                     |   |
|-----------------------------------------------------|---|
| 1. НАЗНАЧЕНИЕ ПРОГРАММЫ .....                       | 4 |
| 1.1. Функциональное назначение .....                | 4 |
| 1.2. Эксплуатационное назначение .....              | 4 |
| 2. УСЛОВИЯ ВЫПОЛНЕНИЯ ПРОГРАММЫ .....               | 5 |
| 2.1. Минимальный состав аппаратных средств .....    | 5 |
| 2.2. Минимальный состав программных средств .....   | 5 |
| 2.3. Требования к персоналу (пользователю) .....    | 5 |
| 3. Выполнение программы .....                       | 6 |
| 3.1. Установка программы .....                      | 6 |
| 3.2. Запуск программы и работа с приложением .....  | 6 |
| 3.2.1. Проверка матричного умножения .....          | 6 |
| 3.2.2. Запуск инференса сети LeNet .....            | 6 |
| 3.2.3. Проведение бенчмаркинга .....                | 6 |
| 3.2.4. Конвертация весов модели .....               | 7 |
| 3.2.5. Работа с квантованными представлениями ..... | 7 |
| СООБЩЕНИЯ ОПЕРАТОРУ .....                           | 8 |
| Тексты сообщений оператору .....                    | 8 |
| Действия оператора в исключительных ситуациях ..... | 8 |

|                           |              |              |              |              |
|---------------------------|--------------|--------------|--------------|--------------|
|                           |              |              |              |              |
| Изм.                      | Лист         | № докум.     | Подп.        | Дата         |
| RU.17701729.04.06 34 01-1 |              |              |              |              |
| Инв. № подл.              | Подп. и дата | Взам. Инв. № | Инв. № дубл. | Подп. и дата |

## 1. НАЗНАЧЕНИЕ ПРОГРАММЫ

### 1.1. Функциональное назначение

Программа «» предназначена для выполнения прямого прохода сверточных нейронных сетей на устройствах Apple Silicon с возможностью выбора CPU/NEON- и AMX/Accelerate-режимов исполнения.

В рамках функционального назначения программа обеспечивает:

- управление тензорами и их описаниями;
- операции матричного умножения и преобразование im2col;
- CPU/NEON-эталон и AMX/Accelerate-путь исполнения;
- стандартные слои CNN: Conv2D, Linear, ReLU, Softmax, AvgPool2D, Flatten;
- загрузку весов модели из JSON;
- вещественные и квантованные режимы вычислений;
- тесты корректности и бенчмарки производительности.

### 1.2. Эксплуатационное назначение

Программный проект по созданию высокопроизводительной реализации сверточных нейронных сетей на устройствах Apple Silicon. В рамках работы сравниваются CPU- и AMX-исполнения, поддерживаются вещественные и квантованные представления различной разрядности, а целевой архитектурой выступает VGG-уровень для задач компьютерного зрения.

Основными пользователями программы являются разработчики программного обеспечения и инженеры по машинному обучению, интегрирующие локальный инференс моделей компьютерного зрения в приложения iOS/macOS.

В эксплуатационном режиме программа используется как вычислительный бэкенд. Пользователь интегрирует заголовочные файлы библиотеки в C++ проект или запускает поставляемые тестовые и бенчмарк-приложения для проверки корректности и оценки производительности.

|                           |              |              |              |              |
|---------------------------|--------------|--------------|--------------|--------------|
|                           |              |              |              |              |
| Изм.                      | Лист         | № докум.     | Подп.        | Дата         |
| RU.17701729.04.06 34 01-1 |              |              |              |              |
| Инв. № подл.              | Подп. и дата | Взам. Инв. № | Инв. № дубл. | Подп. и дата |

## 2. УСЛОВИЯ ВЫПОЛНЕНИЯ ПРОГРАММЫ

### 2.1. Минимальный состав аппаратных средств

Для обеспечения корректного функционирования программы и достижения заявленной производительности требуются следующие аппаратные средства:

1. Устройство или компьютер на базе Apple Silicon (серии M или A).
2. Поддержка ARM64 и инструкций NEON.
3. Наличие аппаратного механизма AMX для ускоренного пути исполнения.
4. Оперативная память, достаточная для хранения весов модели и промежуточных тензоров.
5. Свободное место на накопителе для весов модели в формате JSON и тестовых изображений.

### 2.2. Минимальный состав программных средств

Для сборки, запуска и эксплуатации программы необходимо наличие следующих программных средств:

1. macOS или iOS, совместимая с целевой архитектурой Apple Silicon.
2. Xcode с компилятором Clang и поддержкой C++17 или выше.
3. CMake или иной используемый в проекте инструмент сборки.
4. Apple Accelerate Framework.
5. Python 3 для запуска вспомогательного скрипта pt2json.py.

### 2.3. Требования к персоналу (пользователю)

Пользователем программы является разработчик или инженер по машинному обучению, интегрирующий библиотеку в конечное приложение или выполняющий проверку ее работы. К пользователю предъявляются следующие требования: владение C++ на уровне интеграции API, понимание базовых принципов CNN, тензоров, свертки, матричного умножения и квантования, а также навыки работы с терминалом, Xcode и инструментами сборки.

|                           |              |              |              |              |
|---------------------------|--------------|--------------|--------------|--------------|
|                           |              |              |              |              |
| Изм.                      | Лист         | № докум.     | Подп.        | Дата         |
| RU.17701729.04.06 34 01-1 |              |              |              |              |
| Инв. № подл.              | Подп. и дата | Взам. Инв. № | Инв. № дубл. | Подп. и дата |

### 3. Выполнение программы

#### 3.1. Установка программы

Для установки и развертывания программы необходимо подготовить устройство Apple Silicon с установленным Xcode, клонировать исходный код проекта, выполнить сборку через CMake или Xcode и убедиться, что при линковке доступен фреймворк Accelerate.

Общий порядок установки:

1. Клонировать репозиторий проекта.
2. Установить Xcode и инструменты командной строки.
3. Подготовить Python 3 для запуска scripts/pt2json.py.
4. Собрать библиотеку и исполняемые файлы тестов/бенчмарков.
5. Разместить веса mnist\_lenet.json и тестовые изображения в ожидаемых директориях проекта.

#### 3.2. Запуск программы и работа с приложением

Поскольку программный продукт является API-библиотекой, основное взаимодействие с ним выполняется через C++ код, использующий заголовочные файлы библиотеки, либо через готовые исполняемые файлы тестов и бенчмарков.

##### 3.2.1. Проверка матричного умножения

Данный сценарий используется для проверки корректности тензорного ядра.

Действия оператора:

1. Создать два тензора с размерностями, совместимыми для матричного умножения.
2. Выполнить операцию матричного умножения через общий интерфейс библиотеки.
3. Сравнить результаты CPU/NEON-эталоны и AMX/Accelerate-исполнения.

Ожидаемый результат: результаты ускоренного исполнения должны совпадать с CPU/NEON-эталоном в пределах заданной численной погрешности. При несовместимости размерностей программа должна выдать диагностическое сообщение.

##### 3.2.2. Запуск инференса сети LeNet

Данный сценарий используется для проверки полного прямого прохода нейронной сети.

Действия оператора:

1. Загрузить веса из tests/weights/mnist\_lenet.json.
2. Инициализировать модель LeNet.
3. Передать входное изображение в виде тензора.
4. Выполнить прямой проход модели.

Ожидаемый результат: на выходе формируется тензор вероятностей классов после Softmax.

##### 3.2.3. Проведение бенчмаркинга

Данный сценарий используется для измерения производительности путей исполнения.

Действия оператора:

1. Запустить исполняемый файл бенчмарков.
2. Зафиксировать параметры эксперимента: размер матриц или входного тензора, тип данных, режим вычислений.

|                           |              |              |              |              |
|---------------------------|--------------|--------------|--------------|--------------|
|                           |              |              |              |              |
| Изм.                      | Лист         | № докум.     | Подп.        | Дата         |
| RU.17701729.04.06 34 01-1 |              |              |              |              |
| Инв. № подл.              | Подп. и дата | Взам. Инв. № | Инв. № дубл. | Подп. и дата |

3. Сохранить результаты измерений для последующего анализа.

Ожидаемый результат: программа выводит среднее время выполнения, пропускную способность и ускорение AMX-исполнения относительно CPU/NEON.

#### **3.2.4. Конвертация весов модели**

Данный сценарий используется для подготовки входных данных модели. Оператор запускает скрипт pt2json.py, передает на вход файл модели PyTorch и получает JSON-файл, совместимый с модулем сериализации библиотеки.

#### **3.2.5. Работа с квантованными представлениями**

Данный сценарий используется для проверки режима пониженной разрядности. Оператор выбирает соответствующий тип данных и параметры масштабирования при инициализации модели. Результат сравнивается с вещественной реализацией и CPU/NEON-эталоном в пределах допустимой погрешности.

|                           |              |              |              |              |
|---------------------------|--------------|--------------|--------------|--------------|
|                           |              |              |              |              |
| Изм.                      | Лист         | № докум.     | Подп.        | Дата         |
| RU.17701729.04.06 34 01-1 |              |              |              |              |
| Инв. № подл.              | Подп. и дата | Взам. Инв. № | Инв. № дубл. | Подп. и дата |

## СООБЩЕНИЯ ОПЕРАТОРУ

### 3.2.5 Тексты сообщений оператору

Поскольку программный продукт представляет собой библиотеку API, взаимодействие с оператором осуществляется через исключения C++, коды возврата тестовых программ и диагностические сообщения в стандартном потоке ошибок.

| Категория             | Содержание сообщения                                                                         | Действие оператора                                           |
|-----------------------|----------------------------------------------------------------------------------------------|--------------------------------------------------------------|
| Ошибка входных данных | Файл весов или входное изображение не найдено, повреждено или имеет неподдерживаемый формат. | Проверить путь и формат файла.                               |
| Ошибка размерностей   | Формы тензоров несовместимы для matmul, conv2d, flatten или linear.                          | Проверить параметры слоя и форму входного тензора.           |
| Ошибка типа данных    | Выбранный dtype или разрядность квантования не поддерживается текущим путем исполнения.      | Выбрать поддерживаемый dtype или резервный режим.            |
| Ошибка AMX            | Ускоренный путь недоступен или завершился ошибкой.                                           | Переключиться на CPU/NEON и зафиксировать параметры запуска. |
| Ошибка точности       | Отклонение результата AMX или квантованного режима превышает допустимый порог.               | Проверить масштабирование, dtype и целостность весов.        |
| Результаты бенчмарка  | Выведены latency, throughput и параметры эксперимента.                                       | Сохранить вывод для отчета.                                  |

Таблица 1. Основные категории сообщений оператору

### 3.2.5 Действия оператора в исключительных ситуациях

В случае возникновения исключительных ситуаций оператору рекомендуется выполнить следующие действия:

- при ошибках загрузки проверить наличие JSON-файла весов и тестовых изображений;
- при ошибках размерностей сверить архитектуру сети, параметры im2col, размер ядра, stride, padding и число каналов;
- при сбоях AMX повторить запуск в CPU/NEON-режиме и зафиксировать параметры эксперимента;
- при низкой точности квантованного режима проверить параметры масштабирования и сравнить результат с вещественной реализацией.

|                           |              |              |              |              |
|---------------------------|--------------|--------------|--------------|--------------|
|                           |              |              |              |              |
| Изм.                      | Лист         | № докум.     | Подп.        | Дата         |
| RU.17701729.04.06 34 01-1 |              |              |              |              |
| Инв. № подл.              | Подп. и дата | Взам. Инв. № | Инв. № дубл. | Подп. и дата |

## ЛИСТ РЕГИСТРАЦИИ ИЗМЕНЕНИЙ

[illegible]