

**ПРАВИТЕЛЬСТВО РОССИЙСКОЙ ФЕДЕРАЦИИ
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ
ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ
"ВЫСШАЯ ШКОЛА ЭКОНОМИКИ"**

Факультет компьютерных наук
Образовательная программа "Программная инженерия"

СОГЛАСОВАНО

Научный руководитель, научный
сотрудник ФИЦ ИУ РАН

_____ Е. Е. Лимонова

«__» _____ 2026 г.

УТВЕРЖДЕНО

Академический руководитель
образовательной программы
"Программная инженерия", старший
преподаватель Департамента
программной инженерии

_____ Н. А. Павлов

«__» _____ 2026 г.

**БЫСТРАЯ РЕАЛИЗАЦИЯ ВЕЩЕСТВЕННЫХ И КВАНТОВАННЫХ
СВЕРТОЧНЫХ НЕЙРОННЫХ СЕТЕЙ НА МОБИЛЬНЫХ УСТРОЙСТВАХ
APPLE**

Руководство оператора

ЛИСТ УТВЕРЖДЕНИЯ

RU.17701729.04.06 34 01-1-ЛУ

Исполнители:

Студент группы БПИ241

_____ / А. Д. Ергучев /

«__» _____ 2026 г.

Студент группы БПИ241

_____ / Г. А. Суханов /

«__» _____ 2026 г.

Инд.№ подп	Подп. и дата	Взам. инв.№	Инд.№ дубл.	Подп. и дата

УТВЕРЖДЕН

RU.17701729.04.06 34 01-1-ЛЮ

**БЫСТРАЯ РЕАЛИЗАЦИЯ ВЕЩЕСТВЕННЫХ И КВАНТОВАННЫХ
СВЕРТОЧНЫХ НЕЙРОННЫХ СЕТЕЙ НА МОБИЛЬНЫХ УСТРОЙСТВАХ
APPLE**

Руководство оператора

RU.17701729.04.06 34 01-1

Листов 9

Инов.№ подп	Подп. и дата	Взам. инв.№	Инов.№ дубл.	Подп. и дата

АННОТАЦИЯ

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 34 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

СОДЕРЖАНИЕ

1. НАЗНАЧЕНИЕ ПРОГРАММЫ	4
1.1. Функциональное назначение	4
1.2. Эксплуатационное назначение	4
2. УСЛОВИЯ ВЫПОЛНЕНИЯ ПРОГРАММЫ	5
2.1. Минимальный состав аппаратных средств	5
2.2. Минимальный состав программных средств	5
2.3. Требования к персоналу (пользователю)	5
3. Выполнение программы	6
3.1. Установка программы	6
3.2. Запуск программы и работа с приложением	6
3.2.1. Проверка матричного умножения	6
3.2.2. Запуск инференса сети LeNet	6
3.2.3. Проведение бенчмаркинга	6
3.2.4. Конвертация весов модели	7
3.2.5. Работа с квантованными представлениями	7
СООБЩЕНИЯ ОПЕРАТОРУ	8
Тексты сообщений оператору	8
Действия оператора в исключительных ситуациях	8

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 34 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

1. НАЗНАЧЕНИЕ ПРОГРАММЫ

1.1. Функциональное назначение

Программа «Быстрая реализация вещественных и квантованных сверточных нейронных сетей на мобильных устройствах Apple» предназначена для выполнения прямого прохода сверточных нейронных сетей на устройствах Apple Silicon с возможностью выбора CPU/NEON- и AMX/Accelerate-режимов исполнения.

В рамках функционального назначения программа обеспечивает:

- управление тензорами и их описаниями;
- операции матричного умножения и преобразование im2col;
- CPU/NEON-эталон и AMX/Accelerate-путь исполнения;
- стандартные слои CNN: Conv2D, Linear, ReLU, Softmax, AvgPool2D, Flatten;
- загрузку весов модели из JSON;
- вещественные и квантованные режимы вычислений;
- тесты корректности и бенчмарки производительности.

1.2. Эксплуатационное назначение

Программный проект по созданию высокопроизводительной реализации сверточных нейронных сетей на устройствах Apple Silicon. В рамках работы сравниваются CPU/NEON- и AMX-исполнения, поддерживаются вещественные и квантованные представления различной разрядности, а целевой архитектурой выступает VGG-уровень для задач компьютерного зрения.

Основными пользователями программы являются разработчики программного обеспечения и инженеры по машинному обучению, интегрирующие локальный инференс моделей компьютерного зрения в приложения iOS/macOS.

В эксплуатационном режиме программа используется как вычислительный бэкенд. Пользователь интегрирует заголовочные файлы библиотеки в C++ проект или запускает поставляемые тестовые и бенчмарк-приложения для проверки корректности и оценки производительности.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 34 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

2. УСЛОВИЯ ВЫПОЛНЕНИЯ ПРОГРАММЫ

2.1. Минимальный состав аппаратных средств

Для обеспечения корректного функционирования программы и достижения заявленной производительности требуются следующие аппаратные средства:

1. Устройство или компьютер на базе Apple Silicon (серии M или A).
2. Поддержка ARM64 и инструкций NEON.
3. Наличие аппаратного механизма AMX для ускоренного пути исполнения.
4. Оперативная память, достаточная для хранения весов модели и промежуточных тензоров.
5. Свободное место на накопителе для весов модели в формате JSON и тестовых изображений.

2.2. Минимальный состав программных средств

Для сборки, запуска и эксплуатации программы необходимо наличие следующих программных средств:

1. macOS или iOS, совместимая с целевой архитектурой Apple Silicon.
2. Xcode с компилятором Clang и поддержкой C++17 или выше.
3. CMake или иной используемый в проекте инструмент сборки.
4. Apple Accelerate Framework.
5. Python 3 для запуска вспомогательного скрипта pt2json.py.

2.3. Требования к персоналу (пользователю)

Пользователем программы является разработчик или инженер по машинному обучению, интегрирующий библиотеку в конечное приложение или выполняющий проверку ее работы. К пользователю предъявляются следующие требования: владение C++ на уровне интеграции API, понимание базовых принципов CNN, тензоров, свертки, матричного умножения и квантования, а также навыки работы с терминалом, Xcode и инструментами сборки.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 34 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

3. Выполнение программы

3.1. Установка программы

Для установки и развертывания программы Быстрая реализация вещественных и квантованных сверточных нейронных сетей на мобильных устройствах Apple необходимо подготовить устройство Apple Silicon с установленным Xcode, клонировать исходный код проекта, выполнить сборку через CMake или Xcode и убедиться, что при линковке доступен фреймворк Accelerate.

Общий порядок установки:

1. Клонировать репозиторий проекта.
2. Установить Xcode и инструменты командной строки.
3. Подготовить Python 3 для запуска scripts/pt2json.py.
4. Собрать библиотеку и исполняемые файлы тестов/бенчмарков.
5. Разместить веса mnist_lenet.json и тестовые изображения в ожидаемых директориях проекта.

3.2. Запуск программы и работа с приложением

Поскольку программный продукт является API-библиотекой, основное взаимодействие с ним выполняется через C++ код, использующий заголовочные файлы библиотеки, либо через готовые исполняемые файлы тестов и бенчмарков.

3.2.1. Проверка матричного умножения

Данный сценарий используется для проверки корректности тензорного ядра.

Действия оператора:

1. Создать два тензора с размерностями, совместимыми для матричного умножения.
2. Выполнить операцию матричного умножения через общий интерфейс библиотеки.
3. Сравнить результаты CPU/NEON-эталона и AMX/Accelerate-исполнения.

Ожидаемый результат: результаты ускоренного исполнения должны совпадать с CPU/NEON-эталоном в пределах заданной численной погрешности. При несовместимости размерностей программа должна выдать диагностическое сообщение.

3.2.2. Запуск инференса сети LeNet

Данный сценарий используется для проверки полного прямого прохода нейронной сети.

Действия оператора:

1. Загрузить веса из tests/weights/mnist_lenet.json.
2. Инициализировать модель LeNet.
3. Передать входное изображение в виде тензора.
4. Выполнить прямой проход модели.

Ожидаемый результат: на выходе формируется тензор вероятностей классов после Softmax.

3.2.3. Проведение бенчмаркинга

Данный сценарий используется для измерения производительности путей исполнения.

Действия оператора:

1. Запустить исполняемый файл бенчмарков.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 34 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

2. Зафиксировать параметры эксперимента: размер матриц или входного тензора, тип данных, режим вычислений.
3. Сохранить результаты измерений для последующего анализа.

Ожидаемый результат: программа выводит среднее время выполнения, пропускную способность и ускорение AMX-исполнения относительно CPU/NEON.

3.2.4. Конвертация весов модели

Данный сценарий используется для подготовки входных данных модели. Оператор запускает скрипт pt2json.py, передает на вход файл модели PyTorch и получает JSON-файл, совместимый с модулем сериализации библиотеки.

3.2.5. Работа с квантованными представлениями

Данный сценарий используется для проверки режима пониженной разрядности. Оператор выбирает соответствующий тип данных и параметры масштабирования при инициализации модели. Результат сравнивается с вещественной реализацией и CPU/NEON-эталоном в пределах допустимой погрешности.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 34 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

СООБЩЕНИЯ ОПЕРАТОРУ

3.2.5 Тексты сообщений оператору

Поскольку программный продукт представляет собой библиотеку API, взаимодействие с оператором осуществляется через исключения C++, коды возврата тестовых программ и диагностические сообщения в стандартном потоке ошибок.

Категория	Содержание сообщения	Действие оператора
Ошибка входных данных	Файл весов или входное изображение не найдено, повреждено или имеет неподдерживаемый формат.	Проверить путь и формат файла.
Ошибка размерностей	Формы тензоров несовместимы для matmul, conv2d, flatten или linear.	Проверить параметры слоя и форму входного тензора.
Ошибка типа данных	Выбранный dtype или разрядность квантования не поддерживается текущим путем исполнения.	Выбрать поддерживаемый dtype или резервный режим.
Ошибка AMX	Ускоренный путь недоступен или завершился ошибкой.	Переключиться на CPU/NEON и зафиксировать параметры запуска.
Ошибка точности	Отклонение результата AMX или квантованного режима превышает допустимый порог.	Проверить масштабирование, dtype и целостность весов.
Результаты бенчмарка	Выведены latency, throughput и параметры эксперимента.	Сохранить вывод для отчета.

Таблица 1. Основные категории сообщений оператору

3.2.5 Действия оператора в исключительных ситуациях

В случае возникновения исключительных ситуаций оператору рекомендуется выполнить следующие действия:

- при ошибках загрузки проверить наличие JSON-файла весов и тестовых изображений;
- при ошибках размерностей сверить архитектуру сети, параметры im2col, размер ядра, stride, padding и число каналов;
- при сбоях AMX повторить запуск в CPU/NEON-режиме и зафиксировать параметры эксперимента;
- при низкой точности квантованного режима проверить параметры масштабирования и сравнить результат с вещественной реализацией.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 34 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

ЛИСТ РЕГИСТРАЦИИ ИЗМЕНЕНИЙ

[illegible]