

**ПРАВИТЕЛЬСТВО РОССИЙСКОЙ ФЕДЕРАЦИИ
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ
ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ
"ВЫСШАЯ ШКОЛА ЭКОНОМИКИ"**

Факультет компьютерных наук
Образовательная программа "Программная инженерия"

СОГЛАСОВАНО

Научный руководитель, научный
сотрудник ФИЦ ИУ РАН

_____ Е. Е. Лимонова
«__» _____ 2026 г.

УТВЕРЖДЕНО

Академический руководитель
образовательной программы
"Программная инженерия", старший
преподаватель Департамента
программной инженерии

_____ Н. А. Павлочев
«__» _____ 2026 г.

**БЫСТРАЯ РЕАЛИЗАЦИЯ ВЕЩЕСТВЕННЫХ И КВАНТОВАННЫХ
СВЕРТОЧНЫХ НЕЙРОННЫХ СЕТЕЙ НА МОБИЛЬНЫХ УСТРОЙСТВАХ
APPLE**

Пояснительная записка

ЛИСТ УТВЕРЖДЕНИЯ

RU.17701729.04.06 81 01-1-ЛУ

Исполнители:

Студент группы БПИ241

_____ / Г. А. Суханов /

«__» _____ 2026 г.

Инд.№ подп	Подп. и дата	Взам. инв.№	Инд.№ дубл.	Подп. и дата

УТВЕРЖДЕН

RU.17701729.04.06 81 01-1-ЛЮ

**БЫСТРАЯ РЕАЛИЗАЦИЯ ВЕЩЕСТВЕННЫХ И КВАНТОВАННЫХ
СВЕРТОЧНЫХ НЕЙРОННЫХ СЕТЕЙ НА МОБИЛЬНЫХ УСТРОЙСТВАХ
APPLE**

Пояснительная записка

RU.17701729.04.06 81 01-1

Листов 19

Инов.№ подп	Подп. и дата	Взам. инв.№	Инов.№ дубл.	Подп. и дата

АННОТАЦИЯ

Данный программный документ представляет собой пояснительную записку к программному проекту «Быстрая реализация вещественных и квантованных сверточных нейронных сетей на мобильных устройствах Apple» содержит следующие разделы: «Введение», «Назначение и область применения», «Технические характеристики», «Ожидаемые технико-экономические показатели», приложения.

Раздел «Введение» включает в себя наименование программы и документ, на основании которого ведётся разработка, с указанием организации, утвердившей данный документ.

В разделе «Назначение и область применения» содержатся функциональное и эксплуатационное назначение программы и краткая характеристика области её применения.

В разделе «Назначение разработки» указано функциональное и эксплуатационное назначение создаваемого программного продукта.

В разделе «Технические характеристики» присутствуют следующие подразделы: постановка задачи на разработку программы, описание функционирования программы, описание и обоснование алгоритма работы программы, описание и обоснование выбора метода организации входных и выходных данных, описание работы с базой данных, описание и обоснование выбора состава технических и программных средств.

Раздел «Требования к программным документам» содержит указание на предварительный состав программной документации и специальные требования к ней.

В разделе «Ожидаемые технико-экономические показатели» указана предполагаемая потребность и экономические преимущества разработки по сравнению с отечественными и зарубежными образцами или аналогами.

Настоящий документ разработан в соответствии с требованиями:

1. ГОСТ 19.101-77 [1]: Виды программ и программных документов.
2. ГОСТ 19.102-77 [2]: Стадии разработки.
3. ГОСТ 19.103-77 [3]: Обозначения программ и программных документов.
4. ГОСТ 19.104-78 [4]: Основные надписи.
5. ГОСТ 19.105-78 [5]: Общие требования к программным документам.
6. ГОСТ 19.106-78 [6]: Требования к программным документам, выполненным печатным способом.
7. ГОСТ 19.404-79 [10]: Пояснительная записка. Требования к содержанию и оформлению.

Изменения к данной Пояснительной записке оформляются согласно ГОСТ 19.603-78 [12], ГОСТ 19.604-78 [13].

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 81 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

СОДЕРЖАНИЕ

1. ВВЕДЕНИЕ	4
1.1. Наименование программы	4
1.2. Документ(ы), на основании которого(ых) ведется разработка	4
2. НАЗНАЧЕНИЕ РАЗРАБОТКИ	5
2.1. Функциональное назначение	5
2.2. Эксплуатационное назначение	5
2.3. Краткая характеристика области применения программы	5
3. ТЕХНИЧЕСКИЕ ХАРАКТЕРИСТИКИ	7
3.1. Постановка задачи на разработку программы	7
3.2. Описание и обоснование выбора состава технических и программных средств	7
3.2.1. Состав технических и программных средств	7
3.2.2. Обоснование выбора технических и программных средств	8
3.3. Описание и обоснование архитектуры программы	8
3.4. Особенности функционала	8
3.4.1. Модуль im2col и сверточные вычисления	8
3.4.2. Бэкенд CPU/NEON	9
3.4.3. Механизм квантования данных	9
3.4.4. Сценарий измерения производительности (Benchmarks)	9
3.5. Обоснование выбора метода организации входных и выходных данных	9
4. ОЖИДАЕМЫЕ ТЕХНИКО-ЭКОНОМИЧЕСКИЕ ПОКАЗАТЕЛИ	11
4.1. Ориентировочная экономическая эффективность	11
4.2. Предполагаемая потребность	11
4.3. Экономические преимущества разработки по сравнению с отечественными и зарубежными аналогами	11
ПРИЛОЖЕНИЕ 1. СПИСОК ИСПОЛЬЗУЕМОЙ ЛИТЕРАТУРЫ	13
ПРИЛОЖЕНИЕ 2. ССЫЛКИ НА АНАЛОГИ	14
ПРИЛОЖЕНИЕ 3. ТЕРМИНОЛОГИЯ	15
ПРИЛОЖЕНИЕ 4. ГРАФИК СРАВНЕНИЯ ПРОИЗВОДИТЕЛЬНОСТИ	17
ПРИЛОЖЕНИЕ 5. ПОКАЗАТЕЛИ ОЦЕНКИ ТОЧНОСТИ КВАНТОВАННЫХ МОДЕЛЕЙ	18

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 81 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

1. ВВЕДЕНИЕ

1.1. Наименование программы

Наименование программы – «Быстрая реализация вещественных и квантованных сверточных нейронных сетей на мобильных устройствах Apple».

Наименование программы на английском языке – «Fast Implementation of Floating-Point and Quantized Convolutional Neural Networks on Apple Mobile Devices».

1.2. Документ(ы), на основании которого(ых) ведется разработка

Разработка ведется на основании учебного плана подготовки бакалавров по направлению 09.03.04 «Программная инженерия» и утвержденной академическим руководителем программы темы курсового проекта.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 81 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

2. НАЗНАЧЕНИЕ РАЗРАБОТКИ

2.1. Функциональное назначение

Разрабатываемая программа представляет собой специализированную библиотеку (API) для высокопроизводительного выполнения прямого прохода (inference) сверточных нейронных сетей на устройствах с архитектурой Apple Silicon. Программный комплекс предназначен для решения задач компьютерного зрения на уровне архитектур типа VGG.

Основное функциональное назначение программы заключается в обеспечении эффективного вычисления сверточных слоев и полносвязных слоев нейронной сети за счет реализации следующих возможностей:

- выполнение преобразования им-ту-кол (im2col), позволяющего свести операцию свертки к умножению матриц (GEMM) с учетом параметров ядра, шага (stride), отступов (padding) и количества каналов входного тензора;
- поддержка различных режимов вычислений: высокопроизводительного исполнения на специализированном ускорителе AMX и эталонного/резервного исполнения на CPU с использованием векторных инструкций NEON;
- поддержка вещественных вычислений и квантованных представлений данных различной разрядности, включая подготовку параметров масштабирования, согласованных с моделью, для снижения нагрузки на память и увеличения скорости обработки;
- обеспечение работы базовых слоев нейронной сети, включая сверточные слои (Conv2D), слои пулинга (AvgPool2D), функции активации (ReLU), слои выравнивания (Flatten), полносвязные слои (Linear) и функцию Softmax;
- предоставление инструментов для измерения производительности (бенчмарков), позволяющих сравнивать время выполнения операций в разных режимах (CPU vs AMX) с фиксацией параметров эксперимента: размера входа, типа данных, разрядности и размера пакета.

2.2. Эксплуатационное назначение

Программный продукт предназначен для разработчиков систем машинного зрения и инженеров по оптимизации нейронных сетей, создающих приложения для мобильных устройств Apple. Библиотека может использоваться как базовый вычислительный бэкенд в составе более крупных приложений, где требуется минимальная задержка (latency) при обработке визуальных данных и оптимизация энергопотребления за счет использования аппаратных ускорителей Apple Silicon.

Эксплуатация программы предполагает интеграцию API в итоговое приложение, где библиотека принимает на вход тензоры данных и веса модели, загруженные из внешних файлов (например, в формате JSON, подготовленном с помощью скрипта pt2json.py), и возвращает результаты вычислений нейронной сети.

2.3. Краткая характеристика области применения программы

Программа «project-name» применяется в области глубокого обучения (Deep Learning) и компьютерного зрения, конкретно в задачах оптимизации инференса сверточных нейронных сетей (CNN).

Область применения охватывает следующие сценарии:

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 81 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

- встраивание предобученных моделей (например, архитектуры LeNet) в мобильные приложения для анализа изображений в реальном времени;
- исследование эффективности квантования весов и активаций нейронных сетей при переходе от вещественных типов данных к целочисленным для оценки потери точности относительно вещественной реализации;
- сравнительный анализ производительности общего назначения (CPU/NEON) и специализированных матричных ускорителей (AMX) на конкретных архитектурах Apple Silicon.

Программа интегрируется в бизнес-процессы разработки мобильного ПО как низкоуровневый API, обеспечивающий высокую пропускную способность при обработке тензорных данных.

График сравнения производительности CPU- и AMX-режимов приведен в приложении 4.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 81 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

3. ТЕХНИЧЕСКИЕ ХАРАКТЕРИСТИКИ

3.1. Постановка задачи на разработку программы

Целью разработки является создание высокопроизводительной программной библиотеки (API) для выполнения прямого прохода (inference) сверточных нейронных сетей (CNN) на мобильных устройствах с архитектурой Apple Silicon.

Основной задачей является реализация эффективных механизмов вычислений, которые позволят минимизировать время обработки данных при сохранении заданной точности. В рамках проекта необходимо решить следующие подзадачи:

- Реализовать преобразование `im2col` для сведения операции свертки к операции матричного умножения (GEMM), что позволяет использовать оптимизированные библиотечные или аппаратные методы перемножения матриц.
- Разработать два пути исполнения операций: высокопроизводительный путь с использованием Apple Matrix Coprocessor (AMX) и эталонный/резервный путь на базе CPU с использованием векторных инструкций NEON.
- Обеспечить поддержку как вещественных вычислений, так и квантованных представлений данных различной разрядности для снижения требований к памяти и увеличения скорости работы.
- Реализовать базовый набор слоев нейронной сети, включая сверточные слои (Conv2D), полносвязные слои (Linear), функции активации (ReLU, Softmax) и слои пулинга (AvgPool2D).
- Создать систему бенчмарков для количественного сравнения производительности и точности различных режимов исполнения.

Ожидаемым результатом является библиотека, способная загружать веса предобученной модели (например, LeNet) и выполнять предсказание на входных изображениях с зафиксированными параметрами производительности и точности.

3.2. Описание и обоснование выбора состава технических и программных средств

3.2.1. Состав технических и программных средств

Для реализации и тестирования проекта используется следующий стек:

- **Оборудование:** Устройства Apple на базе процессоров Apple Silicon (серии M или A), поддерживающие инструкции ARM NEON и имеющие блок AMX.
- **Операционная система:** macOS / iOS.
- **Язык программирования:** C++ (стандарт C++17 или выше) для обеспечения максимальной производительности и низкоуровневого контроля памяти.
- **Инструменты разработки и сборки:**
 - Компилятор Clang (в составе Xcode).
 - Среда разработки Xcode.
 - Скрипты на Python (для конвертации весов моделей из формата PyTorch в JSON).
- **Форматы данных:** JSON (для сериализации весов и конфигурации модели), JPEG (для входных тестовых изображений).

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 81 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

3.2.2. Обоснование выбора технических и программных средств

Выбор языка C++ обусловлен необходимостью разработки системного ПО с минимальными задержками. Прямое управление памятью и возможность использования интринсиков позволяют максимально эффективно задействовать архитектурные особенности Apple Silicon.

Использование архитектуры Apple Silicon (М-чипы) продиктовано целью проекта — изучением и применением специализированных ускорителей (AMX), которые значительно превосходят стандартные CPU-вычисления в задачах линейной алгебры.

Инструкции ARM NEON выбраны в качестве базового метода векторных вычислений, так как они обеспечивают переносимость кода между различными моделями процессоров ARM и служат надежным эталоном для проверки корректности работы более сложных оптимизаций.

Формат JSON для хранения весов был выбран из-за его простоты в реализации и читаемости, что упрощает процесс отладки и конвертации моделей из популярных фреймворков глубокого обучения (PyTorch) через вспомогательные Python-скрипты.

3.3. Описание и обоснование архитектуры программы

Архитектура библиотеки построена по модульному принципу, разделяя описание математических операций, аппаратную реализацию и высокоуровневое описание нейронной сети.

Основные уровни архитектуры:

1. **Core Layer (Ядро):** Содержит базовые структуры данных. Ключевым элементом является класс `Tensor`, который описывает многомерный массив данных, его размерность (`TensorDesc`) и тип данных (`dtype`). Реализованы итераторы и механизмы отображения тензоров (`TensorView`).
2. **Ops Layer (Операторы):** Содержит элементарные математические операции. Здесь реализованы `matmul` (умножение матриц), `elementwise` операции (сложение, активации) и специализированные функции для работы с тензорами.
3. **Backend Layer (Бэкенды исполнения):** Реализует одну и ту же операцию разными способами. Существуют отдельные реализации для AMX (максимальная скорость) и CPU/NEON (совместимость и эталон).
4. **NN Layer (Слой нейросети):** Высокоуровневые абстракции, такие как `Layer`, `Conv2D`, `Linear` и `LeNet`. Слой `Conv2D` использует вспомогательный модуль `conv_im2col` для преобразования свертки в матричное умножение перед передачей данных в выбранный бэкенд.
5. **Serialization Layer:** Отвечает за загрузку параметров модели из внешних файлов в структуры данных библиотеки.

Такая структура позволяет легко добавлять новые типы слоев или новые аппаратные ускорители, не затрагивая логику работы всей сети.

3.4. Особенности функционала

3.4.1. Модуль `im2col` и сверточные вычисления

Назначение: преобразование входного тензора изображения в матрицу, где каждая строка представляет собой развернутый патч, на который накладывается ядро свертки.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 81 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

- **Входные данные:** Входной тензор, параметры ядра (kernel size), шаг (stride), отступы (padding) и количество каналов.
- **Действия системы:** Вычисление индексов элементов входного тензора и их переупорядочивание в плоскую матрицу.
- **Результат:** Матрица, готовая к перемножению с матрицей весов слоя свертки через операцию GEMM.

3.4.2. Бэкенд CPU/NEON

Назначение: обеспечение базового режима вычислений с использованием векторных инструкций ARM.

- **Входные данные:** Тензоры данных и весов.
- **Действия системы:** Выполнение операций перемножения и суммирования с использованием SIMD-инструкций NEON.
- **Результат:** Вычисленный тензор с точностью, соответствующей вещественному или квантованному представлению.
- **Примечание:** CPU/NEON-бэкенд используется как переносимый эталонный и резервный путь исполнения для проверки корректности ускоренных режимов.

3.4.3. Механизм квантования данных

Назначение: поддержка вычислений с пониженной разрядностью для ускорения инференса и снижения потребления памяти.

- **Входные данные:** Вещественные веса модели и параметры масштабирования (scaling factors).
- **Действия системы:** Приведение данных к квантованному виду, выполнение операций с учетом разрядности, последующее деквантование или масштабирование результата.
- **Результат:** Результаты вычислений с минимально допустимой потерей точности относительно вещественной реализации.

3.4.4. Сценарий измерения производительности (Benchmarks)

Назначение: количественный анализ скорости работы CPU и AMX режимов.

- **Входные данные:** Тестовая модель (например, LeNet), набор входных изображений, конфигурация разрядности.
- **Действия системы:** Многократный запуск инференса модели в разных режимах с замерением времени выполнения каждого слоя.
- **Результат:** Статистические данные по времени выполнения и точности предсказаний.
- График сравнения производительности CPU- и AMX-режимов приведен в приложении 4.

3.5. Обоснование выбора метода организации входных и выходных данных

Входные данные в программе представлены в двух форматах:

- **Конфигурационные данные:** Веса и параметры модели хранятся в формате JSON. Это обеспечивает удобство передачи данных между Python-скриптом подготовки и C++ библиотекой.
- **Данные для обработки:** Изображения подаются в виде тензоров в памяти, которые загружаются из файлов или генерируются в ходе тестов.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 81 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

Внутренняя организация данных основана на использовании плоских массивов с дополнительным описанием размерностей (TensorDesc). Это позволяет эффективно работать с памятью и передавать указатели на данные в низкоуровневые функции AMX и NEON без лишнего копирования.

Выходные данные программы представляют собой тензор с вероятностями классов (после слоя Softmax), который может быть выведен в консоль или использован в интеграционных тестах для проверки корректности классификации (например, для набора данных MNIST).

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 81 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

4. ОЖИДАЕМЫЕ ТЕХНИКО-ЭКОНОМИЧЕСКИЕ ПОКАЗАТЕЛИ

4.1. Ориентировочная экономическая эффективность

Экономическая эффективность разработки библиотеки высокопроизводительного вывода сверточных нейронных сетей (CNN) на устройствах Apple Silicon заключается в существенном снижении затрат вычислительных ресурсов и оптимизации энергопотребления мобильных устройств.

Внедрение специализированного исполнения через AMX (Apple Matrix Extensions) и оптимизированных NEON-инструкций позволяет достичь значительного ускорения обработки данных по сравнению с общими CPU-реализациями. Это ведет к следующим эффектам:

- **Снижение энергопотребления:** за счет сокращения времени активного состояния процессора при выполнении тяжелых операций свертки, что увеличивает автономность мобильных устройств.
- **Повышение пропускной способности:** возможность обработки большего количества кадров или запросов в единицу времени на одном устройстве, что снижает потребность в аппаратном масштабировании.
- **Оптимизация памяти:** использование квантованных представлений данных (различной разрядности) позволяет сократить объем занимаемой оперативной памяти и ускорить передачу весов модели из памяти в вычислительные блоки.

4.2. Предполагаемая потребность

Целевой аудиторией разработки являются разработчики мобильных приложений для экосистемы Apple, специализирующиеся на задачах компьютерного зрения (Computer Vision), а также исследователи в области глубокого обучения, создающие легковесные модели для Edge-вычислений.

Разработка востребована в следующих сценариях использования:

- **Реальное время (Real-time inference):** приложения для распознавания объектов, лиц или жестов, где критически важна низкая задержка (latency) отклика.
- **Ограниченные ресурсы:** работа с моделями VGG-уровня на устройствах с ограниченным объемом ОЗУ, где требуется эффективное квантование без значительной потери точности.
- **Кросс-архитектурная совместимость:** необходимость наличия как максимально быстрого пути исполнения (AMX), так и стабильного резервного/эталонного режима (CPU/NEON) для обеспечения совместимости с различными поколениями чипов Apple Silicon.

4.3. Экономические преимущества разработки по сравнению с отечественными и зарубежными аналогами

Разрабатываемое решение ориентировано на максимальное использование специфического аппаратного обеспечения Apple Silicon, в частности AMX, что дает преимущество перед универсальными библиотеками, которые могут не использовать все доступные инструкции платформы или иметь избыточный оверхед.

В отличие от тяжеловесных фреймворков, данная библиотека предоставляет специализированный API для CNN-вывода, поддерживая гибкий выбор между вещественной точностью и квантованными режимами, что позволяет точно балансировать между точностью предсказания и скоростью работы.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 81 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

Характеристика	Общие CPU-реал.	Универсальные SDK	Спец. библиотеки	Our Project
Поддержка AMX (Apple Silicon)	-	-	+	+
Квантование разной разрядности	-	+	+	+
Низкий оверхед (Lightweight)	+	-	-	+
Наличие NEON-fallback	+	+	+	+
Оптимизация im2col	-	+	+	+
Итого	2	3	4	5

Таблица 1. Сравнение функциональных характеристик с существующими подходами

График сравнения производительности CPU- и AMX-исполнения приведен в приложении 4. Показатели оценки точности квантованных моделей относительно вещественной реализации приведены в приложении 5.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 81 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

ПРИЛОЖЕНИЕ 1. СПИСОК ИСПОЛЬЗУЕМОЙ ЛИТЕРАТУРЫ

1. ГОСТ 19.101-77: Виды программ и программных документов. // Единая система программной документации. – М.: ИПК Издательство стандартов, 2001.
2. ГОСТ 19.102-77: Стадии разработки. // Единая система программной документации. – М.: ИПК Издательство стандартов, 2001.
3. ГОСТ 19.103-77: Обозначения программ и программных документов. // Единая система программной документации. – М.: ИПК Издательство стандартов, 2001.
4. ГОСТ 19.104-78: Основные надписи. // Единая система программной документации. – М.: ИПК Издательство стандартов, 2001.
5. ГОСТ 19.105-78: Общие требования к программным документам. // Единая система программной документации. – М.: ИПК Издательство стандартов, 2001.
6. ГОСТ 19.106-78: Требования к программным документам, выполненным печатным способом. // Единая система программной документации. – М.: ИПК Издательство стандартов, 2001.
7. ГОСТ 19.201-78: Техническое задание. Требования к содержанию и оформлению. // Единая система программной документации. – М.: ИПК Издательство стандартов, 2001.
8. ГОСТ 19.301-79: Программа и методика испытаний. Требования к содержанию и оформлению. // Единая система программной документации. – М.: ИПК Издательство стандартов, 2001.
9. ГОСТ 19.401-78: Текст программы. Требования к содержанию и оформлению. // Единая система программной документации. – М.: ИПК Издательство стандартов, 2001.
10. ГОСТ 19.404-79: Пояснительная записка. Требования к содержанию и оформлению. // Единая система программной документации. – М.: ИПК Издательство стандартов, 2001.
11. ГОСТ 19.505-79: Руководство оператора. Требования к содержанию и оформлению. // Единая система программной документации. – М.: ИПК Издательство стандартов, 2001.
12. ГОСТ 19.603-78: Общие правила внесения изменений. // Единая система программной документации. – М.: ИПК Издательство стандартов, 2001.
13. ГОСТ 19.604-78: Правила внесения изменений в программные документы, выполненные печатным способом. // Единая система программной документации. – М.: ИПК Издательство стандартов, 2001.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 81 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

ПРИЛОЖЕНИЕ 2. ССЫЛКИ НА АНАЛОГИ

Аналог	Ссылка
Core ML	https://developer.apple.com/documentation/coreml
Accelerate Framework	https://developer.apple.com/documentation/accelerate
BNNS	https://developer.apple.com/documentation/accelerate/bnns
TensorFlow Lite	https://www.tensorflow.org/lite
TensorFlow Lite Core ML Delegate	https://www.tensorflow.org/lite/performance/coreml_delegate
ONNX Runtime	https://onnxruntime.ai/
PyTorch Mobile	https://pytorch.org/mobile/home/
MNN	https://github.com/alibaba/MNN
ncnn	https://github.com/Tencent/ncnn

Дата обращения: 11.04.26.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 81 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

ПРИЛОЖЕНИЕ 3. ТЕРМИНОЛОГИЯ

Термин	Определение
Инференс	Прямой проход нейронной сети по входным данным с получением результата классификации, регрессии или другого предсказания без дообучения модели.
Сверточная нейронная сеть	Архитектура нейронной сети, применяющая операции свертки для выделения признаков из изображений и других данных с пространственной структурой.
Тензор	Многомерный массив числовых данных, используемый для хранения входных изображений, весов модели, промежуточных активаций и выходных результатов нейронной сети.
Backend	Низкоуровневый путь исполнения вычислительной операции, например эталонная реализация на CPU/NEON или ускоренная реализация через AMX.
CPU/NEON-эталон	Базовая программная реализация вычислений на центральном процессоре с использованием векторных инструкций NEON, применяемая для проверки корректности ускоренного пути исполнения.
Apple Silicon	Семейство систем на кристалле Apple на базе архитектуры ARM64, включающее центральный процессор, графический процессор, ускорители и объединенную память.
AMX	Apple Matrix Extensions или Apple Matrix Coprocessor – аппаратный механизм Apple Silicon, предназначенный для ускорения матричных вычислений.
Accelerate	Системный фреймворк Apple, предоставляющий оптимизированные функции линейной алгебры, обработки сигналов и нейросетевых вычислений.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 81 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

Термин	Определение
GEMM	Обобщенное матричное умножение, являющееся базовой операцией для полносвязных слоев и ускоренной реализации сверток через преобразование im2col.
Conv2D	Двумерная свертка, применяемая в сверточных слоях для вычисления карт признаков по входному изображению и набору фильтров.
im2col	Метод преобразования областей входного изображения в матричное представление, позволяющий выполнять свертку через матричное умножение.
Квантование	Представление весов и активаций нейронной сети с меньшей разрядностью для снижения потребления памяти и ускорения вычислений при допустимой потере точности.
LeNet	Классическая архитектура сверточной нейронной сети, используемая в проекте как тестовая модель для проверки корректности инференса.
Softmax	Функция активации, преобразующая выходной вектор модели в распределение вероятностей по классам.
Fallback	Резервное переключение вычислений на CPU/NEON-реализацию при недоступности или ошибке ускоренного пути исполнения.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 81 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

ПРИЛОЖЕНИЕ 4. ГРАФИК СРАВНЕНИЯ ПРОИЗВОДИТЕЛЬНОСТИ




Рис. 1. Сравнение ускорения АМХ-исполнения относительно CPU/NEON-исполнения
Источник данных: результаты выполнения бенчмарков матричного умножения.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 81 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

ПРИЛОЖЕНИЕ 5. ПОКАЗАТЕЛИ ОЦЕНКИ ТОЧНОСТИ КВАНТОВАННЫХ МОДЕЛЕЙ

Режим	Сравнение	Показатель	Критерий
Вещественная модель	Базовый режим	Точность классификации	Эталон
Квантованная модель	Относительно вещественной модели	Падение точности	Не более 1–3%
Квантованная модель	Относительно вещественной модели	Совпадение класса с максимальной вероятностью	Не ниже 95%
Квантованная модель	Относительно CPU/NEON-эталона	Численное отклонение выходного тензора	В пределах допустимой погрешности

Таблица 5. Показатели оценки точности квантованных моделей относительно вещественной реализации

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 81 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

ЛИСТ РЕГИСТРАЦИИ ИЗМЕНЕНИЙ

[illegible]