

**ПРАВИТЕЛЬСТВО РОССИЙСКОЙ ФЕДЕРАЦИИ
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ
ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ
"ВЫСШАЯ ШКОЛА ЭКОНОМИКИ"**

Факультет компьютерных наук
Образовательная программа "Программная инженерия"

СОГЛАСОВАНО

Научный руководитель, научный
сотрудник ФИЦ ИУ РАН

_____ Е. Е. Лимонова
«__» _____ 2026 г.

УТВЕРЖДЕНО

Академический руководитель
образовательной программы
"Программная инженерия", старший
преподаватель Департамента
программной инженерии

_____ Н. А. Павлочев
«__» _____ 2026 г.

**БЫСТРАЯ РЕАЛИЗАЦИЯ ВЕЩЕСТВЕННЫХ И КВАНТОВАННЫХ
СВЕРТОЧНЫХ НЕЙРОННЫХ СЕТЕЙ НА МОБИЛЬНЫХ УСТРОЙСТВАХ
APPLE**

Руководство оператора

ЛИСТ УТВЕРЖДЕНИЯ

RU.17701729.04.06 34 01-1-ЛУ

Исполнители:

Студент группы БПИ241

_____ / Г. А. Суханов /

«__» _____ 2026 г.

Подп. и дата	
Инв.№ дубл.	
Взам. инв.№	
Подп. и дата	
Инв.№ подл	

УТВЕРЖДЕН

RU.17701729.04.06 34 01-1-ЛЮ

**БЫСТРАЯ РЕАЛИЗАЦИЯ ВЕЩЕСТВЕННЫХ И КВАНТОВАННЫХ
СВЕРТОЧНЫХ НЕЙРОННЫХ СЕТЕЙ НА МОБИЛЬНЫХ УСТРОЙСТВАХ
APPLE**

Руководство оператора

RU.17701729.04.06 34 01-1

Листов 11

Инов.№ подп	Подп. и дата	Взам. инв.№	Инов.№ дубл.	Подп. и дата

АННОТАЦИЯ

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 34 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

СОДЕРЖАНИЕ

1. НАЗНАЧЕНИЕ ПРОГРАММЫ	4
1.1. Функциональное назначение	4
1.2. Эксплуатационное назначение	4
2. УСЛОВИЯ ВЫПОЛНЕНИЯ ПРОГРАММЫ	6
2.1. Минимальный состав аппаратных средств	6
2.2. Минимальный состав программных средств	6
2.3. Требования к персоналу (пользователю)	6
3. Выполнение программы	7
3.1. Установка программы	7
3.2. Запуск программы и работа с приложением	7
3.2.1. Запуск интеграционных тестов (проверка точности)	7
3.2.2. Проведение бенчмаркинга (сравнение производительности)	7
3.2.3. Конвертация весов модели	8
3.2.4. Работа с квантованными представлениями	8
СООБЩЕНИЯ ОПЕРАТОРУ	9
Тексты сообщений оператору	9
Действия оператора в исключительных ситуациях	9

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 34 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

1. НАЗНАЧЕНИЕ ПРОГРАММЫ

1.1. Функциональное назначение

Программа «Быстрая реализация вещественных и квантованных сверточных нейронных сетей на мобильных устройствах Apple» предназначена для выполнения пользовательских сценариев, описанных в техническом задании.

Основным функциональным назначением программы является предоставление высокопроизводительного программного интерфейса (API) для инференса сверточных нейронных сетей (CNN) на устройствах с архитектурой Apple Silicon. Программа реализует набор низкоуровневых примитивов и высокоуровневых слоев, необходимых для развертывания моделей компьютерного зрения (уровня VGG).

В состав функциональных возможностей программы входят:

- выполнение преобразования $im2col$ для сведения операции свертки к операции матричного умножения с учетом параметров ядра, шага, отступов и числа каналов;
- поддержка нескольких путей исполнения вычислений:
 - CPU/NEON-путь, выступающий в роли эталонного и резервного режима;
 - AMX-путь (Apple Matrix Extensions) для максимально быстрого выполнения матричных операций;
- поддержка различных представлений данных:
 - вещественные числа для обеспечения высокой точности;
 - квантованные представления различной разрядности с соответствующими параметрами масштабирования для оптимизации производительности и энергопотребления;
- реализация стандартных слоев нейронной сети: сверточных слоев (Conv2D), полносвязных слоев (Linear), функций активации (ReLU, Softmax) и слоев пулинга (AvgPool2D);
- обеспечение механизмов сериализации и загрузки весов моделей из внешних файлов (например, в формате JSON).

1.2. Эксплуатационное назначение

Программный проект по созданию высокопроизводительной реализации сверточных нейронных сетей на устройствах Apple Silicon. В рамках работы сравниваются CPU- и AMX-исполнения, поддерживаются вещественные и квантованные представления различной разрядности, а целевой архитектурой выступает VGG-уровень для задач компьютерного зрения.

Программный продукт предназначен для использования разработчиками мобильных приложений и инженерами по машинному обучению, стремящимися оптимизировать скорость работы нейронных сетей на устройствах Apple. Программа позволяет проводить сравнительный анализ производительности между различными режимами исполнения (CPU против AMX) и оценивать влияние квантования данных на итоговую точность предсказаний модели.

В эксплуатационном режиме программа используется как библиотека, интегрируемая в состав более крупных приложений для компьютерного зрения. Для проверки корректности работы и измерения показателей производительности в программу включены специализированные бенчмарки и интеграционные тесты (например, на архитектуре LeNet), позволяющие фиксировать время выполнения, размер пакета данных и точность вычислений.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 34 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

TODO: вставить скрин или график сравнения производительности CPU и AMX-исполнения

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 34 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

2. УСЛОВИЯ ВЫПОЛНЕНИЯ ПРОГРАММЫ

2.1. Минимальный состав аппаратных средств

Для обеспечения работоспособности библиотеки и проведения сравнительных тестов производительности требуются следующие аппаратные средства:

1. Мобильное устройство или компьютер на базе архитектуры Apple Silicon (процессоры серии М или А);
2. Наличие специализированного вычислительного блока AMX (Apple Matrix Extensions) для использования высокопроизводительного режима матричного умножения;
3. Поддержка инструкций NEON для работы эталонного CPU-пути исполнения и базовых операций свертки;
4. Объем оперативной памяти, достаточный для размещения весов нейронной сети (например, архитектуры LeNet) и промежуточных тензоров в памяти устройства;
5. Свободное место на накопителе для хранения файлов весов модели в формате JSON и тестовых входных изображений.

2.2. Минимальный состав программных средств

Для сборки, развертывания и эксплуатации программы необходимо наличие следующих программных средств:

1. Операционная система семейства Apple (iOS или macOS), совместимая с целевой архитектурой Apple Silicon;
2. Среда разработки Xcode (актуальной версии) с установленным компилятором Clang, поддерживающим стандарт C++17 или выше;
3. Инструментарий командной строки для сборки и запуска бенчмарков;
4. Интерпретатор Python (версии 3.x) для работы вспомогательного скрипта `pt2json.py`, предназначенного для конвертации весов из формата PyTorch в JSON;
5. Библиотеки стандартной шаблонизации C++ (STL) для управления памятью и базовых структур данных.

2.3. Требования к персоналу (пользователю)

Пользователем программы является разработчик или инженер по машинному обучению, интегрирующий библиотеку в конечное приложение. К пользователю предъявляются следующие требования:

1. Владение языком программирования C++ на уровне, достаточном для работы с заголовочными файлами API библиотеки и интеграции её в проект;
2. Базовые знания в области архитектуры сверточных нейронных сетей (CNN), понимание принципов работы сверточных слоев, операций пулинга (Average Pooling) и функций активации (ReLU, Softmax);
3. Понимание концепций квантования данных и разрядности представлений для настройки параметров масштабирования в квантованном режиме;
4. Навыки работы с терминалом и инструментами сборки проектов в экосистеме Apple.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 34 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

3. Выполнение программы

3.1. Установка программы

Для развертывания и настройки среды исполнения библиотеки `project-name` необходимо подготовить аппаратную платформу на базе Apple Silicon (М-серия), так как функционал АМХ-исполнения привязан к специфическим инструкциям данной архитектуры.

Процесс установки и настройки включает следующие этапы:

1. Клонирование исходного кода проекта из репозитория.
2. Установка среды разработки Xcode (версии 15.0 или выше) для компиляции C++ кода.
3. Настройка окружения Python для работы со скриптом `pt2json.py`, который используется для конвертации весов моделей из формата PyTorch в JSON-формат, поддерживаемый библиотекой.
4. Компиляция проекта с использованием стандартных средств сборки (например, CMake или Xcode Build), при этом в настройках компилятора должны быть указаны флаги оптимизации для архитектуры `arm64` и поддержка SIMD-инструкций NEON.
5. Размещение файлов весов (например, `mnist_lenet.json`) и тестовых изображений в директории `tests/weights/` и `tests/inputs_test/` соответственно.

3.2. Запуск программы и работа с приложением

Поскольку `project-name` представляет собой API-библиотеку (CNN inference API library), взаимодействие с ней осуществляется через запуск скомпилированных исполняемых файлов тестов (`lenet_test`) или бенчмарков (`lenet_benchmark`). Управление параметрами работы происходит на этапе конфигурации кода или через передачу аргументов запуска.

3.2.1. Запуск интеграционных тестов (проверка точности)

Данный сценарий используется для проверки корректности работы реализации сверточных слоев, `im2col`-преобразования и функций активации.

Действия оператора:

1. Скомпилировать файл `lenet_test.cpp`.
2. Запустить исполняемый файл, указав путь к файлу весов `mnist_lenet.json` и тестовым изображениям из папки `inputs_test`.

Реакция программы: Программа загружает веса модели, инициализирует тензоры, выполняет прямой проход (`inference`) по тестовому набору данных и выводит результат классификации для каждого изображения.

Ожидаемый результат: Вывод в консоль предсказанного класса для каждого тестового изображения. Сравнение результатов между CPU-исполнением и АМХ-исполнением должно показывать идентичные или близкие значения (с учетом погрешности квантования).

TODO: вставить скриншот вывода консоли с результатами тестов `lenet_test`

3.2.2. Проведение бенчмаркинга (сравнение производительности)

Сценарий предназначен для измерения времени выполнения операций и сравнения эффективности CPU/NEON и АМХ режимов.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 34 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

Действия оператора:

1. Скомпилировать файл `lenet_benchmark.cpp`.
2. Запустить программу с выбором режима вычислений (CPU или AMX) и указанием разрядности данных (вещественные или квантованные).
3. Зафиксировать параметры эксперимента: размер входного тензора, размер пакета (batch size) и тип данных.

Реакция программы: Программа выполняет многократный запуск итераций сверточного слоя или всей сети LeNet, замеряя время выполнения каждой операции с помощью высокоточного таймера.

Ожидаемый результат: Вывод в консоль среднего времени выполнения операции в миллисекундах или микросекундах, а также расчет пропускной способности.

TODO: вставить скриншот или график сравнения производительности CPU vs AMX

3.2.3. Конвертация весов модели

Сценарий подготовки данных для работы библиотеки с использованием внешнего скрипта.

Действия оператора:

1. Запустить скрипт `pt2json.py` через интерпретатор Python.
2. Передать на вход файл модели PyTorch (.pth) и указать путь для сохранения результирующего .json файла.

Реакция программы: Скрипт считывает тензоры весов и смещений из модели PyTorch, нормализует их (в случае квантования) и записывает в структурированный JSON-файл.

Ожидаемый результат: Создание файла `mnist_lenet.json`, который может быть считан классом `serialization` библиотеки для инициализации слоев нейронной сети.

3.2.4. Работа с квантованными представлениями

Сценарий проверки работы сети в режиме пониженной разрядности.

Действия оператора:

1. В конфигурации инициализации модели выбрать квантованный тип данных (согласно `fastinf/core/dtype.hpp`).
2. Запустить выполнение сети на тестовых данных.

Реакция программы: Библиотека использует специализированные пути исполнения для квантованных данных, применяя параметры масштабирования (scaling factors) для корректного приведения типов.

Ожидаемый результат: Выполнение инференса с меньшим потреблением памяти и потенциально более высокой скоростью работы при сохранении приемлемой точности классификации.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 34 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

СООБЩЕНИЯ ОПЕРАТОРУ

3.2.4 Тексты сообщений оператору

Поскольку библиотека представляет собой программный интерфейс (API) для высокопроизводительных вычислений, сообщения оператору выводятся в стандартный поток ошибок (stderr) или через механизмы логирования при возникновении критических сбоев в процессе инициализации или исполнения нейронной сети.

Ключевые категории сообщений включают:

- **Ошибки инициализации и загрузки:** сообщения о невозможности найти или прочитать файл с весами модели (например, при некорректном пути к .json файлу), а также ошибки десериализации структуры сети.
- **Ошибки совместимости типов:** предупреждения о несоответствии разрядности входных данных и выбранного режима исполнения (вещественный или квантованный).
- **Ошибки выделения памяти:** уведомления о невозможности выделить непрерывный блок памяти для тензоров при работе с большими размерами пакетов (batch size) или слоями с большим числом каналов.
- **Ошибки конфигурации тензоров:** сообщения о несоответствии размерностей при операциях свертки (conv2d) или матричного умножения (matmul), например, если размер входного тензора не соответствует ожидаемому размеру ядра или шага.
- **Информационные сообщения о режиме исполнения:** уведомления о выбранном бэкенде вычислений (CPU/NEON или AMX) и используемом представлении данных.

3.2.4 Действия оператора в исключительных ситуациях

При возникновении исключительных ситуаций оператор должен предпринять следующие действия в зависимости от типа проблемы:

- **Некорректные входные данные или веса:** При получении ошибки загрузки модели необходимо проверить целостность JSON-файла с весами и соответствие структуры сети (количество слоев, размерности) архитектуре, заложенной в коде (например, LeNet). Проверить правильность путей к файлам в конфигурации запуска.
- **Ошибка несовместимости архитектуры процессора:** Если при попытке использования AMX-исполнения возникает сбой или ошибка инициализации, оператору следует переключить режим вычислений на CPU/NEON, который является эталонным и резервным режимом исполнения для всех поддерживаемых устройств Apple Silicon.
- **Превышение лимитов памяти:** В случае ошибок выделения памяти (out of memory) необходимо уменьшить размер входного пакета (batch size) или оптимизировать размерность входных тензоров.
- **Низкая точность квантованного исполнения:** При обнаружении значительного расхождения в результатах между вещественной и квантованной реализациями, оператору следует проверить параметры масштабирования (scaling factors) и разрядность квантования, согласованную с моделью.
- **Нестабильная работа или падение (crash):** В случае критического сбоя оператор должен зафиксировать параметры эксперимента (размер входа, тип данных, разрядность, режим вы-

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 34 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

числений) и предоставить данные логи через систему отслеживания ошибок или репозиторий проекта.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.06 34 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

ЛИСТ РЕГИСТРАЦИИ ИЗМЕНЕНИЙ

[illegible]